



**UNIVERSIDAD DE CHILE
FACULTAD DE CIENCIAS FISICAS Y MATEMATICAS
DEPARTAMENTO DE INGENIERÍA ELÉCTRICA**

**PREDICCIÓN DE LA POTENCIA PARA LA OPERACIÓN DE PARQUES
EÓLICOS**

MEMORIA PARA OPTAR AL TÍTULO DE INGENIERO CIVIL ELECTRICISTA

IGNACIO ERBETTA MATTIG

**PROFESOR GUÍA:
DORIS SÁEZ HUEICHAPAN**

**PROFESOR CO-GUÍA:
MARCOS ORCHARD CONCHA**

**MIEMBRO DE LA COMISIÓN:
HÉCTOR AGUSTO ALEGRÍA**

**SANTIAGO DE CHILE
Noviembre de 2010**

“PREDICCIÓN DE LA POTENCIA PARA LA OPERACIÓN DE PARQUES EÓLICOS”

Tomando en cuenta la reciente incorporación de varios parques eólicos al SIC y la naturaleza estocástica de la velocidad del viento, se hace imprescindible contar con una herramienta que sea capaz de pronosticar el nivel de generación en un parque eólico, de manera de facilitar y optimizar la programación diaria manteniendo la calidad de suministro por parte del CDEC; organismo encargado de garantizar la operación de las instalaciones del sector eléctrico en Chile.

El objetivo general de este trabajo es desarrollar un predictor de potencia activa para el Parque Eólico Canela para un horizonte máximo de 36 horas, entregándose los resultados no sólo en términos del valor esperado de la predicción, sino también a través de la generación de intervalos del 95% confianza. Para realizar este trabajo, se han analizado datos históricos de velocidad de viento y potencia activa del Parque Eólico Canela provistos por ENDESA ECO, así como predicciones diarias de velocidad de viento provistas por la DGAC. Los datos han sido tomados con un tiempo de muestreo de 1 hora.

Para el desarrollo del modelo predictor se han probado modelos lineales FIR y ARX, que consideran como variables de entrada la velocidad de viento, la potencia y sus retardos; y un modelo no lineal (red neuronal MLP), que considera como entrada sólo la velocidad del viento. Además se implementó un modelo de referencia (modelo de referencia de Nielsen). El modelo que mostró mejores resultados es la red neuronal MLP con una mejora de un 62% en el error cuadrático medio con respecto al modelo de referencia, superando ampliamente al modelo ARX, que mostró una mejora del 25% y al modelo FIR, que mostró una mejora del 10%. Para la calibración de estos modelos se asume conocida con exactitud la velocidad del viento en el futuro, condición que es posteriormente relajada para dar paso a la utilización de la predicción de velocidad de viento de la DGAC.

Luego, se ha realizado una caracterización del error de predicción de la velocidad del viento entregada por la DGAC en función del horizonte de predicción y del valor de la predicción. Como entrada al predictor se ha utilizado la predicción de velocidad de viento provista por la DGAC, la cual es perturbada con realizaciones del proceso estocástico que caracteriza el error de predicción ejecutándose una simulación de Monte Carlo. La salida del predictor es el valor medio de las salidas de cada iteración de la simulación. El intervalo de confianza es calculado como el menor rango de potencia que acumule el 95% de probabilidad de ocurrencia en el histograma de salida.

El predictor ha logrado un error absoluto medio en torno al 12% en un horizonte de 36 horas, mejorando al método simple en 2,3 p.p. Este valor es cercano a los obtenidos por los mejores modelos de predicción desarrollados por empresas que prestan el servicio de predicción de potencia para parques eólicos. Además, se ha realizado una comparación con una predicción simple que consiste en calcular la potencia utilizando como entrada al modelo directamente la predicción de velocidad de viento. El método implementado mejora en hasta un 7% al método simple. El nuevo método implementado es muy exacto con un error medio cercano al 0%, a diferencia del método simple que tiene un error medio de un -8%. El método es computacionalmente eficiente, se requieren menos de 10 segundos para obtener una predicción de potencia para las próximas 36 horas.

Como líneas de investigación futuras se propone principalmente estudiar las fuentes de error de la predicción de velocidad del viento de la DGAC e incorporarlas al modelo desarrollado con el objetivo de lograr mejores predicciones de potencia.

Índice

| | |
|--|----|
| RESUMEN | 2 |
| Capítulo 1 | 6 |
| 1.1 Introducción | 6 |
| 1.2 Motivación y Descripción del Problema | 7 |
| 1.3 Objetivo General | 8 |
| 1.4 Objetivos Específicos | 8 |
| 1.5 Metodología | 8 |
| 1.6 Estructura del Trabajo | 10 |
| Capítulo 2 | 11 |
| 2.1 Energías Renovables No Convencionales (ERNC) | 11 |
| 2.2 Energía Eólica | 11 |
| 2.3 Parque Eólico Canela | 14 |
| 2.4 Turbina Eólicas | 15 |
| 2.5 Modelación del viento | 18 |
| 2.5.1 Modelación Fenomenológica Global | 18 |
| 2.5.2 Distribución Estadística de la Velocidad del Viento | 19 |
| 2.5.3 Clasificación de Modelos | 21 |
| 2.5.3.1 Modelos Físicos | 22 |
| 2.5.3.2 Modelos Estocásticos | 23 |
| 2.5.3.3 Modelos de Correlación Espacial | 23 |
| 2.5.3.4 Modelos Basados en Inteligencia Artificial | 24 |
| 2.6 Productos Comerciales | 26 |
| 2.7 Integración de la Energía Eólica | 27 |
| Capítulo 3 | 29 |
| 3.1 Introducción | 29 |
| 3.2 Identificación de Sistemas | 29 |
| 3.2.1 Obtención de Datos | 29 |
| 3.2.2 Estructuras de Modelos | 30 |
| 3.2.3 Criterios de Selección de Estructura | 37 |
| 3.2.4 Estimación de Parámetros | 38 |
| Capítulo 4 | 39 |
| 4.1 Planteamiento del Problema | 39 |

| | | |
|-------------------|--|----|
| 4.2 | Protocolo de Evaluación de Modelos de Predicción de Potencia | 39 |
| 4.2.1 | Notación | 40 |
| 4.2.2 | Definición de Errores de Predicción..... | 40 |
| 4.2.3 | Definición de Medidas de Error..... | 41 |
| 4.2.4 | Comparación de Modelos | 42 |
| 4.2.5 | Modelos de Referencia | 42 |
| 4.3 | Selección y Obtención de Datos | 44 |
| 4.4 | Desarrollo de Modelos Lineales | 49 |
| 4.4.1 | Desarrollo de Modelo FIR..... | 49 |
| 4.4.2 | Desarrollo de Modelo ARX | 52 |
| 4.5 | Desarrollo de Red Neuronal MLP | 55 |
| 4.6 | Discusión de Resultados | 58 |
| Capítulo 5 | | 59 |
| 5.1 | Introducción | 59 |
| 5.2 | Descripción del Método..... | 59 |
| 5.3 | Estudio de Error de Predicción | 59 |
| 5.3.1 | Regularización de Función de Distribución Acumulada..... | 62 |
| 5.4 | Estudio de Predicción con Intervalo de Confianza | 64 |
| 5.5 | Resultados y Validación de Intervalo de Confianza..... | 67 |
| 5.6 | Discusión de Resultados | 69 |
| Capítulo 6 | | 71 |
| 6.1 | Conclusiones Generales | 71 |
| 6.2 | Conclusiones Específicas | 71 |
| 6.3 | Líneas de Investigación futuras | 72 |
| Referencias | | 73 |
| Anexo A | | 75 |
| A.1 | Fuerza de Advección | 75 |
| A.2 | Fuerza de Gradiente de Presión | 75 |
| A.3 | Fuerza de Coriolis..... | 75 |
| A.4 | Fuerza de Arrastre Turbulento | 76 |
| A.5 | Perfil Vertical | 76 |
| Anexo B | | 77 |
| Anexo C | | 78 |
| Anexo D | | 79 |
| D.1 | Arquitectura de Red Neuronal | 79 |

| | | |
|--------------|-----------------------------|----|
| D.2 | Pesos de Red Neuronal | 80 |
| Anexo E..... | | 82 |
| Anexo F..... | | 85 |

Capítulo 1

1.1 Introducción

La demanda eléctrica en Chile ha aumentado a una tasa de 6,7% anual en los últimos 20 años y ha sido satisfecha principalmente mediante energía hidroeléctrica y energías no renovables tales como el carbón, petróleo y gas. El hecho de utilizar combustibles fósiles, y el no contar con la mayoría de ellos en nuestro país, genera una gran dependencia energética de Chile con respecto a otros países, donde el 63% de la energía que se genera hoy en día en Chile proviene de recursos extranjeros [1].

Por otra parte, se ha hecho reconocida la importancia de minimizar los efectos que las emisiones de gases invernadero tienen sobre el sistema climático. Es en este punto en donde las energías renovables no convencionales toman mayor importancia.

En el año 2008 se promulgó la ley 20.257 [2], que obliga a las empresas generadoras con capacidad instalada sobre 200 MW, a comercializar un 10% de energía proveniente de fuentes renovables no convencionales o centrales hidroeléctricas. La incorporación se hará gradualmente para llegar a un 5% en el año 2015 y un 10% en el año 2020.

En línea con lo anterior, la empresa ENDESA ECO ha creado el Parque Eólica Canela I, y se está incorporando el Parque Eólica Canela II. Entre ambos, generarán más de 90 MW de potencia nominal.

Las empresas generadoras deben cumplir con normativas en cuanto al nivel de generación de potencia con el objetivo de mantener estable el sistema interconectado. El CDEC (Centro de Despacho Económico de Carga) es el organismo encargado de realizar el despacho eléctrico y determinar el nivel de generación de cada central. Así, cada central está sujeta a esta determinación y debe acatarla o informar de algún problema técnico o mantención que impida alcanzar el nivel de generación solicitado.

En un parque eólico no es posible determinar con precisión el nivel de generación que presentará el parque con antelación dado que el nivel de generación depende directamente de la velocidad del viento, que puede definirse matemáticamente como un proceso estocástico. De manera de entregar una herramienta para predecir el nivel de generación eólica en un parque, el objetivo general de esta memoria es crear un predictor de potencia activa capaz de generar un intervalo de confianza para la potencia eléctrica para parques eólicos en un horizonte de predicción que establece la normativa vigente; en donde se especifica que se debe predecir en forma horaria el nivel de generación para el día siguiente.

1.2 Motivación y Descripción del Problema

Entre los beneficios que presenta la energía eólica se puede mencionar que no genera emisiones y que es económicamente competitiva, por esto, ha sido la forma de generación más instalada durante los últimos años en Europa [3].

Junto con los beneficios mencionados, este tipo de energía tiene algunas desventajas. Una de ellas es que no es capaz de suplir continuamente la demanda energética de un país. Esto se debe a que la naturaleza estocástica de la velocidad del viento para distintos momentos y lugares, produce problemas en la integración de este tipo de energía a la red eléctrica (ver Capítulo 2.7). La integración de la energía eólica es un problema para los operadores y planificadores de la red eléctrica ya que una vez estimada la demanda diaria, es necesario determinar el nivel de generación de cada central, de manera de suplir la demanda total y contar con las reservas que aseguren un buen funcionamiento del sistema.

El manual de procedimientos MP-12 [4] del CDEC-SIC establece la normativa vigente referente a la programación de corto plazo o programa diario, que es el proceso mediante el cual se definen para el o los días siguientes, según corresponda, los niveles de generación de cada una de las centrales del sistema, con el objeto de obtener una operación del sistema eléctrico segura y económica.

El CDEC-SIC determina en base a información estadística la demanda de potencia para el o los días siguientes, según lo cual procede a establecer el nivel de generación horario de cada central.

La consideración más importante para establecer el nivel de generación de las centrales es la utilización de una orden de mérito principalmente creada en base a los costos marginales de cada central. Otras consideraciones son las planificaciones de mantenimiento y las características técnicas y restricciones de las instalaciones del sistema.

Los parques eólicos tienen un costo marginal de generación igual a cero y, siendo éste un factor principal dentro de la determinación del programa diario, es normal que estén despachados los siete días de la semana a toda hora.

El CDEC-SIC debe mantener un estándar de calidad de suministro para lo cual se utilizan reservas por sobre la demanda esperada. Al no conocerse con precisión el nivel de generación en un parque eólico (debido a la naturaleza estocástica del viento), no es posible determinar con exactitud cuánto es el nivel de generación para cada central de manera tal de cumplir en todos los horarios con un despacho óptimo, entendiéndose éste como aquel que minimiza las reservas satisfaciendo la demanda plenamente. En este sentido, el conocer a priori el nivel de generación en un parque eólico en forma horaria es de gran ayuda para los operadores de la red puesto que así se puede determinar de manera más eficiente el nivel de generación del resto de las centrales y calcular con mayor certeza las reservas durante el día.

La motivación de este trabajo de memoria nace de la necesidad de contar un predictor de potencia en un parque eólico para lograr que el sistema interconectado funcione de la manera más económica y eficiente posible.

1.3 Objetivo General

El objetivo general de este trabajo es desarrollar un predictor de potencia activa para el Parque Eólico Canela en un horizonte máximo de 36 horas, generando un intervalo de confianza para los resultados. El intervalo de confianza es un rango estimado en donde existe una alta probabilidad de ocurrencia una variable aleatoria.

Se espera que este método de predicción pueda ser incorporado en el Parque Eólico Canela.

1.4 Objetivos Específicos

Los objetivos específicos son:

- Establecer el estado del arte de la modelación de potencia y/o viento utilizadas actualmente y reconocer sus fortalezas y debilidades.
- Implementar distintas estructuras de modelos predictivos y seleccionar el más apto para el caso de predicción de potencia activa en parques eólicos.
- Implementar un método novedoso de predicción de potencia utilizando predicciones de velocidad de viento, que considera la generación de un intervalo de confianza para las predicciones de potencia.

1.5 Metodología

La metodología de trabajo propuesta es la mostrada en Figura 1.1.

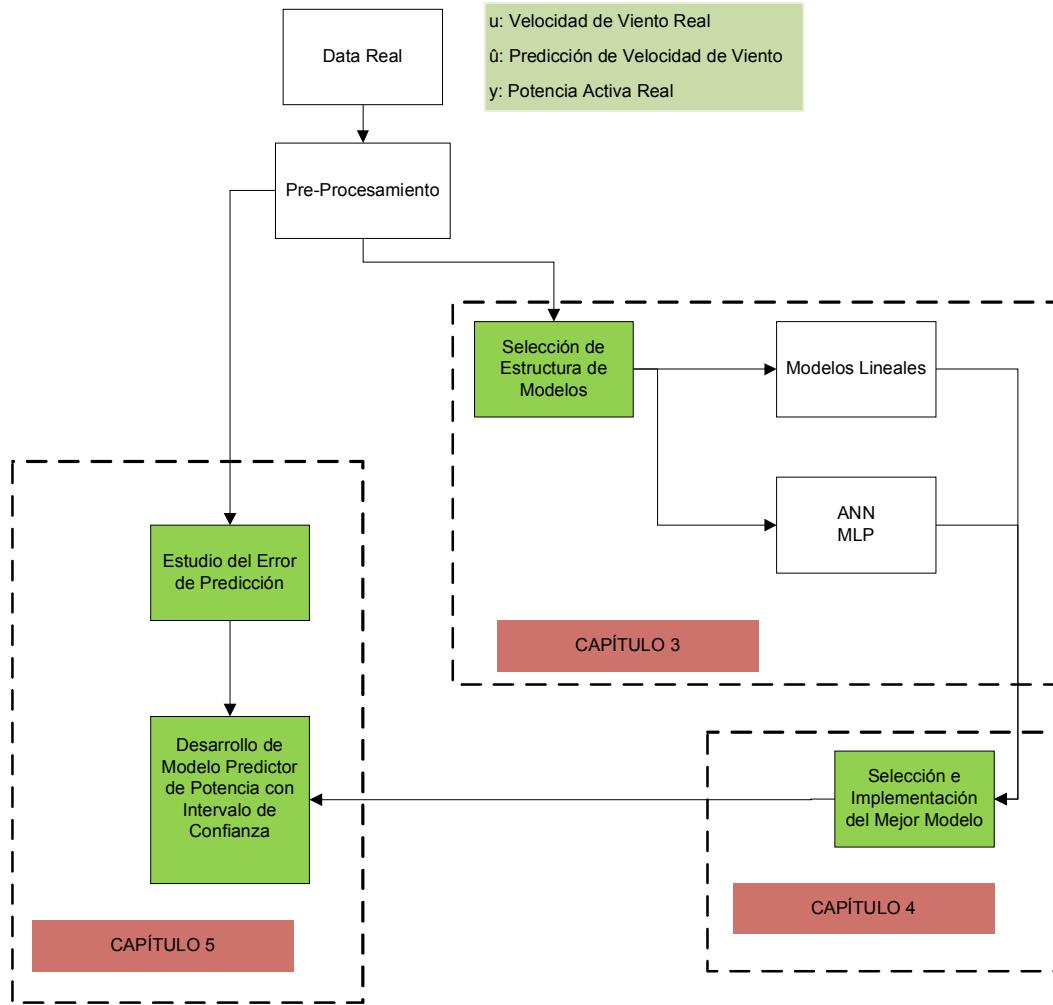


Figura 1.1: Estructura del método propuesto

El método propuesto consiste en seleccionar el mejor modelo de predicción de potencia utilizando la data real del parque eólico Canela considerando conocida la velocidad del viento en el futuro, restricción que se relajará más adelante. Luego, se ha realizado una caracterización del error de predicción de la velocidad del viento entregada por la DGAC en función del horizonte de predicción y del valor de la predicción. Como entrada del predictor se ha utilizado la predicción de velocidad de viento provista por la DGAC, la cual es perturbada con realizaciones del proceso estocástico que caracteriza el error de predicción (bloque de Estudio del Error de Predicción en Figura 1.1) ejecutándose una simulación de Monte Carlo. La salida del predictor es el valor medio de las salidas de cada iteración de la simulación. El intervalo de confianza es calculado como el menor rango de potencia que acumule el 95% de probabilidad de ocurrencia en el histograma de salida.

Se han coloreado en verde los pasos más importantes del método utilizado: la selección del mejor modelo; el estudio del error de predicción de velocidad del viento; y el desarrollo del modelo predictor de potencia con intervalo de confianza.

El método se explica en detalle en el Capítulo 5.

1.6 Estructura del Trabajo

El Capítulo 1 muestra la introducción a la memoria, presenta sus objetivos generales y específicos y se muestra la motivación y descripción del problema a resolver.

El Capítulo 2 muestra una visión general del panorama energético mundial y en especial del uso de la energía eólica en el planeta. Da una descripción del Parque Eólico Canela y de las turbinas que ahí se encuentran. Se describen los tipos de modelos que se implementan en la actualidad y sus problemas con la integración a la red eléctrica.

El Capítulo 3 es una descripción de los pasos de una identificación de sistemas. Se presentan las estructuras de modelos que se implementarán. Se definen qué criterios se utilizarán para seleccionar estructuras de modelos y cómo se estimarán los parámetros de éstos.

El Capítulo 4 comienza con una descripción del problema que se enfrenta. Se presenta un protocolo de evaluación de resultados y se implementan y discuten resultados de los modelos descritos en el Capítulo 3.

El Capítulo 5 presenta el método que se utilizará para desarrollar el modelo predictor de potencia con intervalo de confianza y se detallan todos los pasos que este método contiene. Se presentan los resultados obtenidos y se comparan con los resultados esperados de modelos de empresas que prestan el servicio de predicción de potencia para parques eólicos.

El Capítulo 6 muestra las principales conclusiones del trabajo y las líneas de investigación futuras.

Capítulo 2

2.1 Energías Renovables No Convencionales (ERNC)

En los últimos años, se ha hecho reconocida la importancia de minimizar los efectos que las emisiones de gases invernadero tienen sobre el sistema climático junto con la inminente futura escasez de recursos no renovables y los problemas de abastecimiento que hubo en nuestro país, entre otras, con lo que las energías renovables cobran mayor fuerza e importancia. Según la ley 20.257 [2], se entiende por plantas de energías renovables no convencionales a las plantas hidráulicas de potencia menor a 20 [MW] y a plantas de energía proveniente de biomasa, geotérmica, solar, de los mares y eólica, entre otras. La energía eólica es captada del viento por turbinas eólicas y transmitida en los canales usuales. En el mundo, hoy se generan más de 120 [GW] de energía eólica [3].

2.2 Energía Eólica

El ser humano ha utilizado la energía proveniente del viento desde tiempos antiguos, ejemplos de esto son la navegación a vela y los molinos para la molienda de granos. Durante largos años se ha utilizado la energía cinética del viento, transformándola en energía mecánica para usos tales como los descritos anteriormente, sin embargo, la transformación a energía eléctrica se ha desarrollado recién en el siglo recién pasado [5].

El viento es un fenómeno que se presenta en casi todo el planeta Tierra con intensidad y regularidad variable, siendo algunos lugares más aptos que otros para efectos de la instalación de un parque eólico. La generación de energía eléctrica con una turbina eólica es directamente dependiente de la velocidad del viento que sopla perpendicular al plano de giro de las aspas de la turbina; sin embargo, ésta es una variable estocástica dependiente de muchos factores tales como la presión, temperatura, densidad del aire, entre otras.

En los últimos años, la energía eólica ha tenido un aumento explosivo, principalmente en Europa y América de Norte. En la Figura 2.1, se puede observar la evolución que ha tenido la generación de energía eólica desde la década anterior en Europa y el resto del mundo.

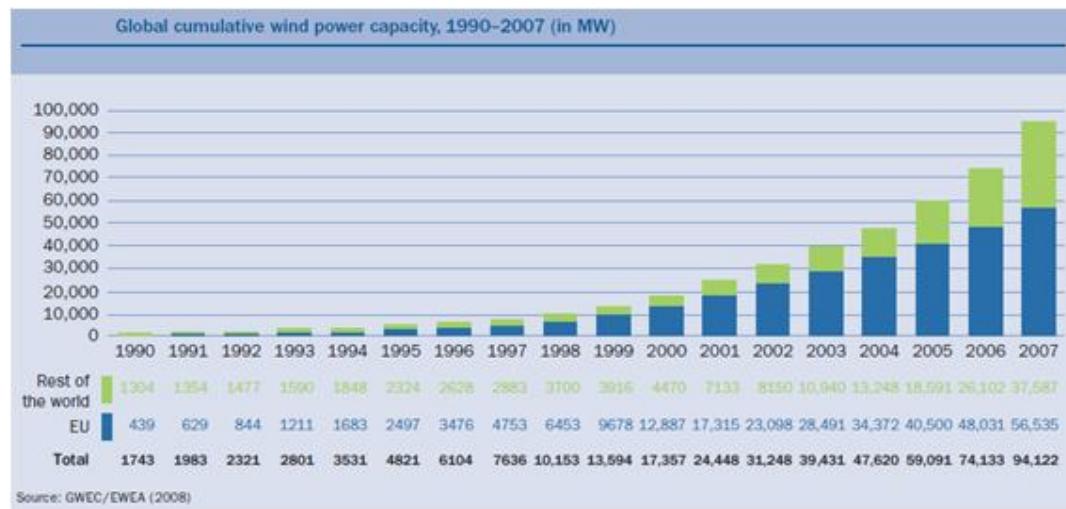


Figura 2.1: Evolución de la potencia instalada de energía eólica en Europa y el resto del mundo [3]

De la potencia eléctrica instalada en el año 2008 en Europa, la predominante fue la energía eólica, según vemos en la Figura 2.2. En esta figura, sorprende que de los 23851 [MW] instalados en Europa, más de la mitad correspondan a energías renovables no convencionales, principalmente, energía eólica y solar. Así mismo, en Estados Unidos en el año 2008 se instalaron cerca de 2400 [MW] de energía eólica [3], similar a lo instalado en toda Europa.

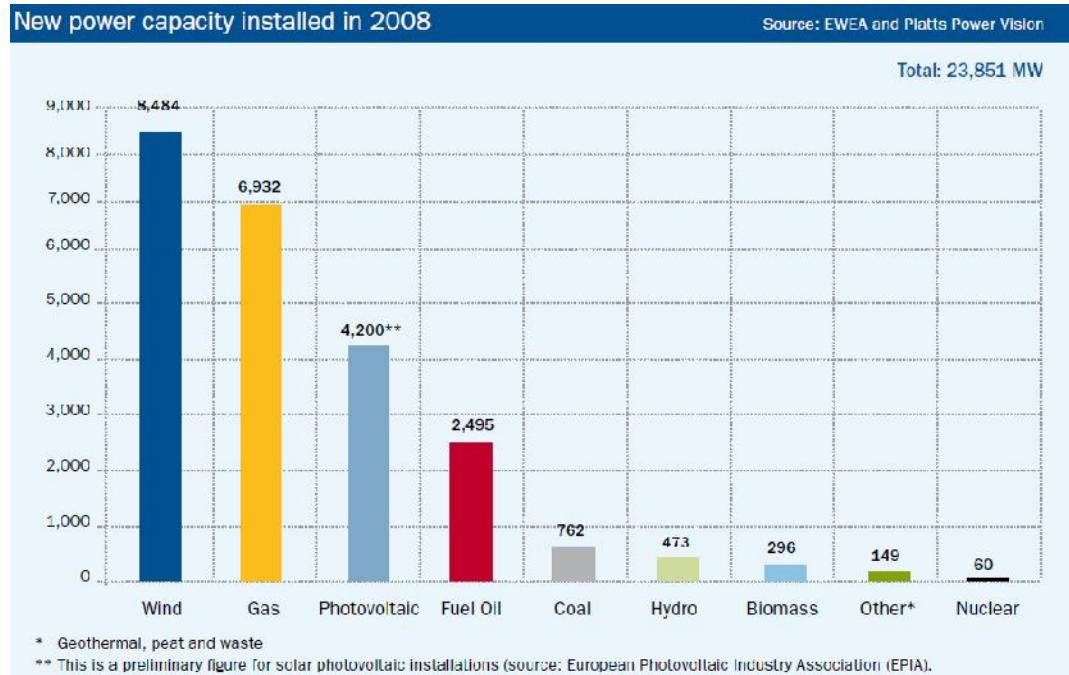


Figura 2.2: Nueva potencia instalada en el mundo según su fuente durante el año 2008 [3]

En Sudamérica, el panorama es diametralmente opuesto. A pesar de contar con enormes recursos eólicos, los niveles de generación a partir de esta fuente no son comparables con Europa y América del Norte. En la Figura 2.3, se muestra una comparación de la potencia instalada de energía eólica durante los últimos años en todos los continentes.

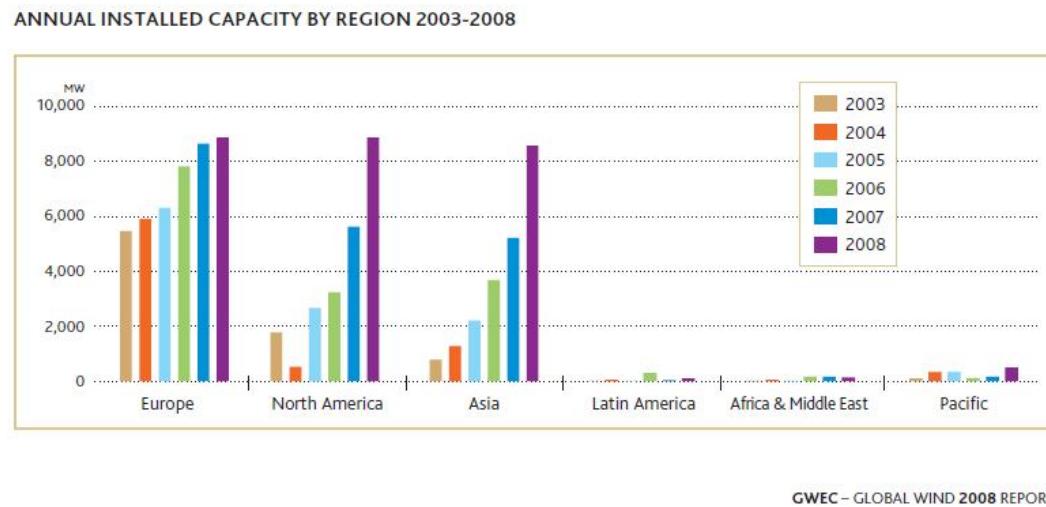


Figura 2.3: Potencia instalada de energía eólica en todos los continentes [3]

En América latina, Brasil es el país con mayor nivel de generación eólica con cerca de la mitad de la potencia instalada [3].

Según GWEC (*Global Wind Energy Council*) en su reporte anual del año 2008 [3], se espera que en los próximos cinco años Sudamérica aumente su generación de energía eólica a una tasa de 1000 [MW] por año y éste crecimiento estará dado de la mano de, principalmente, Brasil, México y Chile. Se espera que para el año 2013 haya una potencia instalada de unos 5700 [MW] de energía eólica. En la Figura 2.4, se muestra una tabla en la que se observa la distribución de energía eólica generada por los distintos países de América Latina.

GLOBAL INSTALLED WIND POWER CAPACITY (MW) – REGIONAL DISTRIBUTION

| LATIN AMERICA & CARIBBEAN | | End 2007 | New 2008 | Total end 2008 |
|---------------------------|--------------------|----------|----------|----------------|
| | Brazil | 247 | 94 | 341 |
| | Mexico | 87 | 0 | 87 |
| | Costa Rica | 70 | 0 | 70 |
| | Caribbean | 55 | 0 | 55 |
| | Argentina | 29 | 2 | 31 |
| | Other ^s | 45 | 0 | 45 |
| | Total | 533 | 95 | 629 |

^s Colombia, Chile, Cuba;
Source: GWEC

Figura 2.4: Potencia instalada de energía eólica por países en América latina [3]

En Chile, uno de los principales parques eólicos es Canela, del cual es dueño el grupo ENDESA. Las características de este parque eólico se detallan en la Sección 2.3.

2.3 Parque Eólico Canela

El parque eólico está situado en la comuna de Canela, provincia de Choapa, IV Región de Coquimbo, al norte de Los Vilos. Se ubica entre la Ruta 5 Norte y el borde costero. Esta ubicación resulta muy favorable para la instalación de un parque eólico debido a que se trata de un terreno costero con poca variabilidad de cota. En esta localización se está expuesto a vientos dominantes de sur a norte. Entró en funcionamiento en diciembre de 2007 [6].

Su objetivo principal es abastecer el aumento progresivo de la demanda del sector energético, siguiendo con la tendencia ascendente de ésta motivada fuertemente por el desarrollo económico, industrial y de la calidad de vida en el país.

Dado la naturaleza eólica del proyecto, su operación desplaza en el despacho a centrales térmicas, lo que contribuye a reducir la emisión de gases contaminantes que producen el efecto invernadero. Además, este proyecto contribuye a reducir la dependencia energética de Chile en cuanto a combustibles fósiles y otros.

La energía suministrada al SIC (Sistema Interconectado Central) es limpia y diversifica la matriz energética mediante la incorporación de energías renovables no convencionales y contribuye a preservar la seguridad del abastecimiento eléctrico.

La energía generada se conecta al SIC mediante un Tap Off a la línea de transmisión de Los Vilos – Pan de Azúcar, de 2x220 [kV]. Esta línea está ubicada a 600 [m] del parque.

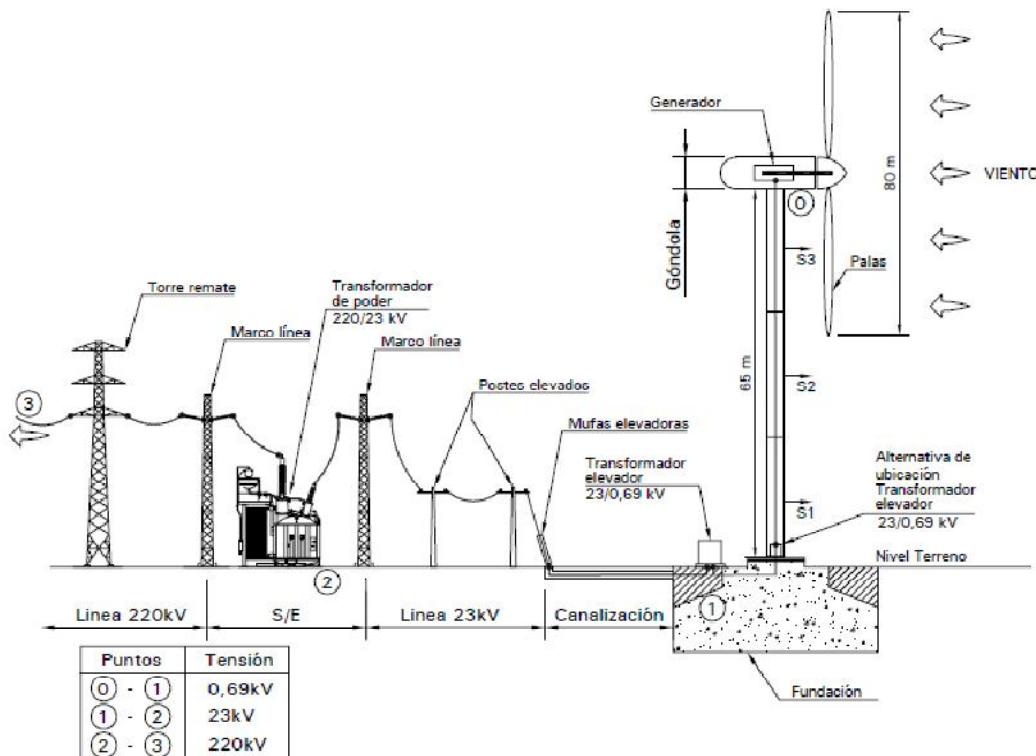
Según mediciones de viento tomadas desde 2004 hasta la fecha cada 10 minutos mediante una estación meteorológica instalada en el lugar, se tiene una velocidad promedio del viento de 6,3 [m/s] a 60 [m] de altura, lo que está dentro de los rangos usuales de viento aceptables para la generación eólica [7].

En noviembre de 2009 entró en operación el Parque Eólico Canela II, el cual aumenta la generación del parque de 18,15 a cerca de 78,15 [MW] mediante la adición de 46 nuevas turbinas. Se estima que la generación de energía media anual aumente de 47.140 a 202.974 [MWh].

Las características de las turbinas de Canela I son:

- Aerogenerador: VESTAS 82
- Potencia nominal: 1,65 [MW]
- Altura de torre: 79 [m]
- Diámetro máximo de rotor: 82 [m]
- Velocidad mínima de giro del rotor: 12 [rpm]
- Velocidad máxima de giro del rotor: 18 [rpm]
- Velocidad promedio de giro del rotor: 15 [rpm]

En la Figura 2.5, se muestra un diagrama de producción de energía del Parque Eólico Canela.



Elaboración: Ingendesa 2006.

Figura 2.5: Diagrama de producción de energía del Parque Eólico Canela [6]

2.4 Turbina Eólicas

En la actualidad se utilizan básicamente dos tipos de turbinas, las de velocidad fija y las de velocidad variable. En este capítulo sólo se tratarán las de velocidad fija puesto que corresponden a las instaladas en Parque Eólico Canela I.

Cuando las turbinas de velocidad fija se encuentran detenidas, esto es, cuando la velocidad del viento es menor a 3,5 m/s, se les debe llevar a velocidad nominal. Luego, cuando la velocidad del viento aumenta por sobre los 3,5 m/s y la turbina ha alcanzado su velocidad nominal, se conecta a la red eléctrica y posteriormente es la red la que mantiene la velocidad de la turbina constante.

La Figura 2.6 muestra un esquema en el cual está contenido la información acerca de las partes típicas de una turbina de velocidad fija [8].

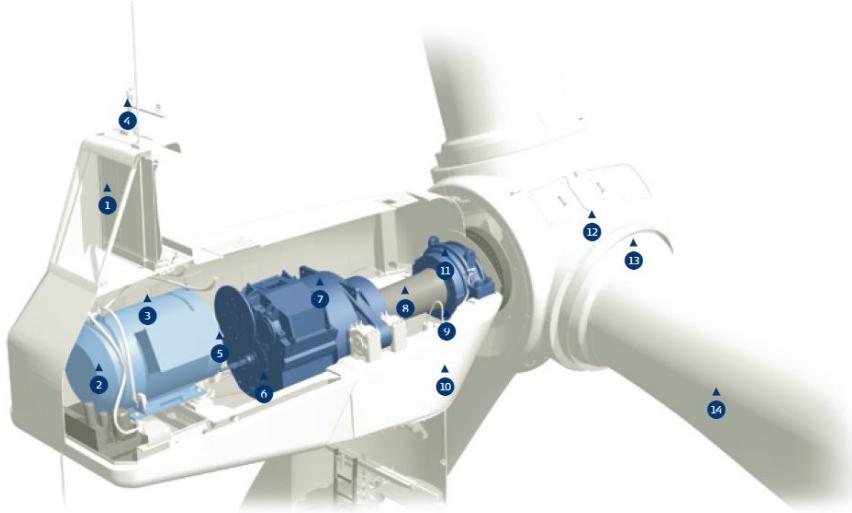


Figura 2.6: Esquema de las partes de la turbina Vestas V82, utilizadas en Canelas [8]

Las partes enumeradas son:

1. Enfriador
2. Generador
3. Controlador
4. Anemómetro
5. Acoplador
6. Freno mecánico
7. Caja de transmisión
8. Eje principal
9. Reductora de giro
10. Fundación
11. Rodamiento principal
12. Controlador de Centro de aspas
13. Sistema de ángulo de aspas
14. Aspas

La Figura 2.7 muestra la curva de velocidad de viento versus la potencia generada por una turbina. Un aspecto importante que es que esta curva es no lineal y que posee una saturación la velocidades de viento superiores a los 20 m/s. A pesar que la Figura 2.7 no lo muestra, las turbinas Vestas V82 tienen una velocidad de corte de cerca de los 25 m/s. Por sobre esa velocidad, la turbina interrumpe su generación por medidas de seguridad [8].

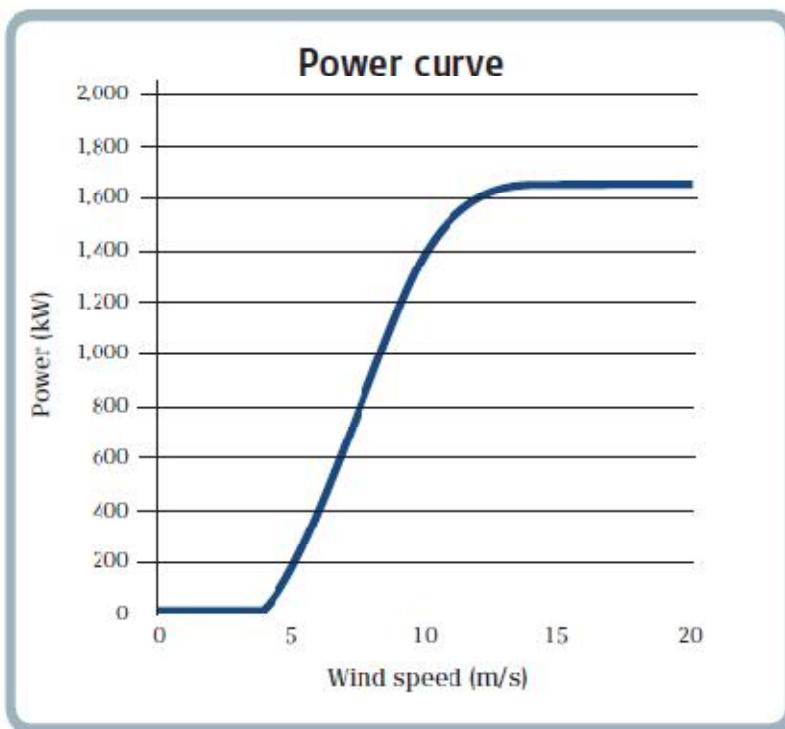


Figura 2.7: Curva de velocidad de viento – potencia de turbina Vestas V82 [8]

La potencia eléctrica extraíble del viento en una turbina está dada por (2.1):

(2.1)

$$P_{wt} = \frac{\rho}{2} A_{wt} C_p(\lambda, \theta) V^3$$

En donde P_{wt} es la potencia generada, ρ la densidad del aire, A_{wt} el área de barrido de las aspas, $C_p(\lambda, \theta)$ es el coeficiente de potencia y V la velocidad del viento.

El coeficiente de potencia tiene la forma mostrada en la Figura 2.8.

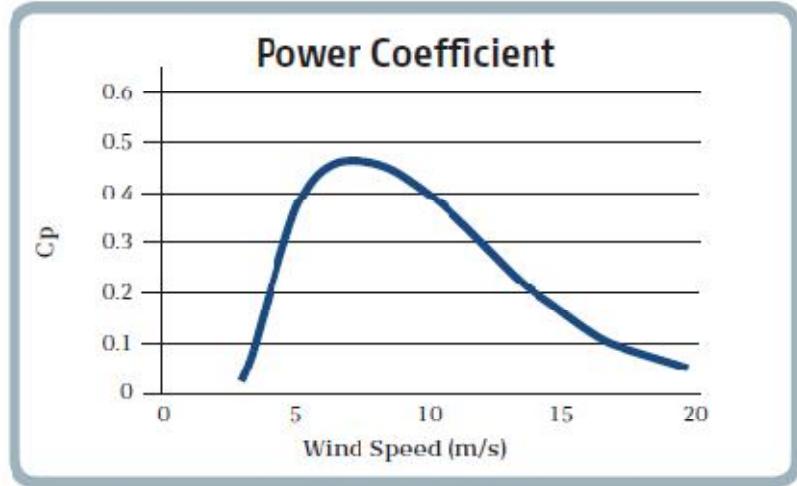


Figura 2.8: Curva velocidad de viento – Coeficiente de potencia [8]

2.5 Modelación del viento

La velocidad del viento es un proceso estocástico. Ésta varía según el día, hora y año. Hay días en que la velocidad del viento es relativamente constante y fuerte, mientras otros en que el viento puede ser suave o moderado.

La velocidad del viento depende fuertemente del lugar y altura en donde se le esté midiendo y de otras variables meteorológicas tales como la presión, humedad, temperatura y la densidad del aire. A su vez, las montañas, edificios y árboles afectan también de manera importante el perfil de velocidad del viento. Otro factor importante es el hemisferio y las coordenadas geográficas en donde se le esté midiendo.

Para realizar modelos predictivos de la velocidad del viento, se pueden utilizar dos tipos de métodos (o una mezcla de ellos), el primer método corresponde a la modelación fenomenológica, en la cual se toman en consideración todos los factores y leyes físicas que gobiernan el proceso. El segundo método corresponde a los modelos empíricos, en los cuales tras tomar medidas de distintas variables físicas, se ajusta un modelo de caja negra en donde las relaciones entre las variables no necesariamente cumplen alguna ley de la física, sino que simplemente reproducen los datos.

2.5.1 Modelación Fenomenológica Global

La modelación fenomenológica es aquella en que se toman en consideración todos los factores y leyes físicas que gobiernan el sistema (como se mencionó en la Sección 2.5) tales como la conservación de la energía y la masa.

Según Stull [9], para predecir la velocidad del viento en un lugar pequeño tal como un pueblo, se debe escoger un sistema de coordenadas tal que el eje x apunte hacia el este, el eje y hacia el norte y el eje z hacia el cielo. Utilizando las leyes de movimiento de Newton:

(2.2)

$$\frac{\partial \vec{V}}{\partial t} = \frac{\vec{F}_{neta}}{m}$$

En donde \vec{V} es la velocidad del viento, \vec{F}_{neta} la sumatoria de fuerzas que actúa sobre una parcela de aire de masa m .

Para resolver la ecuación de movimiento (en las coordenadas x-y, paralelas a la superficie de la Tierra), se debe tener en cuenta que existen, principalmente, cuatro fuerzas a considerar: la fuerza de advección (AD), la fuerza de gradiente de presión (PG), la fuerza de Coriolis (CF) y la fuerza de arrastre turbulento (TD).

La descripción de estas fuerzas se encuentran en el Anexo A.

2.5.2 Distribución Estadística de la Velocidad del Viento

En cualquier anteproyecto de un parque eólico, se instala una estación meteorológica que mide la velocidad del viento y otras variables de menor importancia, tales como la dirección del viento y la presión atmosférica. Esto es fundamental para decidir si el proyecto es viable y potencialmente rentable. Uno de los aspectos importantes que se debe observar es la distribución estadística de la velocidad del viento. La distribución de Weibull es comúnmente utilizada para representar la distribución estadística de la velocidad del viento. Esta distribución está dada por (2.3):

(2.3)

$$p(V) = \frac{k}{V} \left(\frac{V}{c}\right)^{k-1} \exp\left\{-\left(\frac{V}{c}\right)^k\right\}$$

En donde $p(V)$ es la frecuencia o probabilidad de ocurrencia de la velocidad de viento V , c es el parámetro de escala, el cual tiene dimensiones de velocidad, y k es un parámetro adimensional asociado a la forma de la distribución. Un mayor valor de c indica que la velocidad del viento es más alta; el valor de k indica la estabilidad del viento, mientras mayor es k , mayor estabilidad tiene la velocidad del viento.

La estimación de estos parámetros se hace, generalmente, mediante MLE (estimación por método de máxima verosimilitud, por sus siglas en inglés). Utilizando este método, los valores de k y c pueden ser estimados mediante las siguientes ecuaciones:

(2.4)

$$k = \left(\frac{\sum_{i=1}^n \ln(V_i)}{\sum_{i=1}^n V_i^k} - \frac{\sum_{i=1}^n \ln(V_i)}{n} \right)^{-1}$$

(2.5)

$$c = \left(\frac{1}{n} \sum_{i=1}^n V_i^k \right)^{\frac{1}{k}}$$

La Figura 2.9 muestra cómo varía la distribución de Weibull, con factor de escala $c=1$ fijo, al variar el parámetro k .

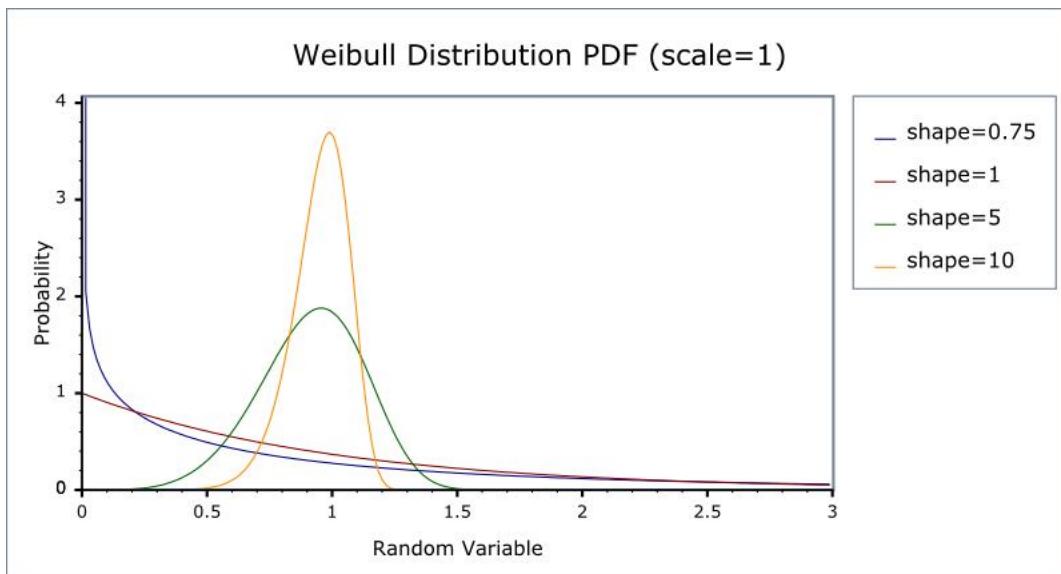


Figura 2.9: Variación de parámetro de forma k con parámetro escala constante en distribución Weibull [10]

De la Figura 2.9 se comprueba que un mayor valor de k implica una mayor estabilidad de la velocidad del viento.

La Figura 2.10 muestra cómo varía la forma de la distribución de Weibull para un factor de forma k fijo e igual a 3, al variar el parámetro de escala.

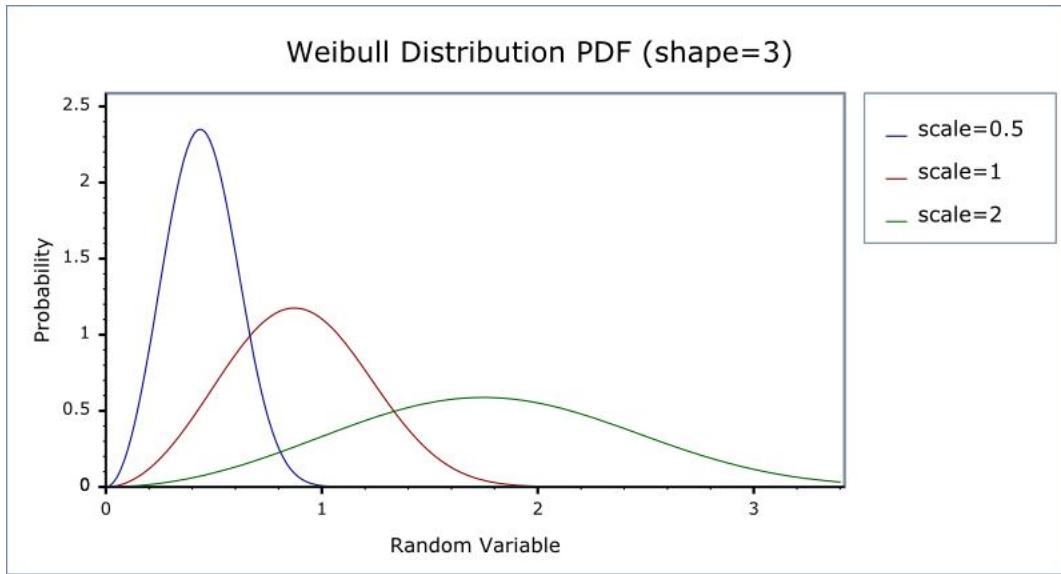


Figura 2.10: Variación de parámetro de escala con parámetro forma constante en distribución Weibull [10]

De la Figura 2.10 se comprueba que un mayor valor de c indica una velocidad media de viento más alta.

2.5.3 Clasificación de Modelos

Los tipos de modelos utilizados en la predicción de potencia se dividen en cuatro categorías: los modelos físicos, modelos estadísticos convencionales, modelos de correlación espacial y modelos basados en inteligencia artificial. Este capítulo dará una descripción de cada uno de ellos y comentará algunas publicaciones ejemplificadoras de tipo de modelo [11].

Para evaluar y ver la factibilidad de implementación de un modelo de predictivo es necesario considerar diversos aspectos. Con el fin de estandarizar el proceso de evaluación, se ha creado un resumen de las características encontradas en publicaciones que se han tomado en consideración para éste.

- *Variable de Predicción:* indica si la variable de salida del modelo de predicción es la potencia o la velocidad del viento.
- *Entradas del modelo*
- *Tipo de Modelo:* indica si el modelo es de la familia de los modelos estadísticos, físicos, de correlación o basados en inteligencia artificial. Además indica en particular el tipo de modelo estadístico (ARMA, ARX, ARIMA), de modelos físicos (MM5, HILRAM), y así sucesivamente.
- *Horizonte y Tiempo de Muestreo*
- *Criterio para Evaluar el Resultado:* indica qué índices se utilizan para evaluar el desempeño del modelo.

- *Resultados*: indica qué resultados se obtuvieron y con respecto a qué modelos o datos se compararon.
- *Conclusiones*: indica cuáles son las conclusiones de los autores.

2.5.3.1 Modelos Físicos

Los modelos físicos son los que físicas tales como la orografía del terreno, presión y temperatura para estimar predicción de la velocidad del viento. En general, este tipo de modelos se utilizan como una fuente de información parcial en un enfoque estadístico. Las predicciones de velocidad del viento mediante un modelo físico provienen de los llamados NWP (*Numerical Weather Prediction*), que son pronósticos meteorológicos de áreas de gran escala. A través de ecuaciones de conservación (momentum, masa y energía) y leyes de gases ideales, se puede hacer un refinamiento de estos pronósticos y ajustarlos al área local en donde se deseé realizar la predicción.

De manera específica, los pasos que se siguen en un modelamiento físico de la velocidad del viento son los siguientes:

1. La dirección y velocidad del viento calculadas a partir del NWP son llevadas a la altura de turbina (normalmente, los pronósticos son realizados para 10 metros sobre el nivel del mar);
2. El siguiente paso consiste en un *downscaling* estadístico, que consiste en un refinamiento de la información entregada por el NWP. Un ejemplo de aplicación de este paso es cuando el NWP entrega información meteorológica para distintos puntos alrededor de área deseada (no específicamente sobre ella);
3. Luego, se procede a convertir la velocidad y dirección del viento en potencia utilizando la curva característica de la turbina;
4. Si se desea realizar la predicción para varios parques, entonces se debe agregar las predicciones de todos ellos.

Los modelos físicos tienen un pobre desempeño en plazos muy cortos de predicción, esto es, desde segundos hasta aproximadamente 6 horas. Por lo general, son utilizados en combinación con modelos estadísticos en predicciones desde las 6 horas hasta 1 semana. Logrando un desempeño bastante aceptable hasta las 42 horas aproximadamente.

Para lograr un buen modelo físico, se consideran necesarias tres condiciones básicas:

- Un buen procedimiento que sea capaz de refinar los pronósticos entregados por los NWP;
- Buenas mediciones que sirvan de condiciones iniciales para el modelo;
- Computadores lo suficientemente potentes para manejar el gran número de ecuaciones y variables involucradas. En modelos avanzados pueden existir más de 100,000 variables y 8,000,000 de mediciones.

Landberg [12] realizó una modelación física simple para predecir la potencia de un parque. Uno de los objetivos principales de este estudio es dar una orientación sobre las simplificaciones que se le pueden hacer a los modelos meteorológicos para lograr ecuaciones simples y que logren explicar el comportamiento del viento. La entrada del modelo es una predicción del viento geostrófico, tomada

de un NWP. Luego se escala a la altura de una turbina para posteriormente proyectarla en la curva de potencia de una turbina. Resaltan la simpleza de las ecuaciones.

2.5.3.2 Modelos Estocásticos

La modelación estocástica de cualquier fenómeno que se desee estudiar, intenta buscar una relación entre un conjunto de variables explicatorias, y combinarlas de manera tal de reproducir una salida deseada, en este caso, la velocidad del viento y/o la potencia generada por la turbina en cierto horizonte de predicción.

Lo manera más común de enfrentar este problema es utilizando método recursivos. De acuerdo con los métodos propuestos por Jenkins, en la literatura se han estudiado modelos ARMA (*autoregressive moving average*), ARIMA (*autoregressive integrated moving average*) y modelos con variable exógena (X), en general mediciones de NWP. Otro método estadístico utilizado el filtro de Kalman, en donde se toma la velocidad del viento como variable de estado.

Kavasseri y Seetharaman [13] realizaron una predicción de velocidad del viento mediante el modelo ARIMA fraccionario, o f-ARIMA. El tiempo de muestreo de 1 hora y un horizonte de predicción de 24 y 48 horas. El modelo utiliza como entrada la velocidad de viento retardada y no incluye variables exógenas. El método f-ARIMA es una variante de ARIMA(p, d, q), en la cual el valor “d” asume valores continuos entre (-0,5 – 0,5). La característica de este método es un lento decaimiento en la función de autocorrelación. El método, en la predicción a 24 horas logró un error de 47%, mientras que el del método persistente fue de un 79%.

En [14] se estudia la aplicación del Filtro de Kalman en la predicción de la velocidad del viento en un horizonte de 24-120 horas con datos obtenidos de los NWP's SKIRON y RAMS. Los datos obtenidos son la predicción de los NWP's de velocidad del viento y dirección, temperatura del aire y presión a nivel del mar. Los errores de predicción están medidos en la desviación media absoluta de los datos. Se define desviación media absoluta como la promedio del error absoluto. El Filtro de Kalman presenta una desviación media absoluta de entre 1,75 y 2 [m/s] en un horizonte de predicción de 24 a 72 horas respectivamente.

2.5.3.3 Modelos de Correlación Espacial

Los modelos de correlación espacial son modelos que toman en cuenta las relaciones existentes entre la velocidad del viento de distintos sitios con un lugar en particular en donde se desea estimarla. La velocidad del viento en los sitios en donde se realiza la predicción y de sus localidades vecinas son empleadas para hacer la predicción de velocidad del viento [11]. Últimamente se han realizado varias investigaciones en esta materia. En la Figura 2.11, se muestra el perfil de velocidad para tres sitios que están correlacionados considerando las zonas por donde fluye el viento comúnmente. Se puede observar claramente que hay una correlación entre el sitio 3 y el 1 y 2. Mediante la función de correlación cruzada se puede calcular la fase entre las mediciones.

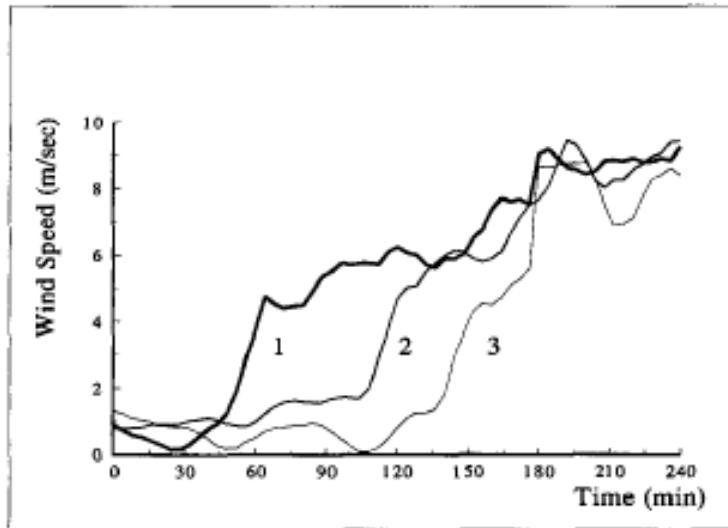


Figura 2.11: Perfil de velocidades de viento para sitios correlacionados [15]

Öztopal [15] estudió un método para estimar la velocidad del viento en una región basado en mediciones de ésta en lugares vecinos y procesó esta información con el uso de redes neuronales. Las redes son del tipo MLP (*Multi Layer Perceptron*) con variables de entrada las mediciones de velocidad de viento en sitios vecinos y con variable de salida la velocidad del viento en el sitio estudiado. Se comparó la salida del modelo con mediciones reales en el sitio de estudio usando como índice de desempeño la correlación R, con valores entre 0,83 y 0,97 dependiendo de lugar en donde se realice la estimación y el mes del año.

2.5.3.4 Modelos Basados en Inteligencia Artificial

Durante las últimas décadas se han desarrollado numerosas aplicaciones de predicción de series de tiempo que utilizan redes neuronales artificiales, lógica difusa, máquinas de soporte vectorial y modelos híbridos.

Las redes neuronales son sido el tipo de modelo más utilizado para la predicción de viento y/o potencia los últimos años [11]. Éstas tienen la capacidad de aprender comportamientos no-lineales complejos tales como los que se dan en la capa límite de nuestra atmósfera.

Gong Li [16] comparó tres distintos modelos basados en redes neuronales para la predicción de la velocidad del viento. La diferencia central entre estos modelos es la topología de las redes neuronales utilizadas; en el primer caso, se utiliza tangente sigmoidal como función de activación en la capa oculta y una función lineal en la capa de salida. En la segunda red, como función de activación se usan RBF (*Radial Basis Function*) y capa de salida función lineal. El tercer modelo es una red ADALINE (*Adaptive Linear Element*). Las entradas del sistema son retardos de la velocidad del viento en todos los casos y fueron elegidas a través de un análisis de autocorrelación. Los tres modelos trabajan con un tiempo de muestreo de 1 hora para predecir la velocidad del viento en un horizonte

de una 1 hora. La métrica del desempeño de las redes es el MSE entre la predicción y el valor real. Datos de dos sitios fueron probados, logrando mejores resultados en uno con la que utiliza tangente sigmoidal en su capa oculta; mientras que en el otro sitio logró un mejor desempeño la red RBF. Una conclusión de esto es que deben utilizar distintos tipos de redes para una aplicación real, ya que no necesariamente que un modelo haya funcionado en un lugar implica necesariamente que sea la mejor opción en otro sitio.

Ramírez – Rozado [17] compararon dos métodos de predicción de la potencia utilizando un modelo basado en redes neuronales. El tiempo de muestreo es de 0.5 horas y el horizonte de predicción es de hasta 72 horas. Ambos modelos tienen como entrada pronósticos de NWP (velocidad y dirección del viento) y mediciones en línea de potencia. En el sistema FORECAS se ajustó una red neuronal para emular la curva de potencia de cada turbina presente en el parque en base a pronósticos de NWP, esta es una de las entradas del sistema que es, a su vez, otra red neuronal. Además el modelo general incorpora como entrada un modelo la predicción de potencia de un modelo AR, que tiene como entrada la potencia medida en línea. El sistema SGP está compuesto por un selector de submodelos, cada uno de ellos está hecho en base a redes neuronales aunque con distintas configuraciones, redes de Elman, MLP, FFBP (*Feed Forward BackPropagation*). Cada uno de estos submodelos está enfocado en un horizonte de tiempo en particular. Ambos modelos se desempeñaron de forma similar, con una leve mejoría del sistema SGP. Los modelos tuvieron un error de 14% en una predicción a 24 horas y cerca de 17% a 48. Esto es cerca de la mitad del error que se obtuvo mediante la predicción persistente: 31,2% a 24 horas y 35,5% a 48 horas.

En el estudio realizado por Mabel y Fernández [18] se analiza el uso de redes neuronales para la predicción mensual de un conjunto de parques en India, se utiliza una red neuronal con tres entradas, la velocidad del viento, la densidad del aire y el número de horas de generación. El horizonte de predicción es de un mes y los errores son menores al 4% (utilizando MSE).

La tabla 2.1 muestra un resumen con las características de cada método.

Tabla 2.1: Resumen con características de los tipos de modelos

| Tipo de Modelo | Descripción | Ejemplos |
|--|--|--|
| Modelo Físico | Utilizan variables físicas tales como la orografía del terreno, presión y temperatura. Se modela la velocidad del viento mediante ecuaciones de conservación y leyes de gases ideales. Generalmente, se utilizan como fuente de información parcial en un enfoque estocástico. | |
| Modelo Estocástico | La modelación se hace a través de métodos recursivos. Generalmente, no se considera la fenomenología del sistema. | ARX, ARMA, ARIMA, ARMAX, ARIMAX |
| Modelo de Correlación Espacial | Este método utiliza mediciones de velocidad de viento en lugares distintos al de estudio para estimar la velocidad del viento en el sitio requerido. Esta información es procesada mediante diversas formas, por ejemplo, con redes neuronales. | |
| Modelo Basados en Inteligencia Artificial | Son modelos no lineales que tienen la capacidad de aprender comportamientos complejos. Son muy útiles cuando no se cuenta con una modelación fenomenológica del sistema en estudio. | Redes Neuronales MLP, RBF, Modelos Difusos, Máquinas de Soporte Vectorial y Modelos Híbridos |

2.6 Productos Comerciales

La predicción de corto plazo de la potencia generada a través del viento ha generado interés en el mercado eléctrico desde sus inicios, lo que se ve reflejado en el gran número de centros de investigación y compañías que se hanocado al desarrollo de modelos para tal efecto.

En general, los software comerciales se especializan en predecir potencia en un horizonte que va desde las 6 horas hasta las 42 horas, en línea con las necesidades del rubro. Más allá de este horizonte los errores de predicción son muy elevados.

En el caso de España y el resto de los países europeos que cuentan con energía eólica, los software predicen el nivel de generación de energía eólica para un grupo de parques con ubicación distribuida. Se ha demostrado empíricamente que se obtienen mejores resultados al hacer la predicción de potencia de un grupo de parques (predicción agregada) que a un parque específico [19].

Los modelos predictores en línea aprenden con el tiempo, es decir, mejoran sus predicciones a medida que van retroalimentando información.

La Figura 2.12 muestra como ejemplo la arquitectura del software ALEASOFT.

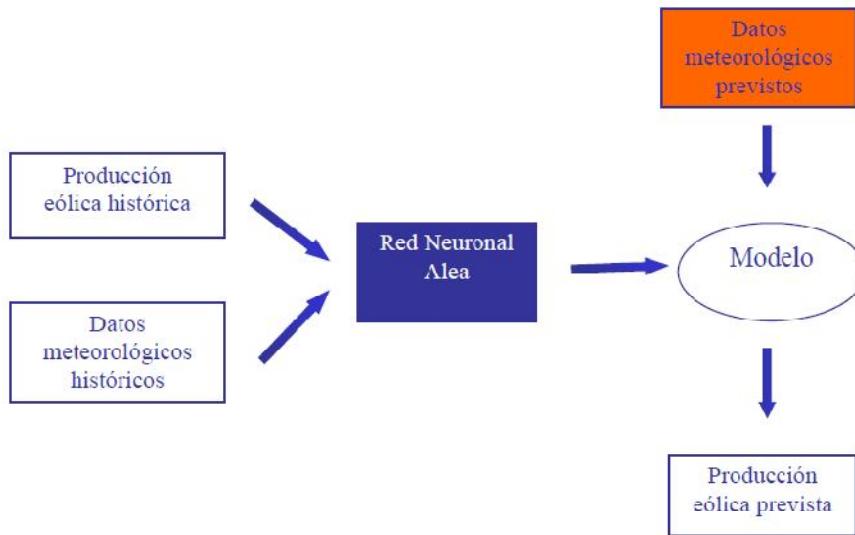


Figura 2.12: Arquitectura Software ALEASOFT [19]

El software ALEASOFT utiliza datos meteorológicos y de producción histórica en una red neuronal que entrega velocidades de viento que han ocurrido con condiciones meteorológicas parecidas.

Las predicciones de velocidad de viento suelen fallar cuando [19]:

- Durante cambios bruscos en las condiciones del tiempo
- Cuando hay fuertes viento (tormenta) y las turbinas deben detenerse
- Cuando hay cambios bruscos locales (puede ser una tormenta eléctrica)
- Cuando hay problemas de mediciones en estación de monitoreo
- Cuando mediciones meteorológicas globales están atrasadas o no están
- Cuando los pronósticos están desfasados

2.7 Integración de la Energía Eólica

La integración de grandes cantidades de energía eólica es, generalmente, un problema en la red. Los efectos que tiene la integración de la energía eólica pueden ser clasificados según la escala temporal que se esté estudiando. Además de la escala temporal es importante el nivel de penetración de la energía eólica en el sistema; el tamaño del sistema; y la composición de la matriz energética. A continuación, se muestran los principales efectos de corto plazo que tiene la energía eólica sobre el voltaje en el sistema.

Variaciones de Frecuencia: son causadas por desbalances en la potencia activa entre la demanda y la generación. En el caso de una baja en el valor de la frecuencia, se pueden producir altas corrientes de excitación en transformadores y máquinas de inducción; variación del flujo magnético y dañar entrehierros y sobrecalentamientos. Para frecuencias altas, se pueden producir aceleraciones en máquinas sincrónicas; desaceleraciones en máquinas de inducción; y torsiones electromecánicas.

Armónicas: son generadas en por la saturación del núcleo de hierro en las máquinas sincrónicas y por los rectificadores e inversores y, dependiendo si son de voltaje o corriente, son capaces de producir sobre tensiones que dañan las aislaciones de los equipos en el primer caso y sobre corrientes que pueden quemar equipos y hacer operar innecesariamente protecciones. Un generador eólico puede producir armónicas ya que muchas tecnologías de generación utilizan conversores e inversores.

Variaciones de Tensión: se produce efecto flicker debido a la gran variabilidad del viento, lo que implica una gran variabilidad de generación de potencia activa; otro factor que crea efecto flicker es la puesta en marcha y desconexión de las turbinas. El efecto flicker puede provocar altas corrientes de partida en motores.

La Tabla 2.2 muestra un resumen de los efectos que tiene la integración de la energía eólica para distintas escalas temporales [20].

Tabla 2.2: Efectos Integración Energía Eólica

| | Efecto o Elemento Impactado | Área | Escala Temporal | Contribución de la Energía Eólica |
|-------------------------------|---|-----------------|-------------------------|---|
| Efectos de Corto Plazo | Manejo del Voltaje | Local/Regional | Segundos/Minutos | Parques Eólicos pueden proveer Soporte Dinámico en el Voltaje (depende del diseño) |
| | Eficiencia de Producción en Hidroeléctricas y Termoeléctricas | Sistema | 1-24 horas | Los impactos dependen de cómo el sistema esté operado y cómo se usen los pronósticos de corto plazo |
| | Eficiencia en Distribución y Transmisión | Sistema o local | 1-24 horas | Dependiendo del nivel de penetración, los parques eólicos pueden generar costos adicionales ó beneficios. Parques distribuidos reducen pérdidas en el sistema |
| | Regulación de Reservas | Sistema | Algunos Minutos a Horas | La energía eólica puede contribuir parcialmente al control primario y secundario de reservas |
| | Energía Eólica Descartada | Sistema | Horas | La energía eólica puede exceder la cantidad de energía que el sistema puede absorber cuando la penetración es alta |
| Efectos de Largo Plazo | Fidelidad del Sistema | Sistema | Años | La energía eólica puede contribuir a la adecuación del sistema de potencia |

Capítulo 3

3.1 Introducción

Este capítulo muestra los pasos fundamentales de la identificación de sistemas. Además, se presentan los modelos que se implementarán en el próximo capítulo y se establece la notación a utilizar para describir los modelos.

3.2 Identificación de Sistemas

La identificación de sistemas es la disciplina que busca describir matemáticamente un modelo de un sistema dinámico a partir de una serie de mediciones de un sistema [21].

El desarrollo de un modelo tiene diversas aplicaciones entre las que se pueden mencionar el control de sistemas, detección de fallas y la que motiva este trabajo, la predicción. Un modelo con un buen desempeño debe lograr, principalmente, dos cosas: capacidad de explicar; y capacidad de predecir.

Según el grado de conocimiento que se tenga del sistema dinámico que se modela, la modelación se divide en dos tipos: modelación de caja blanca o fenomenológica, en la cual se tiene conocimiento de las ecuaciones que rigen el comportamiento del sistema; y modelación de caja negra o empírica, en donde no se usa ninguna información sobre la física del sistema y se dispone de data experimental. Se agrega además un tercer tipo de modelo llamado de caja gris, en donde la información fenomenológica que se tiene del sistema es parcial.

En este capítulo se tratará la modelación de caja negra considerando el siguiente procedimiento [22]:

- Obtención y procesamiento de datos
- Selección de la estructura del modelo
- Estimación de los parámetros del modelo
- Validación del modelo

3.2.1 Obtención de Datos

La obtención de datos para una identificación de un sistema dinámico consiste en el desarrollo de un experimento que colecte información del comportamiento del sistema en todo su rango de operación. Se debe variar y registrar la entrada del sistema y a la vez registrar el impacto que estos cambios producen sobre la salida del sistema. Las etapas más importantes de la recolección de datos son: la determinación del tiempo de muestreo; el diseño y selección de la entrada; y el pre procesamiento de los datos.

3.2.2 Estructuras de Modelos

La selección de la estructura de un modelo es la fase más importante del proceso de identificación de un sistema dinámico. Existen dos grandes categorías de modelos de caja negra, los modelos lineales y los no-lineales, siendo los últimos de mayor complejidad que los primeros.

Es normal comenzar la modelación de un sistema utilizando modelos lineales y, una vez determinado que el modelo no es suficiente, se pasa a una modelación no-lineal, en donde se pueden encontrar variados métodos.

Considérese la notación de las variables entrada y salida y las perturbaciones mostrada en la Figura 3.1.

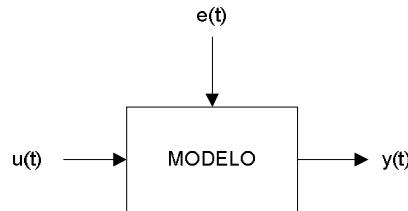


Figura 3.1: notación de variables de entrada, salida y perturbaciones

En donde $u(t)$ es la o las variable de entradas del modelo, $y(t)$ es la variable de salida y $e(t)$ es el conjunto de perturbaciones no medidas, asumidas como ruido blanco de media cero y varianza λ .

En esta sección se describirán las estructuras lineales y no-lineales que se implementarán en este trabajo. Dentro de los modelos lineales, se verán las estructuras AR, FIR y ARX.

No se implementarán estructuras que incorporan como entrada el error tales como ARMAX y ARIMAX, ya que el objetivo es utilizar los modelos para una predicción del tipo sensor virtual, en donde no se conocen las salidas posteriores del sistema y por lo tanto no se conoce el error del modelo en el futuro. Dentro de los modelos no lineales, sólo se estudiará la red neuronal MLP.

3.2.2.1 Modelo AR

Los modelos de estructura lineal polinomial se pueden representar por:

(3.1)

$$A(q)y(t) = \sum_{i=1}^{nu} \frac{B_i(q)}{F_i(q)} u_i(t) + \frac{C(q)}{D(q)} e(t)$$

En donde los polinomios A, B_i, C, D y F_i contienen el operador de retardo q , u_i es la entrada i , nu es el número total de entradas. Se asume que el error $e(t)$ es ruido blanco de media cero y varianza λ [23].

Los modelos lineales presentados se han desarrollado considerando sólo una entrada, la velocidad del viento $v(t)$. Con esto, se puede asumir que los polinomios $B_i = B, F_i = F$ y el número de entradas $nu = 1$.

El operador de retardo q cumple:

(3.2)

$$q^{-1}u(t) = u(t - 1)$$

El modelo AR es el caso particular en que $A \neq 0, B = C = 0$ y $D = F = 1$, por lo que el sistema queda descrito por (3.3):

(3.3)

$$A(q)y(t) = e(t)$$

Expandiendo el polinomio, queda:

(3.4)

$$y(t) = -a_1y(t - 1) - \dots - a_{na}y(t - na) + e(t)$$

El modelo AR es el más simple dentro de las estructuras lineales y en este caso se utilizará como parte del modelo de referencia de Nielsen [24].

El polinomio A del modelo persistente es:

(3.5)

$$A(q) = 1 - q^{-1}$$

Reemplazando en 3.3, el modelo queda descrito por (3.6):

(3.6)

$$y(t) = y(t - 1) + e(t)$$

3.2.2.2 Modelo FIR

El modelo FIR (*Finite Impulse Response*) considera que la salida del sistema puede ser representada por una combinación lineal de la entrada y sus retardos. No toma en consideración la salida del sistema retardada.

El modelo FIR considera que el sistema se puede describir, en formato polinomial, por (3.7):

(3.7)

$$y(t) = B(q)u(t - nk) + e(t)$$

El polinomio B mostrado en (3.7) tiene la forma:

(3.8)

$$B(q) = b_1 + b_2q^{-1} + \dots + b_{nb}q^{-nb+1}$$

Expandiendo el polinomio $B(q)$ de (3.7):

(3.9)

$$y(t) = b_1u(t - nk) + \dots + b_{nb}u(t - nk - nb + 1) + e(t)$$

Es conveniente introducir el formato theta de manera de aislar el vector de parámetros que se deben estimar. El formato theta del modelo es:

(3.10)

$$y = \varphi^T \theta + e$$

En donde φ^T es el vector de regresores y θ es el vector de parámetros.

El vector de regresores es, en este caso:

(3.11)

$$\varphi^T = [u(t - nk) \dots u(t - nk - nb + 1)]$$

El vector de parámetros que se debe estimar es el mostrado en (3.12):

(3.12)

$$\theta = [b_1 \dots b_{nb}]^T$$

De forma gráfica, el modelo es el mostrado en la Figura 3.2:

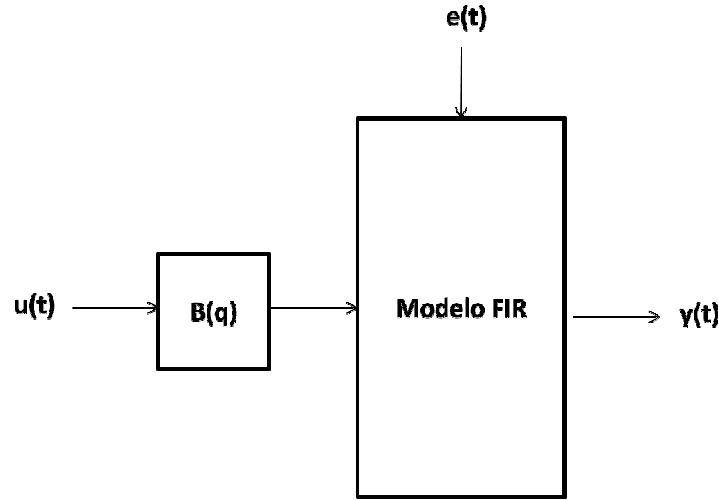


Figura 3.2: Estructura de Modelo FIR

3.2.2.3 Modelo ARX

El modelo ARX incorpora una entrada exógena en el sistema, además de la parte autoregresiva. El modelo ARX considera que el sistema se puede describir, en formato polinomial, por:

(3.13)

$$A(q)y(t) = B(q)u(t - nk) + e(t)$$

El polinomio B mostrado en (3.13) es:

(3.14)

$$B(q) = b_1 + b_2q^{-1} + \dots + b_{nb}q^{-nb+1}$$

Expandiendo el polinomio $B(q)$ de (3.13):

(3.15)

$$y(t) + a_1y(t - 1) + \dots + a_{na}y(t - na) = b_1u(t - nk) + \dots + b_{nb}u(t - nk - nb + 1) + e(t)$$

El vector de regresores del sistema ϕ^T es:

(3.16)

$$\phi^T = [-y(t-1) \dots -y(t-na) \ u(t-nk) \dots u(t-nk-nb+1)]$$

El vector de parámetros θ , es:

(3.17)

$$\theta = [a_1 \ a_2 \dots a_{na} \ b_1 \dots b_{nb}]^T$$

Los pasos para determinar un modelo ARX son: primero, la determinación del número de retardos de la salida, el retardo inicial de la entrada y el número de parámetros de la entrada, na , nk y nb ; el segundo paso es la estimación de los parámetros.

De forma gráfica, el modelo es el mostrado en la Figura 3.3:

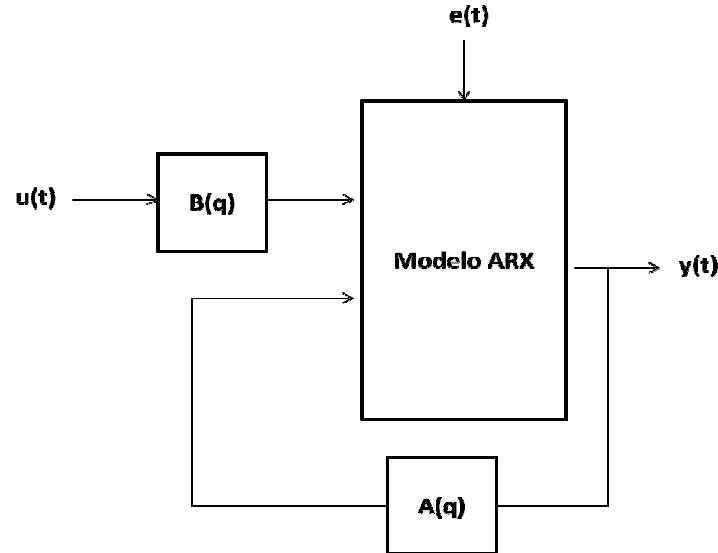


Figura 3.3: Estructura modelo ARX

3.2.2.4 Modelo Red Neuronal MLP

Una red neuronal es un procesador masivamente paralelo y distribuido compuesto por unidades procesadoras elementales (neuronas). Ésta tiene una tendencia natural a almacenar conocimiento experimental y a dejarlo disponible para su uso [25].

La red neuronal MLP (*Multi Layer Perceptron*) es un tipo de modelo no-lineal. Las entrada del modelo pueden ser variables exógenas o auto regresivas.

Las redes neuronales se asemejan al cerebro humano en dos aspectos:

- Adquiere conocimiento de su medio ambiente a través de un proceso de aprendizaje
- Las interconexiones entre neuronas, conocidas como pesos sinápticos, se utilizan para almacenar el conocimiento adquirido

Es posible modificar la topología de la red, esto es, número de neuronas y sus interconexiones. La red neuronal aprende a partir de ejemplos, construyendo un mapa de entrada – salida.

El modelo de una neurona se observa en la Figura 3.4.

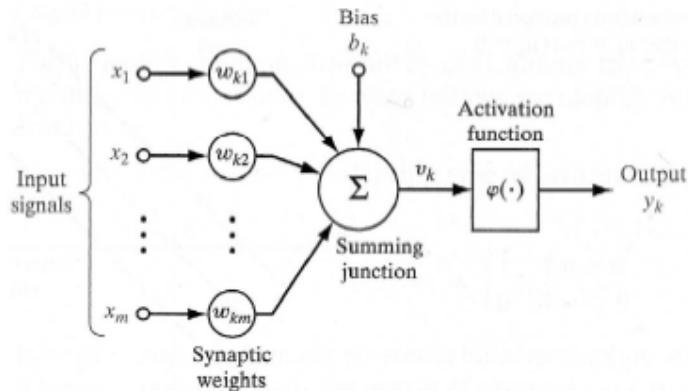


Figura 3.4: Modelo de una neurona [25]

En donde:

- Señales de entrada x_j
- Pesos sinápticos w_{kj}
- Sumador o combinador lineal $u_k = \sum_{j=1}^m w_{kj}x_j$
- Función de activación $y_k = \varphi(u_k + b_k)$, en donde b_k es una constante (*bias*)

Una red neuronal se compone de varias neuronas, como muestra la Figura 3.5.

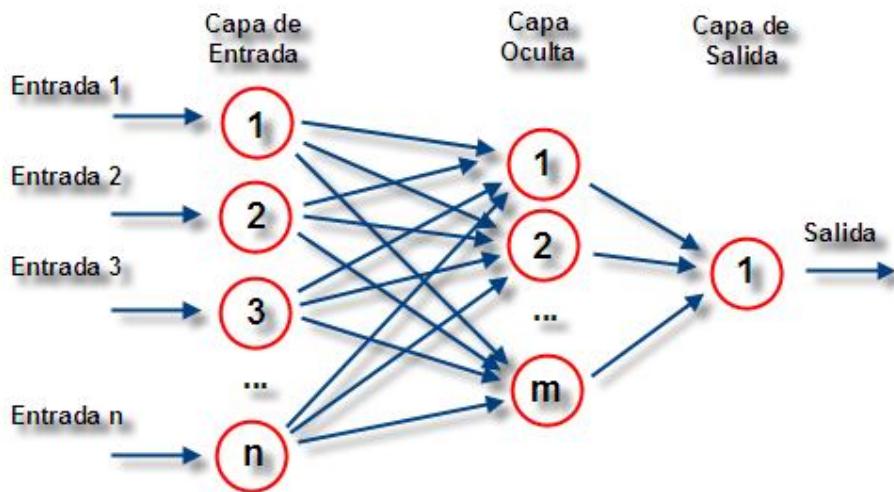


Figura 3.5 [26]: Red neuronal MLP de múltiples entradas y una salida

La salida del modelo de red neuronal MLP está descrito por (3.18), en donde el vector de pesos está representado por θ , la función $g(\cdot)$ es una función no-lineal que representa la relación entrada – salida en su totalidad:

(3.18)

$$y(t) = g[\varphi(t), \theta] + e(t)$$

El vector de regresores φ es:

(3.19)

$$\varphi^T(t) = [y(t-1) \dots y(t-na), u(t-nk) \dots u(t-nk-nb+1)]$$

El vector de parámetros θ corresponde a los pesos de la red neuronal y depende de la arquitectura de ésta, lo que considera el número de neuronas y número de capas. Para mayor información sobre la arquitectura de las redes neuronales ver [25].

3.2.3 Criterios de Selección de Estructura

La determinación de la estructura de un modelo consiste en la minimización de algún criterio de comparación entre el modelo determinado y el sistema real. Se debe hacer con respecto a al vector de parámetros y a los parámetros que determinan la estructura (na , nb y nk) [27].

No se recomienda sobre-parametrizar los modelos. En un caso extremo, si el conjunto de parámetros del modelo es igual al número de datos, es posible ajustar un modelo con error de predicción igual a cero, sin embargo, al probar el modelo con un set de datos distinto, el error de modelación puede ser muy grande.

Existen varios criterios cuantitativos de comparación de modelos, entre ellos se pueden mencionar FPE (*Final PredictionError*) de Akaike y AIC (*Akaike's Information Criterion*).

3.2.3.1 Criterio de FPE (*Final Prediction Error*) de Akaike

Este método consiste en minimizar el índice mostrado en (3.20) [27]. De acuerdo a la teoría de Akaike, el modelo que presente un menor FPE es el más certero. Este método se puede utilizar tanto para modelos lineales como no-lineales.

(3.20)

$$FPE = \frac{1 + \frac{m}{N}}{1 - \frac{m}{N}} V$$

En donde m es el número de parámetros del sistema; N es el número de datos; y V es el error cuadrático medio entre el modelo y el sistema real. Notar que cuando m tiende a N , éste índice tiende a infinito.

3.2.3.2 Criterio de AIC (*Akaike's Information Criterion*)

Este método consiste en minimizar el índice de (3.21). De acuerdo a la teoría de Akaike, el modelo que presente un menor AIC es el más certero. Este método se puede utilizar tanto para modelos lineales como no-lineales.

(3.21)

$$AIC = \log(V) + \frac{2m}{N}$$

3.2.4 Estimación de Parámetros

La estimación de parámetros corresponde a seleccionar el vector de parámetros θ que optimice algún funcional en particular. En este trabajo se utilizará el método LSE (*Least Square Error*) para calcular parámetros constantes. LSE minimiza la suma de los errores al cuadrado entre la respuesta real de un sistema y su predicción ajustando los parámetros del modelo. Este método se utilizará para los modelos lineales y la red neuronal (se utiliza como función objetivo en el método de Levenberg-Marquardt, ver Anexo C).

Sea el error de predicción:

(3.22)

$$e(t, \theta) = y(t) - \hat{y}(t)$$

Donde $\hat{y}(t)$ es la predicción. El método LSE consiste en minimizar la función:

(3.23)

$$V_N(\theta) = \frac{1}{N} \sum_{t=1}^N [e(t, \theta)]^2$$

El vector de parámetros óptimos θ^* será:

(3.24)

$$\theta^* = \operatorname{argmin}(V_N(\theta))$$

En el Capítulo 4 se implementarán los modelos vistos en este capítulo y se utilizarán los métodos presentados para seleccionar estructura y escoger los parámetros de los modelos.

Capítulo 4

4.1 Planteamiento del Problema

Incrementar el valor de la generación eólica a través del mejoramiento de los sistemas de predicción de potencia es una de las prioridades en los próximos años. Las herramientas de predicción mejoran la posición de la energía eólica con respecto a otras formas de generación.

Varios centros de investigación y compañías han acogido la creciente demanda de sistemas de predicción de potencia que nace del aumento en la capacidad instalada en parques eólicos.

En el Parque Eólico Canela no se cuenta aún con un sistema predictor de potencia. En el futuro este parque deberá contar con sistema de este tipo como exigencia de parte del CDEC; organismo encargado de la coordinación de la operación de las instalaciones eléctricas de los concesionarios que operen interconectados entre sí; con el objetivo de realizar una planificación de corto plazo del sistema eléctrico de mayor precisión.

El problema que se plantea en este trabajo es el desarrollo de un predictor de potencia para este parque en un rango estimado en donde existe una probabilidad pre asignada del valor de la salida del predictor, en adelante intervalo de confianza, de las predicciones entregadas por el modelo.

4.2 Protocolo de Evaluación de Modelos de Predicción de Potencia

A raíz de la gran cantidad de modelos existentes, surge la necesidad de estandarizar la evaluación del rendimiento de éstos para ser capaz de distinguir las ventajas y desventajas que cada modelo tiene para el uso que se le deseé dar.

La Unión Europea actualmente desarrolla el proyecto ANEMOS (*Development of A NExt generation wind resource forecasting systeM for large-scale integration of Onshore and offshore wind farms*) que tiene por objetivo desarrollar modelos de predicción de potencia que mejoren continuamente el estado del arte. El proyecto ANEMOS, tomando la necesidad de los parques eólicos de evaluar el servicio de predicción de potencia que reciben, ha desarrollado un protocolo estandarizado para la evaluación de modelos de predicción de potencia de corto plazo.

Este protocolo define la notación que se debe utilizar en la presentación de resultados, los modelos de referencia con los cuales se deben comparar los resultados, las unidades de medidas de error que se deben presentar y recomendaciones generales para las empresas e investigadores que desarrollen modelos de predicción de potencia.

En los subcapítulos siguientes se detallarán los puntos más importantes de este protocolo [24] para utilizarlos en la evaluación de los modelos que se han desarrollado.

4.2.1 Notación

El protocolo establece la siguiente notación:

| | |
|----------------------------|---|
| P_{inst} | : Capacidad instalada en el parque |
| $k = 1, 2, \dots, k_{max}$ | : Horizonte de predicción (número de pasos de tiempo) |
| k_{max} | : Horizonte máximo de predicción |
| N | : Número de datos utilizados en la evaluación del modelo |
| p | : Número de parámetros del modelo |
| $v(t)$ | : Velocidad del Viento |
| $\hat{v}(t + k t^*)$ | : Predicción de la Velocidad del Viento provista por DGAC, en instante $t^* \leq t$ |
| $P(t + k)$ | : Potencia medida en el tiempo $t + k$ |
| $\hat{P}(t + k t)$ | : Predicción de potencia para el instante $t + k$ realizada en el instante t |
| $e(t + k t)$ | : Error correspondiente al instante $t + k$ para la predicción realizada en el instante t |
| $\epsilon(t + k t)$ | : Error normalizado con la capacidad instalada |

4.2.2 Definición de Errores de Predicción

El error de predicción para una serie de tiempo está definido como la diferencia entre el valor real medido y la predicción. Esto se puede extender para cada paso de predicción k .

Error de Predicción:

(4.1)

$$e(t + k|t) = P(t + k) - \hat{P}(t + k|t)$$

Error de Predicción Normalizado:

(4.2)

$$\epsilon(t + k|t) = \frac{1}{P_{inst}} (P(t + k) - \hat{P}(t + k|t))$$

El error puede descomponerse entre el error sistemático μ_e (constante) y error aleatorio ξ_e (media cero).

(4.3)

$$e = \mu_e + \xi_e$$

4.2.3 Definición de Medidas de Error

A continuación se muestran medidas de error que, al menos, se deben considerar según el protocolo de estandarización de evaluación de modelos de predicción de corto plazo [24]. En general, se utilizarán medidas de error normalizadas ya que generan resultados que son independientes de la capacidad del parque.

Error Sistemático Normalizado (NBIAS):

(4.4)

$$NBIAS(k) = \frac{1}{P_{inst}} \cdot \frac{1}{N} \cdot \sum_{t=1}^N e(t+k|t)$$

Error Medio Absoluto Normalizado (NMAE):

(4.5)

$$NMAE(k) = \frac{1}{P_{inst}} \cdot \frac{1}{N} \cdot \sum_{t=1}^N |e(t+k|t)|$$

Error Cuadrático Medio Normalizado (NRMSE):

(4.6)

$$NRMSE(k) = \frac{1}{P_{inst}} \cdot \sqrt{\frac{\sum_{t=1}^N (e(t+k|t))^2}{N - p}}$$

Desviación Estándar del Error Normalizada (NSDE):

(4.7)

$$NSDE(k) = \frac{1}{P_{inst}} \cdot \left(\frac{\sum_{t=1}^N (e(t+k|t) - \bar{e}(k))^2}{N - (p + 1)} \right)^{\frac{1}{2}}$$

Notar que para el conjunto de test $p = 0$. Esta medida de error se puede utilizar como alternativa al *NRMSE*. En este sentido, se utilizará el *NRMSE*.

4.2.4 Comparación de Modelos

Para determinar la calidad de un modelo se recomienda hacer una comparación con el modelo de referencia utilizado, así, es posible determinar cuál es la mejora que significa el desarrollo de un modelo avanzado con respecto a un modelo simple.

La mejoría de un modelo con respecto al modelo de referencia es:

(4.8)

$$IMP_{ref,EC}(k) = \frac{EC_{ref}(k) - EC(k)}{EC_{ref}(k)}$$

En donde EC es el criterio de evaluación, puede ser *Bias*, *MAE*, *RMSE* o éstos normalizados.

4.2.5 Modelos de Referencia

Los modelos de referencia son modelos desarrollados mediante consideraciones simples que se utilizan para comparar los resultados obtenidos con los modelos avanzados.

El principal modelo de referencia utilizado es el modelo persistente, en donde la predicción de potencia es igual al último valor medido [28]:

(4.9)

$$\hat{P}_P(t + k|t) = P(t)$$

El modelo persistente presenta un buen desempeño en horizontes cortos de predicción (4 a 6 horas) y muy mal desempeño para horizontes largos.

Este modelo de referencia presenta muy mal desempeño en las primeras horas de predicción, pero tiene mejores resultados que el modelo persistente en el largo plazo.

Otro modelo de referencia es el promedio global de la potencia (en el conjunto de entrenamiento):

(4.10)

$$\hat{P}_0(t + k|t) = \overline{P(t)}$$

Se han analizado estos modelos de referencia por Nielsen et al. [28] y se ha propuesto unir estos dos enfoques para crear un método que obtenga mejores resultados que cada uno independientemente. Esto lleva a un nuevo modelo de referencia (Modelo de referencia de Nielsen) que es el que se utilizará para comparar los resultados obtenidos en este trabajo.

4.2.5.1 Implementación de Modelo de Referencia de Nielsen

El modelo de referencia de Nielsen, al igual que el modelo de referencia persistente y el de promedio global, no incluyen la velocidad del viento como entrada, tal como se puede ver en (4.11). El nuevo modelo de referencia es:

(4.11)

$$\hat{P}_{NR}(t + k|t) = a_k P(t) + (1 - a_k) \overline{P(t)}$$

En donde a_k es el coeficiente de correlación entre $P(t)$ y $P(t + k)$.

Todas las cantidades estadísticas importantes: $\overline{P(t)}$ y a_k (ver coeficiente de correlación en Anexo B), se calculan con el conjunto de entrenamiento y la predicción se hace en el conjunto de test.

En la Figura 4.1 se muestra una comparación entre la potencia activa real y la predicción del modelo de referencia en un horizonte de 36 pasos.

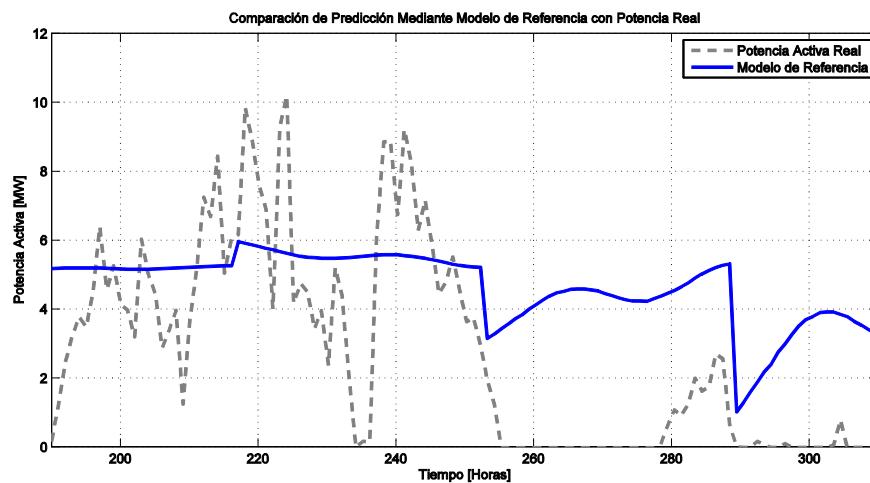


Figura 4.1: Comparación de predicción mediante modelo persistente con potencia real en Canela

En la Tabla 4.1 se muestran las principales medidas de error del modelo de referencia de Nielsen.

Tabla 4.1: Errores de Modelo de Referencia

| | |
|---------------------------|-------|
| BIAS [MW] | -1,52 |
| NBIAS[% de Pinst] | -8,38 |
| MAE [MW] | 2,93 |
| NMAE [% de Pinst] | 16,14 |
| RMSE [MW] | 3,38 |
| NMRSE [% de Pinst] | 18,64 |

En la Figura 4.2 se muestra el histograma de error del modelo de referencia de Nielsen.

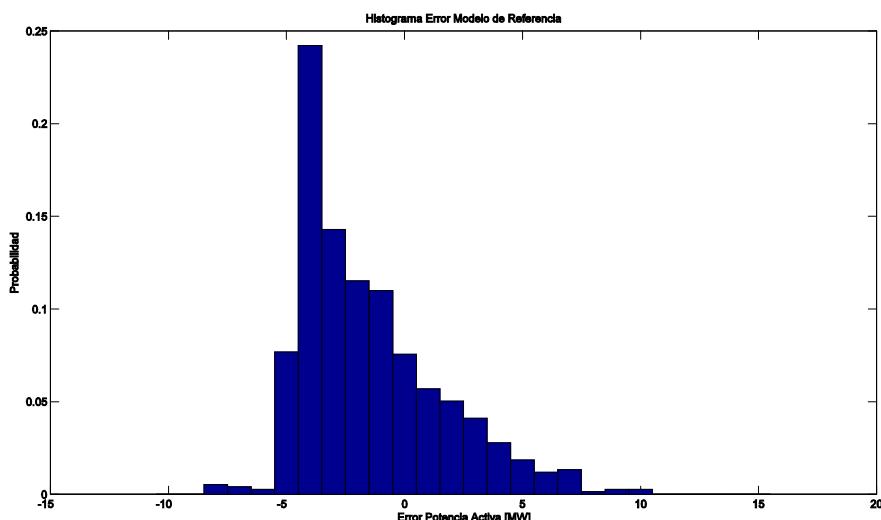


Figura 4.2: Histograma de error de modelo de referencia de Nielsen

4.3 Selección y Obtención de Datos

En la identificación de sistemas utilizando modelos no-lineales y en el caso en particular de la identificación mediante Redes Neuronales, es necesario separar los datos en tres conjuntos:

Entrenamiento (40%): estos datos son utilizados para calcular los parámetros del modelo. No debe usarse para evaluar el desempeño del modelo ya que el error de entrenamiento baja a medida que se aumenta la complejidad de éste y pierde capacidad de predicción en un set de datos distinto.

Validación (40%): conjunto de datos utilizados para seleccionar la estructura del modelo.

Test (20%): este conjunto de datos es utilizado para evaluar el desempeño del modelo propuesto. Sólo debe utilizarse para evaluar y en ningún caso para ajustar parámetros o seleccionar la estructura de la red.

Los datos de entrada y salida del sistema son series de tiempo, es decir, son variables que son función del tiempo. Se deben separar en partes continuas, tal como se muestra en la Figura 4.3 (para la velocidad de viento). La presentación de los datos de potencia es similar.

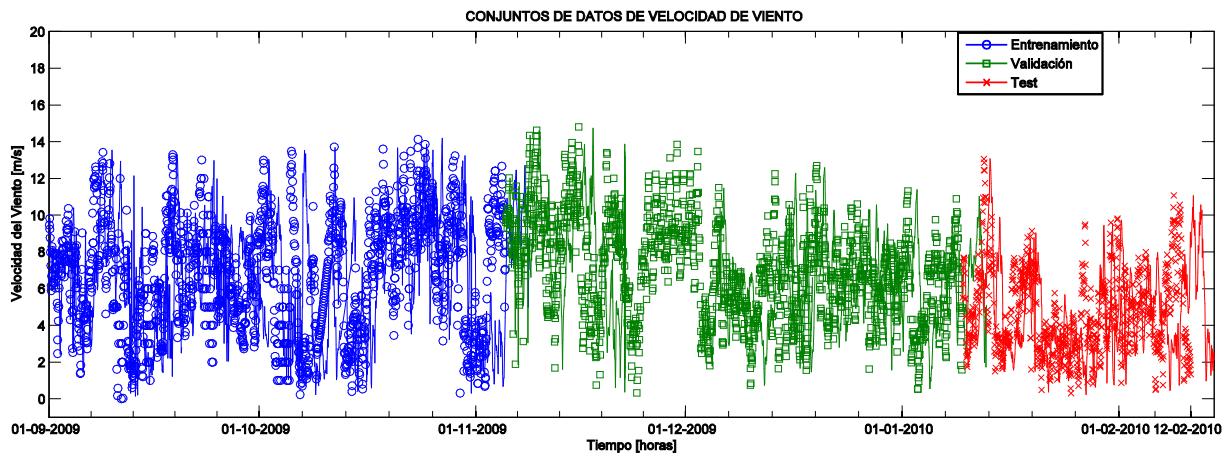


Figura 4.3: Conjunto de datos de velocidad de viento

Los períodos a los cuales corresponden los conjuntos de datos son:

Entrenamiento: 1 de Septiembre de 2009 hasta el 5 de Noviembre de 2009;

Validación: 5 de Noviembre de 2009 hasta el 9 de Enero de 2010;

Test: 9 de Enero de 2010 hasta el 12 de Febrero de 2010.

A continuación se muestra la estrategia de muestreo, las variables de entrada y salida, las características del NWP y un análisis de los datos de la velocidad de viento.

Estrategia de Muestreo: todos los datos han sido tomados con un paso de muestreo de 1 hora, tomando el promedio sobre mediciones cada 1 segundo.

Variable de Entrada: La entrada del modelo es la velocidad del viento medida en una estación de monitoreo ubicada al interior del parque, a 80 m de altura sobre la superficie, al igual que la altura de las turbinas.

En la Figura 4.4 se muestra el gráfico de velocidad de viento medida en la estación de monitoreo versus el tiempo, en una ventana de tiempo de dos meses, correspondientes a los meses de septiembre y octubre del año 2009.

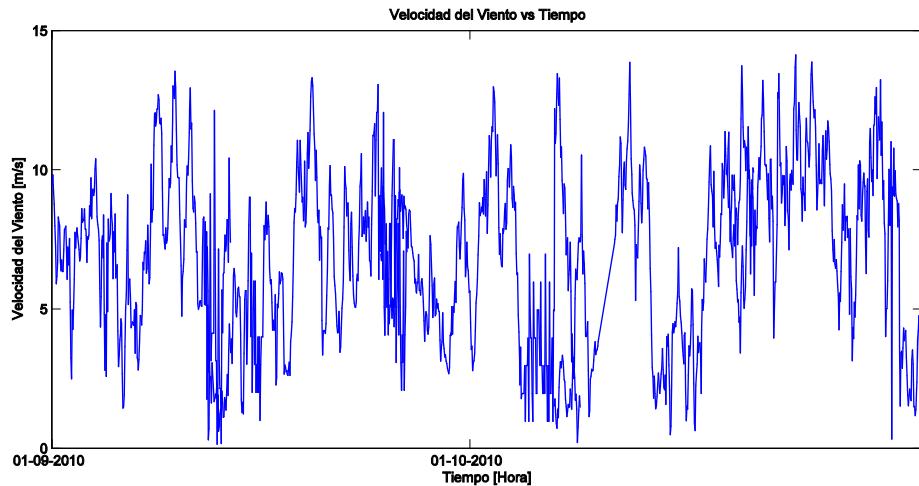


Figura 4.4: Velocidad de viento vs tiempo

El análisis de la medición de velocidad de viento sobre el periodo comprendido en los meses de septiembre de 2009 y febrero de 2010, muestra que la velocidad de viento mínima medida en el parque es de 0,0232 m/s y la máxima es de 14,79 m/s. Las muestras se hacen en un promedio de 1 hora sobre mediciones de 1 segundo y, por lo tanto, la variabilidad del viento asegura que la velocidad de viento mínima medida en el parque es menor que el menor promedio horario, al igual que la velocidad máxima es mayor que el máximo promedio horario. Los datos muestran también que el promedio 6,47 m/s y una desviación estándar de 2,91 m/s.

En la Figura 4.5 se muestra la distribución estadística de la velocidad del viento, y una ajuste de Weibull de los datos (ver Capítulo 2.5).

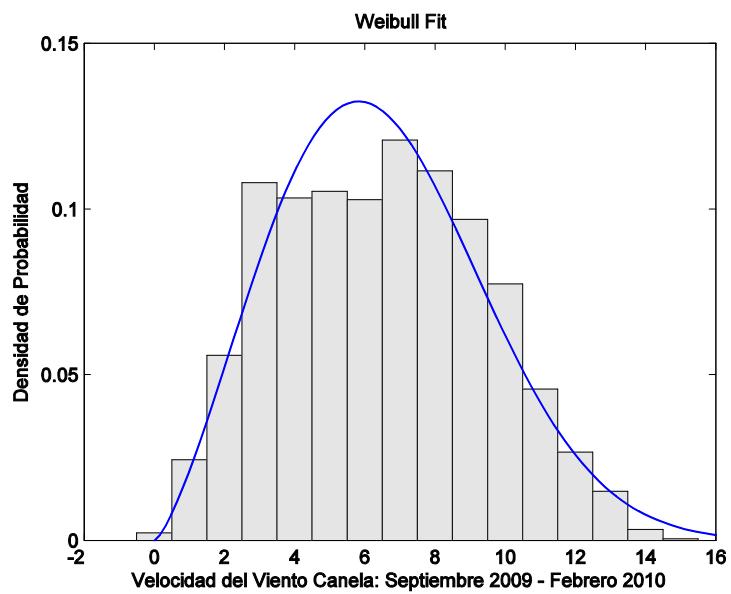


Figura 4.5: Ajuste Weibull de distribución estadística de la velocidad del viento

En la Tabla 4.2 se muestran las estadísticas principales de la velocidad del viento y los parámetros del ajuste Weibull.

Tabla 4.2 Estadísticas de Velocidad de Viento

| | Datos Reales | Ajuste Weibull |
|----------------------------|--------------|----------------|
| Media | 6,471 | 6,468 |
| Desviación Estándar | 2,921 | 2,906 |
| Mínima | 0,023 | |
| Máxima | 14,790 | |
| K_{Weibull} | | 2,3675 |
| C_{Weibull} | | 7,299 |

En la Figura 4.6 se muestra el promedio de la velocidad del viento y su desviación estándar en función de la hora del día.

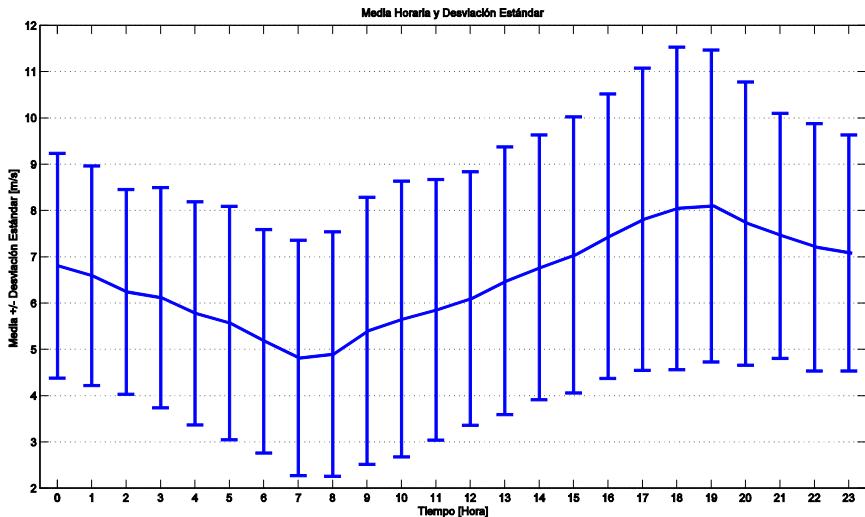


Figura 4.6: Media horaria y desviación estándar de la velocidad del viento

Variable de Salida: La salida del modelo es la potencia activa medida en la conexión del parque con la red.

En la Figura 4.7 se muestra el gráfico de potencia versus el tiempo, en una ventana de tiempo de dos meses, correspondientes a los meses de septiembre y octubre del año 2009. Los conjuntos de test, validación y entrenamiento corresponden exactamente a los mismos que se han utilizado para la velocidad de viento.

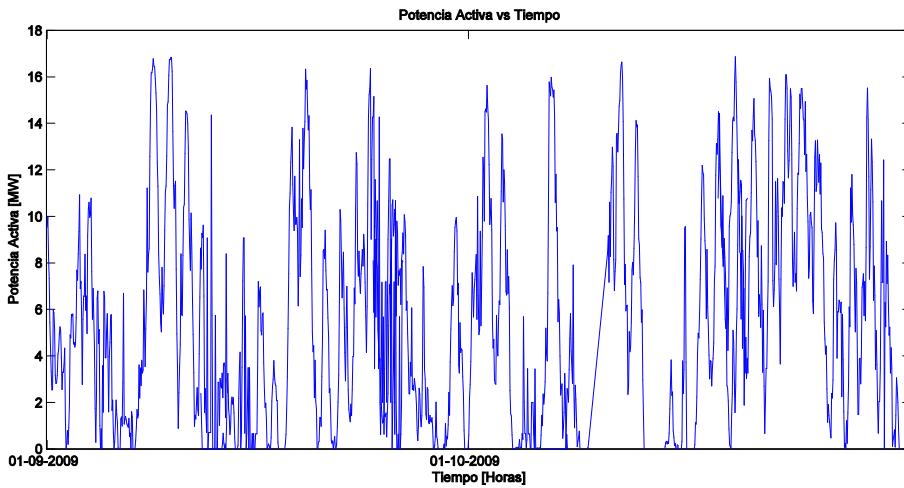


Figura 4.7: Potencia activa vs tiempo

Características de NWP: las predicciones de velocidad del viento son entregadas por la DGAC (Dirección General de Aeronáutica Civil). Los pronósticos son entregados para el punto central de una

grilla de 144 Km². El primer pronóstico diario es entregado a las 3:00 horas y actualiza cada 6 horas. En la Tabla 4.3 se muestran las características del NWP.

Tabla 4.3 Características de NWP

| | |
|------------------------------------|---------------------|
| Frecuencia de Actualización | 6 Hrs |
| Horizonte de Predicción | 72 Hrs |
| Tiempo de Muestreo | 1 Hr |
| Resolución | 144 km ² |

4.4 Desarrollo de Modelos Lineales

En esta sección se muestran los resultados obtenidos con los modelos lineales FIR y ARX descritos en el Capítulo 3. La suposición más importante en la implementación de los modelos lineales y no lineales que se presentan en este capítulo es que se conoce la velocidad del viento en el futuro $v(t + k|t)$. Esta es una suposición necesaria para el estudio de la predicción con intervalo de confianza que se desarrollará en detalle en el Capítulo 6.

Se hará primero una selección de estructura para cada modelo, se estimarán los parámetros del mejor obtenido y serán mostradas las predicciones. Al final se presenta una tabla de errores que cumple el objetivo de comparar el resultado de los modelos propuestos con el modelo de referencia.

4.4.1 Desarrollo de Modelo FIR

Se seleccionará la mejor estructura de modelo FIR mediante la minimización del índice de Akaike. Varias estructuras serán propuestas.

La Figura 4.8 muestra el índice de Akaike para las estructuras probadas.

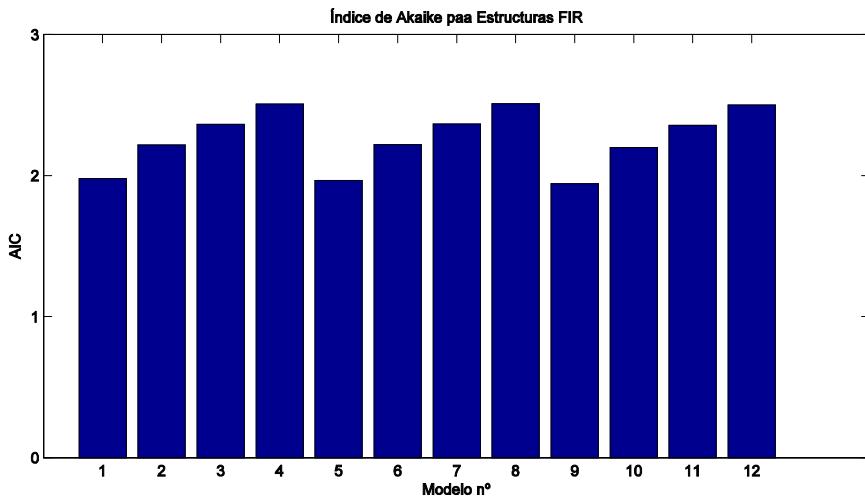


Figura 4.8: Índice de Akaike para estructuras de modelo FIR

A partir de la Figura 4.8, se desprende que el modelo 5 es el que presenta un menor índice de Akaike y es , por lo tanto, el que se seleccionará.

La estructura del modelo FIR es:

(4.12)

$$na = 0; nb = 3; nk = 0$$

El predictor de potencia FIR, expandiendo el formato polinomial mostrado en 3.15 es:

(4.13)

$$\hat{P}(t) = b_1 v(t) + b_2 v(t - 1) + b_3 v(t - 2)$$

Los parámetros del modelo obtenido a través de mínimos cuadrados se muestra en la Tabla 4.4:

Tabla 4.4: Parámetros FIR

| | |
|-------------------------|--------|
| b_1 | 1,448 |
| b_2 | -0,032 |
| b_3 | -0,293 |

En Figura 4.9, se muestra una comparación entre la potencia activa real y la predicción del modelo FIR. Notar que la predicción es a infinitos pasos (asumiendo que se conoce $v(t)$ en cada uno de esos pasos), ya que el modelo FIR no incluye retardos de salida.

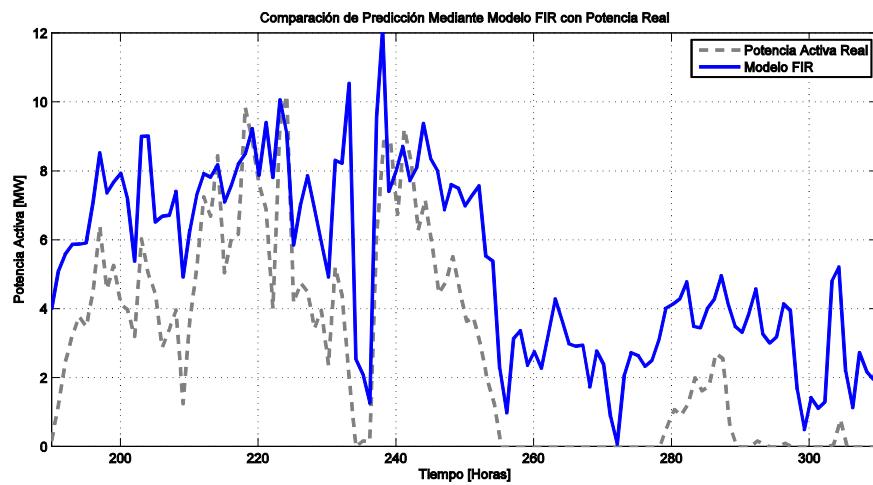


Figura 4.9: Comparación de predicción mediante modelo FIR con potencia real en Canela

En la Tabla 4.5 se muestran las principales medidas de error del modelo FIR.

Tabla 4.5: Errores de Modelo FIR

| | [MW] | [% de Pinst] | IMP [%] |
|-------------|---------|--------------|---------|
| BIAS | -2,5771 | -14,20 | -69,48 |
| MAE | 2,8013 | 15,43 | 4,39 |
| MRSE | 3,0361 | 16,73 | 10,26 |

En la Figura 4.10 se muestra el histograma de error del modelo FIR.

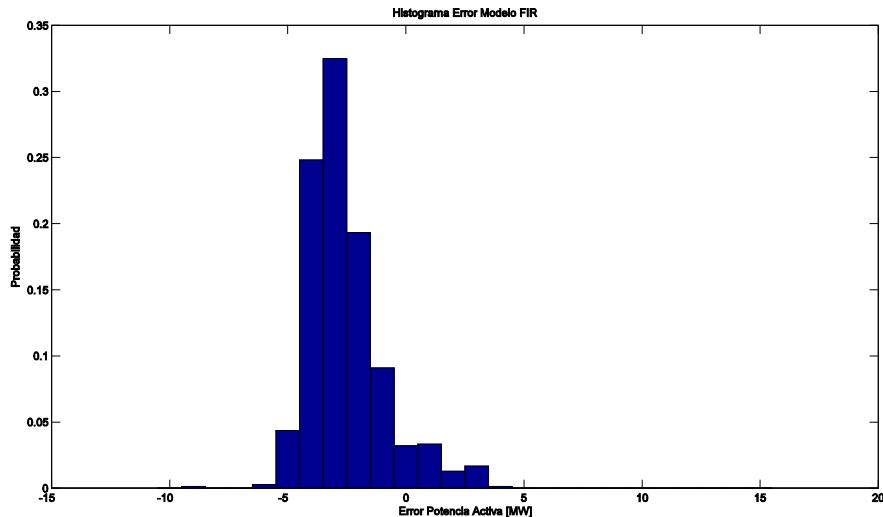


Figura 4.10: Histograma de error de modelo FIR

La Figura 4.9 muestra que el modelo FIR modela mejor en potencias medias que en las potencias bajas (cercanas a cero). Lo que hace que el comportamiento del modelo sea mejor para potencias medias, es que en el comportamiento del sistema real se puede asumir que para potencias medias el comportamiento del sistema es lineal, mientras que las no linealidades se encuentran en las potencias de viento bajas, en donde hay una saturación a cero, y en las potencia altas, donde también existe una saturación.

4.4.2 Desarrollo de Modelo ARX

Se seleccionará la mejor estructura de modelo ARX mediante la minimización del índice de Akaike. Varias estructuras serán propuestas.

En la figura 4.11 se muestra el índice de Akaike para las estructuras probadas.

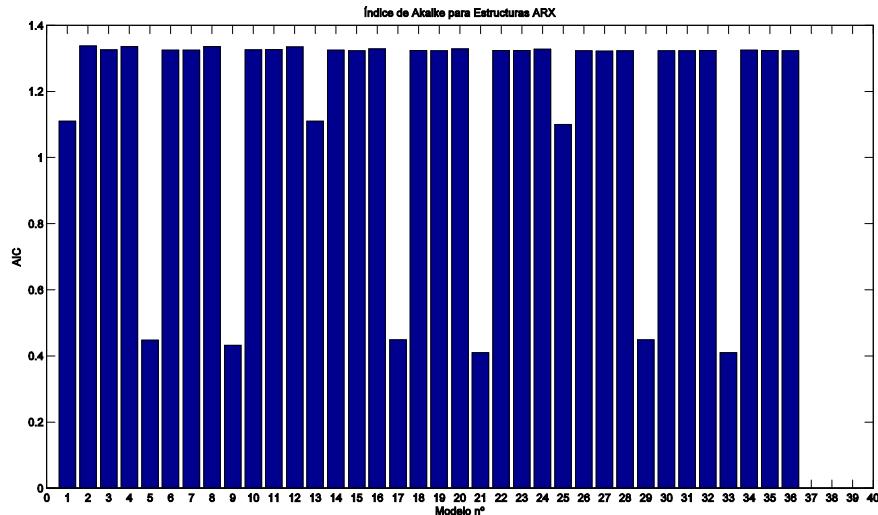


Figura 4.11: Índice de Akaike para estructuras de modelo ARX

Tomando en cuenta la simplicidad del modelo (el número de parámetros es creciente según aumenta el número que identifica al modelo) y la minimización del índice de Akaike se concluye que el mejor modelo es el número 5.

La estructura del modelo ARX es:

(4.14)

$$na = 1; nb = 2; nk = 0$$

El predictor de potencia ARX, expandiendo el formato polinomial mostrado en 3.15 es:

(4.15)

$$\hat{P}(t) = -a_1\hat{P}(t-1) + b_1v(t) + b_2v(t-1)$$

Los parámetros del modelo obtenido a través de la minimización de mínimos cuadrados se muestra en la Tabla 4.6:

Tabla 4.6: Parámetros ARX

| | |
|-------|--------|
| a_1 | -0,875 |
| b_1 | 1,086 |
| b_2 | -0,977 |

En la Figura 4.12, se muestra una comparación entre la potencia activa real y la predicción del modelo ARX. La predicción de potencia es realizada cada 36 horas, es decir, una predicción a 36 pasos (esto cobra importancia sólo cuando el modelo incorpora retardos en la salida).

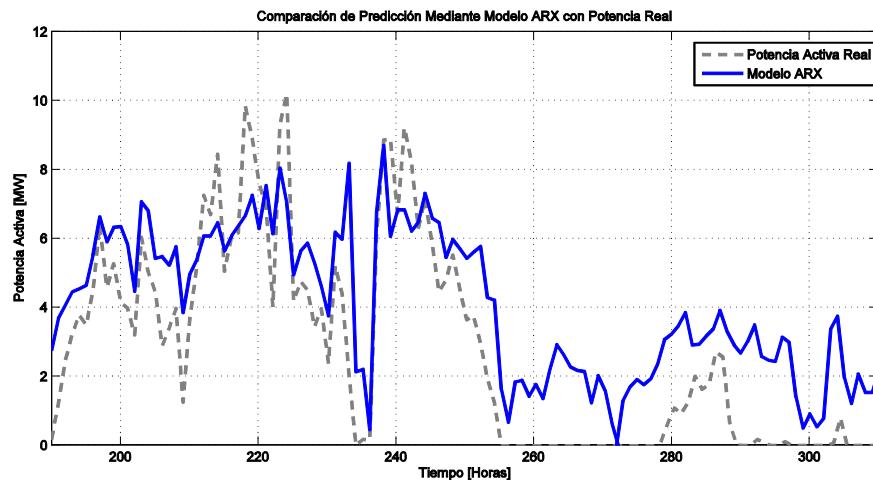


Figura 4.12: Comparación de predicción a 36 horas mediante modelo ARX con potencia real en Canela

En la Tabla 4.7 se muestran las principales medidas de error del modelo ARX.

Tabla 4.7: Errores de Modelo ARX

| | [MW] | % de Pinst | IMP [%] |
|-------------|--------|------------|---------|
| BIAS | -1,362 | -7,50 | 10,43 |
| MAE | 1,999 | 11,01 | 31,78 |
| MRSE | 2,257 | 12,43 | 25,67 |

En la Figura 4.13 se muestra el histograma de error del modelo ARX.

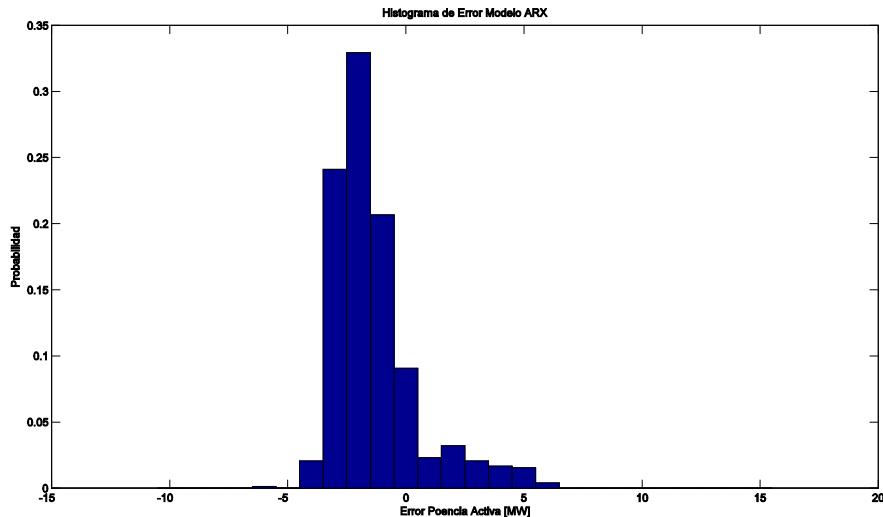


Figura 4.13: Histograma de error modelo ARX

El modelo ARX presenta un mejoramiento en todas las medidas de error de interés con respecto al modelo de referencia y al modelo FIR. Sin embargo, aún tiene problemas para predecir las potencias bajas, lo que se explica, al igual que para el modelo FIR, por la saturación que existe en ese punto. Las saturaciones son por esencia no lineales y, obviamente, un modelo lineal no las podrá predecir.

4.5 Desarrollo de Red Neuronal MLP

La estructura de la red neuronal se seleccionará mediante un método exhaustivo en el que se probarán varios números de neuronas. La mejor estructura seleccionada será con la que el modelo presente el menor error cuadrático medio en el conjunto de test.

La red neuronal utilizada será del tipo MLP con una sola entrada, la velocidad del viento instantánea. En 4.16 se muestra la estructura de la red neuronal utilizada.

(4.16)

$$\hat{P}(t) = g(v(t))$$

La figura 4.14 muestra el error cuadrático medio, calculado en el conjunto de test, para los número de neuronas probadas.

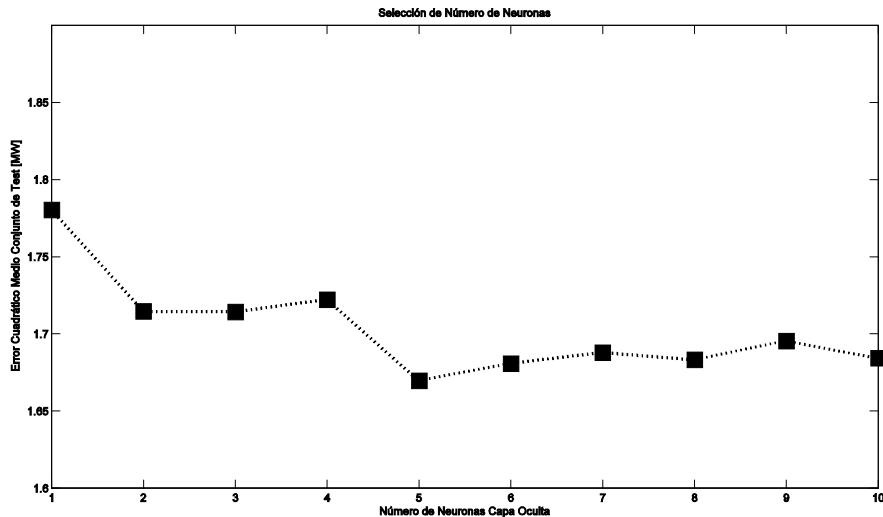


Figura 4.14: Selección de número de neuronas de capa oculta

De la figura anterior se desprende que estructura que presenta un error cuadrático medio menor es una red neuronal con 5 neuronas en la capa oculta.

En la Tabla 4.8 se muestra un resumen de la arquitectura de la red neuronal seleccionada.

Tabla 4.8: Red Neuronal MLP

| | |
|--|----------------------|
| Número Neuronas Capa Oculta | 5 |
| Funciones de Activación Capa Oculta | tansig |
| Función Activación Capa de Salida | purelin |
| Entrada | Velocidad del Viento |
| Salida | Potencia Activa |
| Entrenamiento | Levenberg Marquardt |

En el entrenamiento de la red neuronal se ha utilizado el método de Levenberg-Marquardt (ver Anexo C) para minimizar el error cuadrático medio del modelo. Los pesos de la red neuronal se muestran en Anexo D.

En la Figura 4.15, se muestra una comparación entre la potencia activa real y la predicción del modelo MLP. Notar que es una predicción a infinitos pasos ya que no se incluyen retardos de la variable de salida.

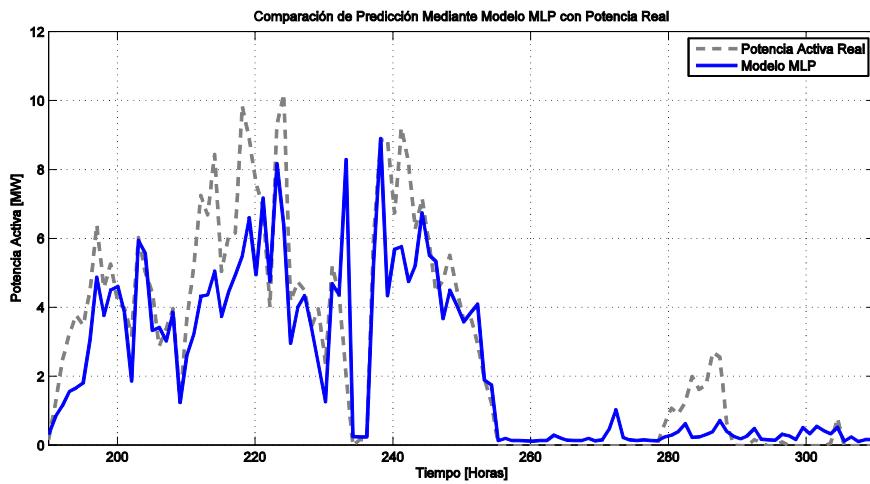


Figura 4.15: Comparación de predicción mediante modelo MLP con potencia real en Canela

En la Tabla 4.9 se muestran las principales medidas de error del modelo MLP.

Tabla 4.9: Errores de Modelo MLP

| | [MW] | [% de Pinst] | IMP [%] |
|------|--------|--------------|---------|
| BIAS | 0,4479 | 2,47 | 129,46 |
| MAE | 0,7636 | 4,21 | 73,94 |
| MRSE | 1,2689 | 6,99 | 62,49 |

En la figura 4.16 se muestra el histograma de error del modelo MLP.

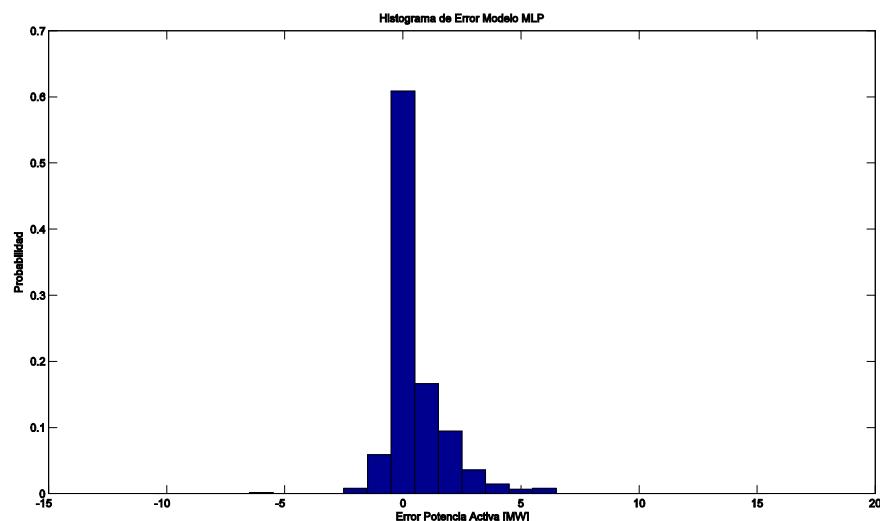


Figura 4.16: Histograma de error modelo MLP

El modelo MLP es que muestra mejores resultados, el error medio está dentro de sólo un 2% del error y tiene el menor error cuadrático medio de todos los modelos. La figura 4.51 muestra que el modelo predice correctamente tanto en períodos de potencia baja como en potencia media y alta. En cerca del 60% de los instantes el error de la predicción está en las cercanías de 0 MW, como se puede observar en la Figura 4.16.

4.6 Discusión de Resultados

El error sistemático correspondiente al error medio, el error cuadrático medio y el error medio absoluto son bastante menores en el modelo MLP en comparación con los modelos lineales y el de referencia.

La Tabla 4.10 muestra un resumen de las medidas de error utilizadas. El mejor modelo, la red MLP, se muestra marcada en color verde.

Tabla 4.10: Resumen de Resultados de Modelos

| | BIAS [MW] | IMP [%] | MAE [MW] | IMP [%] | MRSE [MW] | IMP [%] |
|------------|--------------|----------------|--------------|---------------|--------------|---------------|
| FIR | -2,577 | -69,479 | 2,801 | 4,386 | 3,036 | 10,257 |
| ARX | -1,362 | 10,430 | 1,999 | 31,784 | 2,257 | 25,671 |
| MLP | 0,448 | 129,455 | 0,764 | 73,937 | 1,269 | 62,493 |

Los modelos lineales presentan un gran error cuando el factor de carga es bajo y alto y mejoran para factores de carga medio. La red MLP es capaz de predecir con mayor exactitud que los modelos lineales para los factores de carga bajos, medios y altos.

La ausencia de retardos en la salida y entrada para la red neuronal MLP hacen que este modelo sea muy robusto. La justificación de esta ausencia la valida los resultados obtenidos en la Tesis de G. Bustos [29], que muestra que el tiempo que demora en responder la potencia frente a un escalón de velocidad de viento es cercano a los 12 segundos. Dado que el tiempo de muestreo del modelo MLP es de 1 hora, se puede asumir despreciable la dinámica del sistema pudiéndose modelar perfectamente como un sistema estático.

Capítulo 5

5.1 Introducción

En el Capítulo 4 se han estudiado una variedad de modelos lineales y el modelo de red neuronal MLP. Como entrada de los modelos se ha utilizado la velocidad de viento real medida en una estación de monitoreo ubicada al interior del parque eólico y los resultados, mostrados en el resumen de resultados de la Tabla 4.10, se han calculado suponiendo que se conoce con exactitud la velocidad de viento para cualquier horizonte de tiempo. Este supuesto es sólo válido para calibrar el modelo de entrada – salida ya que en la realidad no es posible saber la velocidad del viento con exactitud. Para utilizar el modelo para predicción de potencia se utiliza como entrada del modelo la predicción de velocidad de viento provista por la DGAC junto a un método novedoso descrito en el Capítulo 6.2.

5.2 Descripción del Método

El método que se utilizará busca caracterizar el error de la predicción entregada por la DGAC e incorporarlo al modelo como una corrección para éste. El objetivo es lograr una predicción de potencia dentro de un intervalo de confianza.

El error de la predicción es una variable aleatoria que se asume dependiente del valor de la predicción y del horizonte de tiempo para el cual se realiza la predicción. En la mayoría de los casos, este error no se ajusta a alguna distribución estadística conocida, por lo que se utilizará un método empírico basado en kernel para el ajuste.

Las predicciones que realiza el modelo seleccionado en el Capítulo 4 (red MLP) no se hacen directamente de las predicciones que entrega la DGAC, sino que son el producto de simulaciones de Monte Carlo, en donde la entrada del modelo (la predicción de la DGAC) es perturbada con realizaciones del error de predicción. La predicción de potencia se calculará como el valor esperado de la salida de la red producto de las simulaciones.

En los sub capítulos siguientes se detallarán el estudio de error, la predicción con intervalo de confianza y se hará un análisis de los resultados obtenidos.

5.3 Estudio de Error de Predicción

La predicción que entrega la DGAC no pretende ser precisa para un punto en el espacio específico. Ésta es más bien un valor general al interior de una grilla, en este caso de 144 km^2 .

Las mediciones de velocidad del viento medidas en la estación de monitoreo del parque no son representativas en un ciento por ciento de la velocidad del viento que recibe cada turbina, como ejemplo de perturbaciones que se presentan en las mediciones de velocidad de viento en cada

turbina está el efecto estela que produce una turbina sobre otra ubicada más atrás y los efectos producidos por la orografía del terreno. Sin embargo, se asumirá que la velocidad del viento medida en la torre de monitoreo representa al parque en su totalidad. En general, ninguna turbina genera exactamente la misma potencia que otra en distinta ubicación espacial al interior del parque, bajo las mismas condiciones climáticas.

El error en las predicciones, comparado con la velocidad real del viento en la estación de monitoreo, se muestra en 5.1:

(5.1)

$$\xi = v - \hat{v}$$

Se asume que el error se distribuye como una variable aleatoria δ cuyos parámetros dependen del valor de la predicción \hat{v} y el horizonte de tiempo para el cual está hecha la predicción K :

(5.2)

$$\xi \sim \delta(\hat{v}, K)$$

Se han creado rangos tanto para la predicción de la velocidad del viento como para el horizonte de predicción.

Se ha considerado que las predicciones están dentro de los rangos:

(5.3)

$$\hat{v}_1 \in [0 - 1] \text{ m/s}; \quad \hat{v}_2 \in [1 - 2] \text{ m/s}; \text{ etc.}$$

El horizonte de tiempo K está definido en los rangos:

(5.4)

$$K_1 \in [1 - 6] \text{ horas}; \quad K_2 = [7 - 12] \text{ horas}; \dots; \quad K_6 = [31 - 36] \text{ horas};$$

El estudio del error de predicción de velocidad de viento de la DGAC tiene por objetivo crear histogramas en función del horizonte K y del valor de la predicción \hat{v} . La selección de rangos tiene como motivación el obtener una mayor cantidad de datos para cada par (\hat{v}_i, K_j) y así lograr histogramas más representativos y de mejor calidad, en especial cuando las predicciones de velocidad de viento se ubican en los extremos (velocidades muy altas o cercanas a cero) y existe poca cantidad de datos. A modo de ejemplo, en la Figura 5.1 se muestra el histograma del error para las predicciones de velocidad de viento que están entre 1 y 2 m/s en un horizonte de entre 7 y 12 horas. En el Anexo E es posible ver otros ejemplos de histogramas del error de predicción.

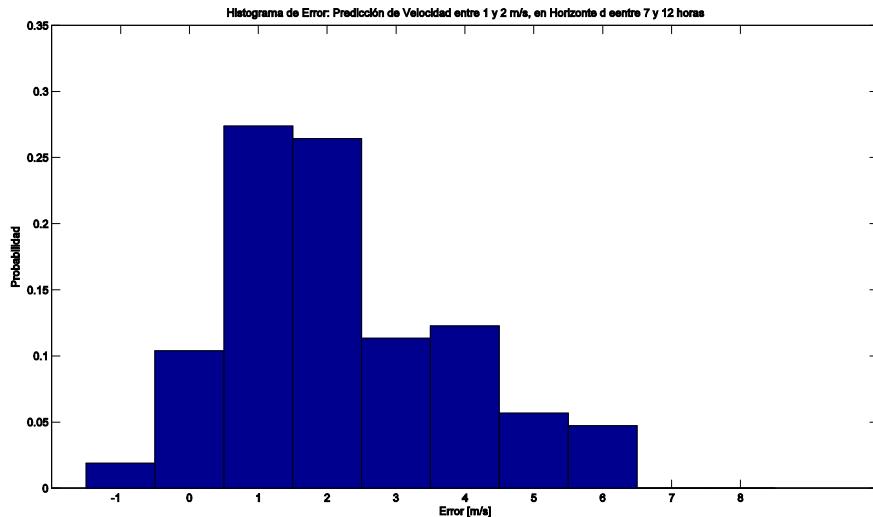


Figura 5.1: Histograma de error de predicción de velocidad entre 1 y 2 m/s, en horizonte de entre 7 y 12 horas

El error medio de la predicción mostrada en la Figura 5.1 es de 2,21 m/s. Esto está bastante alejado del error nulo que teóricamente debiese existir en el caso de que las predicciones fuesen similares a la velocidad real del viento en la estación de monitoreo.

En la Figura 5.2 se muestra la función de distribución acumulada empírica para el mismo caso de predicción de la Figura 5.1:

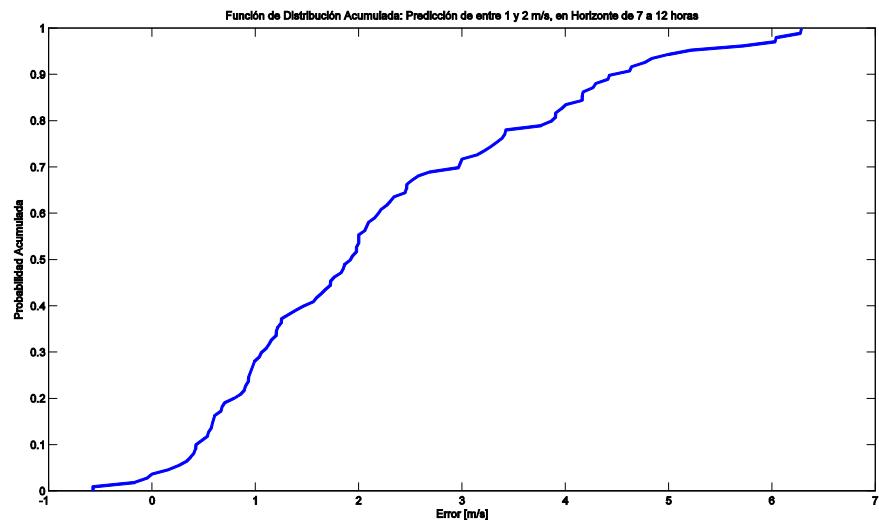


Figura 5.2: Función de distribución acumulada para predicción de viento de entre 1 y 2 m/s, en horizonte de entre 7 y 12 horas

La Figura 5.2 muestra una curva que no es suave; dicho efecto aumenta cuando las muestras son pocas o de mala calidad, como por ejemplo *outliers*. Al mirar la distribución estadística del viento en la Figura 3.2 se observa que las velocidades de viento en los extremos tienen una menor probabilidad de ocurrencia que las velocidades medias. Por esto es natural que se tengan pocas muestras del error en los extremos, lo que genera histogramas y funciones de densidad acumulada empírica que no son suaves o están degeneradas. Esto sucede porque las muestras han sido tomadas desde un muestreo discreto y no a partir de la distribución continua [30]. Para suavizar la función de densidad acumulada se utiliza el método de regularización basado en el kernel de Epanechnikov que se estudia en la Sección 5.3.1.

5.3.1 Regularización de Función de Distribución Acumulada

La regularización es un método no paramétrico de estimación de densidad de una variable aleatoria. Este método consiste en cambiar la aproximación discreta de la función de distribución acumulada dada por los datos reales y cambiarla a una aproximación continua a través de la suma ponderada de kernels situados en los datos originales (ver Figura 5.3). Este proceso produce nuevas muestras con distintas ubicaciones que los datos originales.

Para la regularización se utiliza un kernel K con función de densidad de probabilidad simétrica, tal que [30]:

(5.5)

$$K \geq 0; \quad \int K(x)dx = 1; \quad \int xK(x)dx = 0; \quad \int \|x\|^2 K(x)dx < \infty$$

Sea el kernel re escalado K_h :

(5.6)

$$K_h(x) = \frac{1}{h^{n_x}}$$

donde h^{n_x} es el ancho del kernel. Considerando muestras que tienen el mismo peso, El kernel óptimo es el de Epanechnikov.

(5.7)

$$K_{opt}(x) = \begin{cases} \frac{n_x + 2}{2c_{n_x}}(1 - \|x\|^2), & \|x\| < 1 \\ 0, & \text{otro caso} \end{cases}$$

donde c_{n_x} es el volumen de un esfera unitaria en \mathbb{R}^{n_x} . Más aún, si la densidad es gaussiana con matriz de covarianza unitaria, el ancho óptimo del kernel es [30]:

(5.8)

$$h_{opt} = A \cdot N^{-\frac{1}{n_x+4}}$$

Siendo A calculado como:

(5.9)

$$A = \left(8c_{n_x}^{-1} \cdot (n_x + 4) \cdot (2\sqrt{\pi})^{n_x} \right)^{\frac{1}{n_x+4}}$$

La Figura 5.3 muestra de manera intuitiva el concepto de regularización de un muestreo empírico.

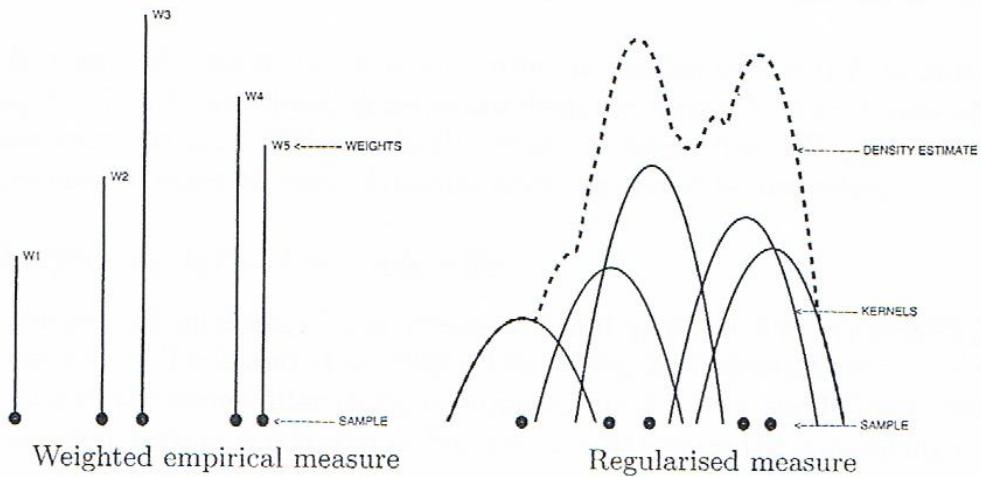


Figura 5.3: Concepto de regularización mediante el uso de kernel [31]

La regularización de los histogramas de error de predicción de la DGAC se ha hecho utilizando el Toolbox de Estadística de Matlab, en particular la función *ksdensity*, con el kernel de Epanechnikov y el ancho de kernel óptimo, especificado más adelante.

En la Figura 5.4 se muestra la regularización de la función de distribución acumulada empírica para el caso de la predicción de la Figura 5.1:

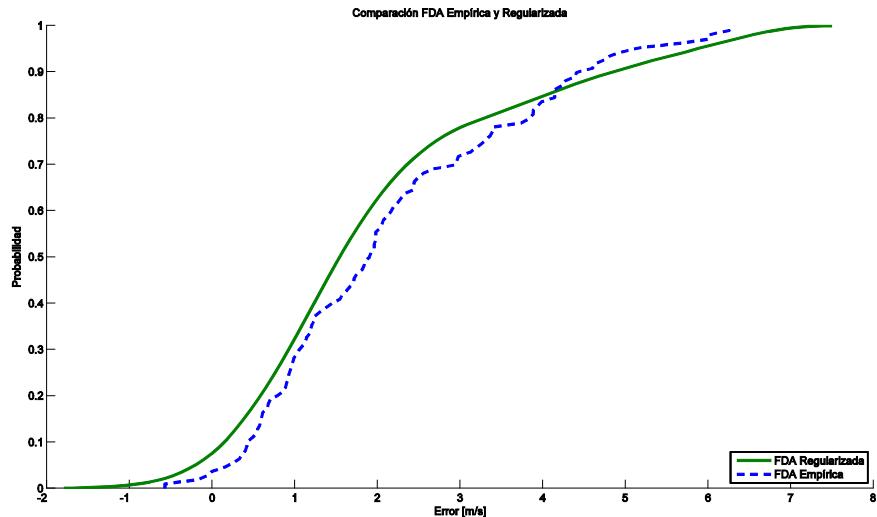


Figura 5.4: Regularización de función de distribución acumulada de Figura 5.1

En la Figura 5.4 se puede observar que la función de distribución acumulada regularizada aproxima bastante bien a la función de distribución acumulada empírica. Esto asegura que las muestras que se tomen posteriormente para crear las realizaciones de la predicción de velocidad del viento se ajusten a la distribución estadística del error de la predicción real.

En el Anexo F es posible ver otros ejemplos de funciones de distribución acumulada regularizadas.

5.4 Estudio de Predicción con Intervalo de Confianza

Las predicciones de potencia suelen entregarse como un pronóstico hora a hora mediante un valor de la potencia que se espera generar, lo que tiene la ventaja de ser fácil de entender. Hoy en día los esfuerzos están enfocados en mejorar las predicciones de velocidad de viento asimilando un mayor número de observaciones y refinando los modelos físicos [32]. A pesar de lo exactos y precisos que puedan llegar a ser los modelos siempre existirá una incertidumbre en sus predicciones ya que no hay un conocimiento total de los procesos atmosféricos que influencian los eventos futuros. La predicción con intervalo de confianza pretende ser un complemento al pronóstico de la potencia al entregar un rango en donde se espera con alta probabilidad que se encuentre el valor de la generación de potencia en las próximas horas.

En este sub capítulo se estudiará en detalle el método utilizado para calcular el intervalo de confianza de la predicción de potencia.

El método consiste de cuatro fases: realización de predicciones; simulación de potencia; predicción de potencia; y cálculo de intervalo de confianza.

La primera fase consiste en crear realizaciones de la entrada del modelo. Estas realizaciones se hacen sumándole a la predicción de velocidad de viento de la DGAC una realización del error. La ecuación (5.9) muestra cómo se genera cada realización:

(5.10)

$$\hat{v}_R(k) = \hat{v}(k) + \xi(k)$$

$$\xi(k) \sim \delta(\hat{v}(k), K(k))$$

donde \hat{v}_R es una realización de la entrada.

La Figura 5.5 muestra, a modo de ejemplo, una comparación entre \hat{v} y algún \hat{v}_R .

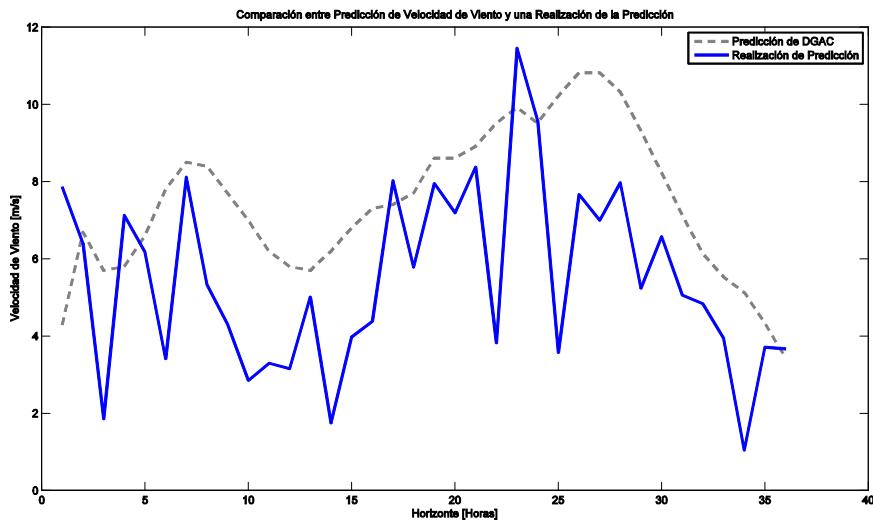


Figura 5.5: Comparación entre predicción de velocidad de viento y una realización de la predicción

Cabe notar que el proceso de regularización es de vital importancia para la creación de las distintas realizaciones. En el caso particular de predicciones de viento muy altas existen pocos datos asociados que permitan crear histogramas de calidad, así, está el caso en que hay menos de diez muestras para alguna combinación de \hat{v} y K . A través de la regularización, es posible distribuir uniformemente las muestras de la distribución estadística y re muestrear a un número distinto de muestras. De esta manera, de todas las funciones de probabilidad acumulada del error se pueden extraer el mismo número de muestras.

La segunda fase del método consiste en simular la relación entrada salida para cada una de las realizaciones de la entrada. Esto es básicamente una simulación de Monte Carlo.

En la Figura 5.6 se muestra la entrada y salida para la realización de la Figura 5.5.

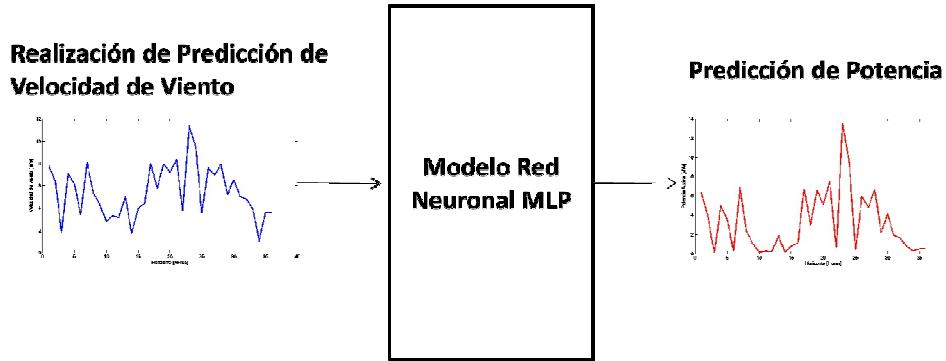


Figura 5.6: Diagrama de entrada y salida del modelo

La tercera fase consiste en calcular la predicción de potencia. Para cada horizonte de predicción se podrán formar histogramas en donde su valor esperado será la predicción de potencia para ese instante.

La cuarta fase del método consiste en calcular el intervalo de confianza. Esto se calcula situándose en el valor esperado del histograma de salida, y calcular menor rango que acumule el 95% (u otro nivel) de la probabilidad.

La Figura 5.7 muestra de manera gráfica el cálculo del intervalo de confianza.

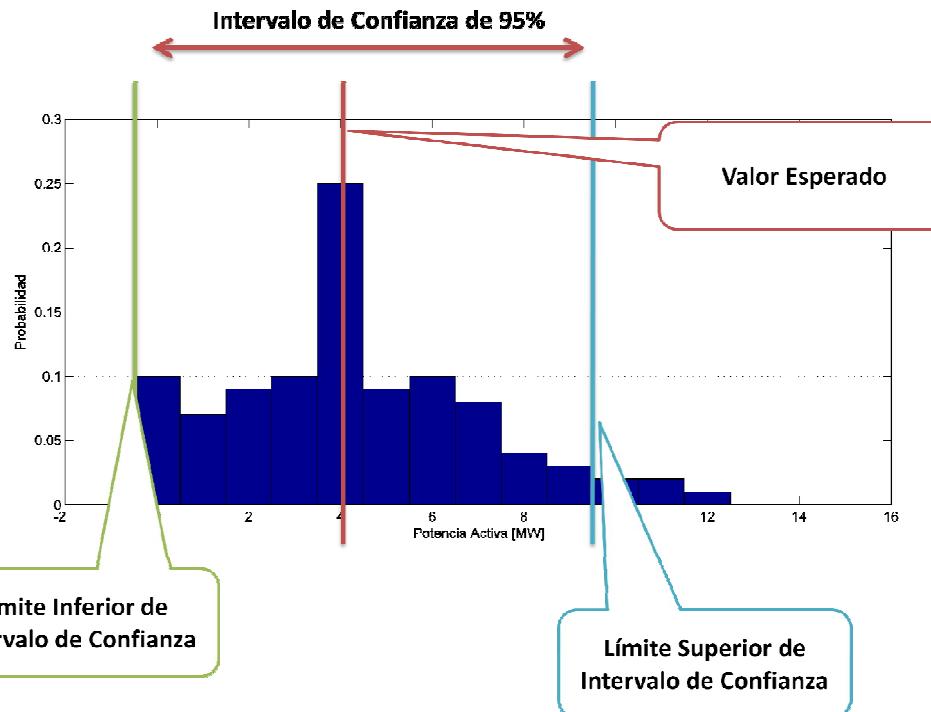


Figura 5.7: Calculo de intervalo de confianza

5.5 Resultados y Validación de Intervalo de Confianza

En este capítulo se mostrarán las fases del cálculo del intervalo de confianza y el predictor de potencia. Con relación al intervalo de confianza, se darán a conocer los parámetros seleccionados: el número de realizaciones de la entrada; el valor estimado del intervalo de confianza; y el ancho del kernel utilizado. Para validar el resultado de la predicción con intervalo de confianza se hará una comparación con el método simple, que consiste en ingresar como entrada al modelo MLP directamente las predicciones de velocidad del viento provistas por la DGAC.

Se define el valor estimado del intervalo de confianza como el porcentaje esperado de predicciones que caen al interior de los límites inferior y superior del intervalo de confianza.

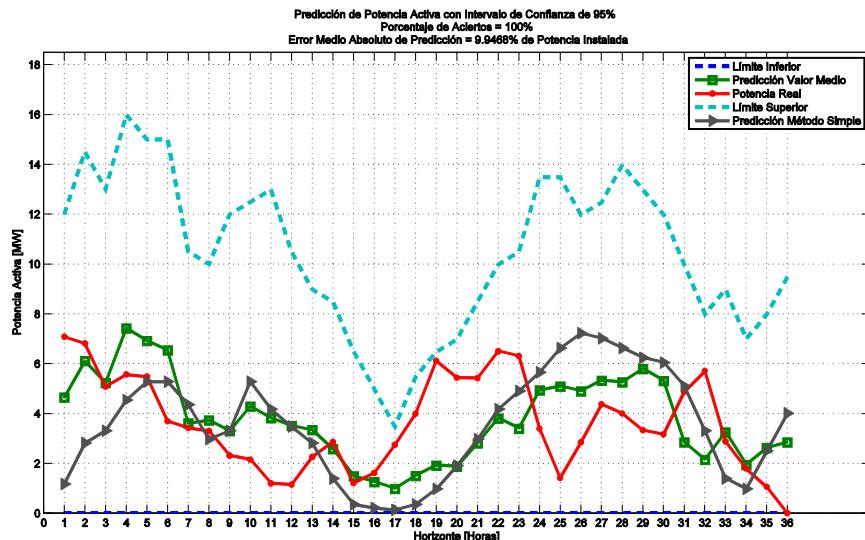
Los histogramas de error de predicción se han calculado utilizando las predicciones entregadas por la DGAC de los meses de diciembre de 2009 y enero de 2010 y las predicciones se han hecho para los meses de febrero de 2010 hasta el 6 de abril de 2010. Es decir, el conjunto de datos con los cuales se calcula el histograma es distinto al con el cual se hacen las predicciones.

La Tabla 5.1 muestra los parámetros de la predicción con intervalo de confianza.

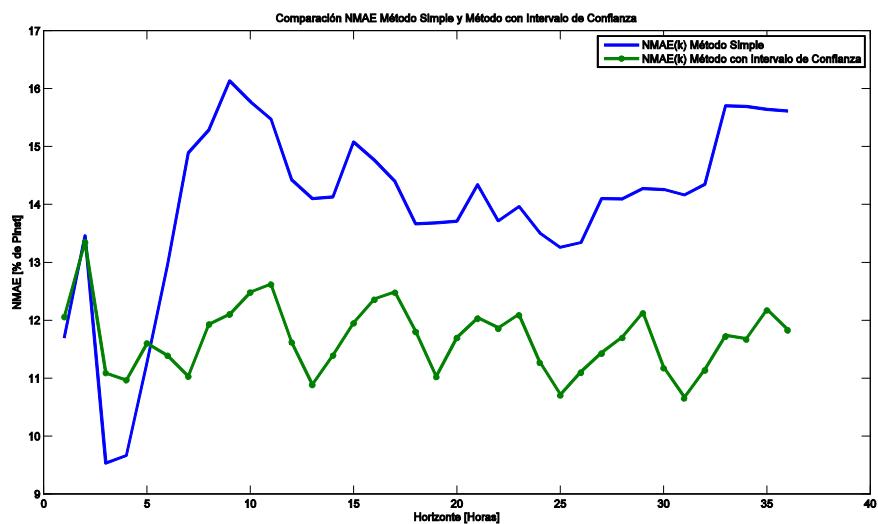
Tabla 5.1: Parámetros de Intervalo de Confianza

| | |
|--|--------|
| Número de Realizaciones | 100 |
| Ancho de Kernel | 0,4754 |
| Valor Estimado de Intervalo de Confianza | 95% |

La Figura 5.8 muestra un ejemplo de la predicción con intervalo de confianza.



En la figura 5.9 se muestra un gráfico que compara el error medio absoluto para cada horizonte de predicción utilizando el método simple y el método de predicción basado en regularización.



La Tabla 5.2 muestra las principales medidas de error para ambos métodos.

Tabla 5.2: Medidas de Error Métodos de Predicción

| | NBIAS [% de Pinst] | NMAE [% de Pinst] | NMRSE [% de Pinst] |
|--|--------------------|-------------------|--------------------|
| Método Simple | -7,55 | 14,00 | 19,52 |
| Método basado en Regularización | -0,03 | 11,68 | 15,43 |

El porcentaje de aciertos en el método de predicción basado en regularización, es decir, el porcentaje de predicciones que están a interior del intervalo, es de un 93,84%.

A modo de comparación, la Figura 5.10 muestra el NMAE esperado para los modelos propuestos por las empresas que prestan servicios de predicción de potencia.

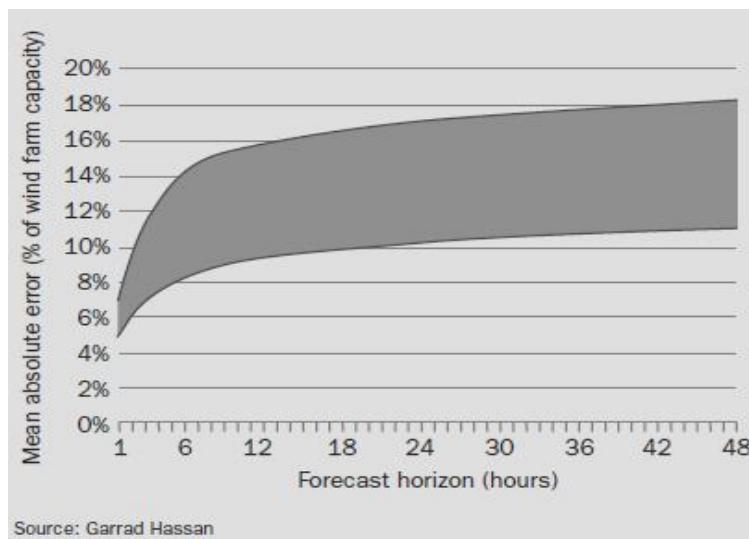


Figura 5.10: NMAE esperado para modelos propuestos por empresas que prestan servicio de predicción de potencia [33]

5.6 Discusión de Resultados

A través de la información contenida en la Figura 5.9 y la Tabla 5.2 es posible concluir que el método de predicción basado en regularización tiene un desempeño mejor que el método simple. El error medio absoluto de predicción del método basado en regularización es más bajo que el del método simple desde los seis pasos en adelante. Considerando que la predicción está pensada para el día siguiente, el hecho de que la predicción con el método basado en regularización sea peor que el simple en las primeras cinco horas es irrelevante para el problema.

Llama la atención que la predicción de un paso no es la que obtiene el MAE mínimo, esto se debe probablemente a que el modelo de predicción de velocidad de viento de la DGAC no está optimizado para entregar predicciones a muy corto plazo.

La Tabla 5.2 muestra que la predicción utilizando el método basado en regularización mejora todos los índices de error, con lo que queda claro que este método tiene mejor desempeño que el método simple.

La Figura 5.9 muestra, para método de predicción basado en regularización, que hay una periodicidad en el MAE. El periodo es de seis horas y corresponde a la frecuencia con que la DGAC entrega sus predicciones. Esto sugiere que si las predicciones fuesen entregadas con mayor frecuencia, el MAE podría situarse en los mínimos locales, cerca del 11%. Otra conclusión que se puede extraer de esta figura es que el error de predicción no tiene un crecimiento sostenido a medida que crece el horizonte de predicción sino que mantiene una media relativamente constante.

Al comparar los resultados obtenidos para el NMAE en la Figura 5.9 y el rendimiento de los modelos de empresas que prestan el servicio de predicción, se observa que el método presentado en esta memoria está a la par de los mejores modelos, situando los resultados en la parte baja de la banda gris. Esto valida que el método utilizado puede ser implementada a lo menos en el Parque Eólico Canela. Se sugiere hacer pruebas con un mayor número de datos y también utilizar el método en otro parque eólico e incluso en una agregación de parques.

Capítulo 6

6.1 Conclusiones Generales

En este trabajo se han implementado una variedad de estructuras de modelos de predicción de potencia para el Parque Eólico Canela con resultados satisfactorios. En el caso de los modelos lineales implementados el error cuadrático medio es cercano al 12% mientras que para el modelo no lineal, la red neuronal MLP, este índice es cercano al 7%. Los resultados han sido validados en datos reales que no se han utilizado en la fase de estimación de parámetros. Se ha logrado caracterizar la totalidad del parque en un modelo simple y robusto que permite trabajar el estudio del intervalo de confianza.

Se ha implementado una metodología nueva para el estudio de la predicción de la potencia y su intervalo de confianza. A través de las predicciones de velocidad de viento entregadas por la DGAC y el estudio del error de predicción de ésta, se ha logrado mejorar la predicción simple, que corresponde a utilizar directamente como entrada del modelo la predicción de velocidad del viento entregada de la DGAC, en cerca de 2,5% para el error medio absoluto, y en un 4% para el error cuadrático medio. Además, el error medio de la predicción con intervalo de confianza es muy cercano al 0%, comparado con el -7,5% que presenta el método simple.

Se ha comprobado que la predicción entregada con la nueva metodología tiene resultados comparables con los mejores modelos de predicción desarrollados por empresas que prestan el servicio de predicción de potencia para parques eólico, con un error medio absoluto de 11,7%.

En el horizonte tiempo estudiado no se detecta que haya un crecimiento sostenido del error de predicción, por el contrario, éste se mantiene constante.

La metodología es simple y computacionalmente liviana. Se requieren menos de 10 segundos para obtener una predicción de potencia para las próximas 36 horas.

6.2 Conclusiones Específicas

Se ha implementado un modelo de referencia nuevo que tiene un error cuadrático medio de un 18%. El objetivo de este modelo es poder compararlo luego con los modelos implementados.

De los modelos lineales que se han presentado, el que ha obtenido un mejor desempeño es el del tipo ARX con 3 parámetros. El error cuadrático medio de este modelo es de un 12%. Los modelos lineales en general, presentan problemas cuando la velocidad del viento es baja y alta, mientras que funcionan mejor cuando las velocidad son medias, en donde es posible aproximar la curva de viento-potencia por una recta. La mejora de este modelo con respecto al modelo de referencia es de un 25% para el error cuadrático medio.

El modelo no lineal MLP es que presenta mejores resultados dentro de todos los modelos, su error cuadrático medio es de un 7%. Además, presenta mejores sustanciales en todas las otras medidas de error. El modelo es capaz de predecir con bastante precisión para velocidades de viento en todos los rangos. La mejora con respecto al modelo de referencia es de un 62% para el error cuadrático medio.

Se ha hecho un estudio de error de predicción entregado por la DGAC. Se han calculado histogramas del error dependiente de la velocidad de viento predicha y el horizonte de tiempo para el cual se hizo la predicción. Utilizando técnicas estadísticas basadas en kernels, se ha logrado regularizar la función de distribución acumulada necesaria para incorporar el error a las predicciones de velocidad de viento. Con esto, se han hecho simulaciones de Monte Carlo en donde la predicción de la potencia es el valor esperado de las salidas producto de las simulaciones.

El intervalo de confianza creado en las predicciones ha sido validado con los datos de potencia real que caen al interior del intervalo. Para un intervalo de confianza teórico de un 95%, se logró un porcentaje de aciertos de más de un 93%.

6.3 Líneas de Investigación futuras

Dentro de las líneas de investigación futura se proponen los siguientes ítems:

- Desarrollo de modelo de predicción que incorpore otras variables de entrada tales como la densidad del aire, la temperatura, presión, etc.
- Estudiar cómo se comporta el modelo cuando hay eventos climáticos tales como la lluvia. Con esto se pueden hacer correcciones al valor esperado de la velocidad del viento.
- Además del parque Canela I, aplicar la metodología presentada en el parque Canela II y evaluar el resultado de los parques agregados. Es interesante también, agregar los demás parques en la zona.
- Crear realizaciones de la predicción de velocidad del viento que tengan una distribución estadística similar a la velocidad del viento real. Con esto es posible utilizar modelos más complejos que incorporen retardos en las variables de entrada y salida.
- Generalizar la metodología para casos de más variables, en donde se reciba como entrada predicciones.

Referencias

- [1] Energía en Movimiento. Comisión Nacional de Energía (CNE). Gobierno de Chile
- [2] Ley 20.257, Biblioteca del Congreso Nacional de Chile
- [3] Global Wind 2008 Report, GWEC, p.3-16
- [4] Manual de Procedimientos MP-12: Programación de Corto Plazo o Programa Diario. CDEC
- [5] Introducción a las Energías Renovables No Convencionales (ERNC). Wilfredo Jara Tirapegui
- [6] “Declaración de Impacto Ambiental, Parque Eólico Canela I”, pp.3-7 y “Declaración de Impacto Ambiental, Parque Eólico Canela II”, pp.3-10
- [7] Wind Energy – The Facts – Part I, Technology, Garrad Hassan p.38
- [8] V82 – 1,65 MW, Vestas, Vestas Wind Systems A/S
- [9] R. Stull, “Meteorology for Scientist and Engineers”, Second Edition, pp. 181-186
- [10]http://boost.ez2learn.com/libs/math/doc/sf_and_dist/html/math_toolkit/dist/dist_ref/dists/weibull.html
- [11] M. Lei, L. Shiyan, J. Chuanwen, L. Hongling, Z. Yan, “A review on the forecasting of wind speed and generated power”, Renewable and Sustainable Energy Reviews 13 (2009), pp. 915-920
- [12] L. Landberg, “A Mathematical Look at a Physical Power Prediction Model” (1998).
- [13] R. Kavasseri, K. Seetharaman, “Day-ahead wind speed forecasting using f-ARIMA models”. Renewable Energy (2009), pp. 1388-1393.
- [14] P. Louka, G. Galanis, N. Siebert, G. Kariniotakis, P. Katsafados, I. Pytharoulis, G. Kallos, “Improvements in wind speed forecasts for wind power purposes using Kalman filtering”, Journal of Wind Engineering and Industrial Aerodynamics 96 (2008), pp. 2348– 2362.
- [15] A. Öztopal, “Artificial neural network approach to spatial estimation of wind velocity data”, Energy Conversion and Management 47 (2006), pp. 395-406.
- [16] Li G, Shi J. “On comparing three artificial neural networks for wind speed forecasting. Appl Energy (2010), doi: 10.1016/j.apenergy.2009.12.013.
- [17] I. J. Ramirez-Rosado, L. A. Fernández-Jiménez, C. Monteiro, J. Sousa, R. Bessa, “Comparison of two new short-term wind-power forecasting systems”, Renewable Energy 34 (2009), pp. 1848-1854.
- [18] M. C. Mabel, E. Fernández, “Analysis of wind power generation and prediction using ANN: A case study”, Renewable Energy 33 (2008), pp. 986-992.
- [19] A. Ceña et al. “Ejercicio de Predicción”, Asociación Empresarial Eólica, Diciembre de 2006.
- [20] <http://www.wind-energy-the-facts.org/en/part-2-grid-integration/chapter-2-wind-power-variability-and-impacts-on-power-systems/>
- [21] M. Norgaard, “Neural Networks for Modelling and Control of Dynamic Systems”, Springer-Verlag London Limited 2000.
- [22] L. Ljung, “System Identification: Theory for the User”, PTR Prentice Hall, Inc., 1987.
- [23] L. Ljung, “System Identification Toolbox”, User’s Guide, MathWorks, Inc., 2008.
- [24] H. Madsen et al, “A protocol for Standardizing the Performance Evaluation of Short-Term Wind Power Prediction Models”, Project ANEMOS, 2002.
- [25] P. Estévez, EM753, “Apuntes Teoría de Redes Neuronales”, Dpto. Ing. Eléctrica, U. de Chile, 2009.

- [26] http://es.wikipedia.org/wiki/Red_neuronal_artificial
- [27] G. González, EM717, “Apuntes Identificación de Sistemas”, Dpto. Ing. Eléctrica, U. de Chile, 2008.
- [28] T.S. Nielsen, A. Joensen, H. Madsen, L. Landberg, and G. Giebel. “A new reference model for wind power forecasting. Wind Energy. 1:29-34, 1998.
- [29] G. Bustos, “Caracterización, Modelación y Simulación de un Generador Eólico de Velocidad Fija”, Tesis de Magíster, Dpto. Ing. Eléctrica, U. de Chile, 2009.
- [30] M. Orchard, “On-line Fault Diagnosis and Failure Prognosis Using Particle Filters. Theoretical Framework and Case Studies”, Publisher: VDM Verlag Dr. Müller Aktiengesellschaft & Co. KG, Saarbrücken, Germany, April 2009, 108 pages.
- [31] C. Musso, N. Oudjane, F. Le Gland, “Improving Regularised Particle Filters”, in Sequencial Monte Carlo Methods in Practice, A. Doucet, N. de Freitas, and N. Gordon, Eds. New York: Springer-Verlag, 2001.
- [32] P. Pinson, “Estimation of the uncertainty in wind power forecasting”, 2006, pp. 73-74.
- [33] P. Gardner et al, Wind Energy- The Facts, “Technology”, Part I.
- [34] H. Demuth, M. Beale, M. Hagan, “Neural Network Toolbox 6”, User’s Guide, MathWorks, Inc., 2009.

Anexo A

Este anexo describe las principales fuerzas que modelan el comportamiento atmosférico global, siendo por tanto una extensión del Capítulo 2.5.1. Además se muestra el perfil vertical de la velocidad del viento.

Las principales fuerzas involucradas son:

A.1 Fuerza de Advección

El viento puede empujar distintos tipos de viento, distinta temperatura, humedad y momento, lo que produce cambios en el viento mismo. La advección no es precisamente una fuerza pero produce los mismos efectos.

$$\frac{\vec{F}_{AD}}{m} = -\vec{V} \cdot \nabla \vec{V}$$

A.2 Fuerza de Gradiente de Presión

La fuerza de gradiente de presión actúa siempre perpendicular a las isóbaras. Esta fuerza empuja el viento desde zonas de mayor a menor presión.

$$\frac{\vec{F}_{PG}}{m} = -\frac{1}{\rho} \nabla P$$

En donde ρ es la densidad del aire y P es la presión atmosférica.

A.3 Fuerza de Coriolis

La fuerza de Coriolis es una fuerza aparente que aparece con la rotación de la Tierra, ésta no puede hacer que el viento sople por sí mismo, pero una vez que hay viento, lo hace cambiar de dirección.

$$\frac{\vec{F}_{CF}}{m} = s \cdot (2\Omega \sin(\phi)) \cdot \vec{V}$$

En donde $s=1$ para V_x y $s=-1$ para V_y , $2\Omega = 1,458 \cdot 10^{-4} [\text{s}^{-1}]$, y ϕ es la latitud.

A.4 Fuerza de Arrastre Turbulento

En la capa límite, el viento sufre un arrastre contra la superficie de la Tierra en una dirección opuesta a la velocidad del viento.

$$\frac{\vec{F}_{TD}}{m} = -\omega_T \cdot \frac{\vec{V}}{z}$$

En donde z es la altura desde la superficie de la Tierra y ω_T es:

$$\omega_T = 1,83 \cdot 10^{-3} \cdot \omega_B$$

En donde ω_B es la velocidad de flotabilidad (siempre positiva).

A.5 Perfil Vertical

El perfil vertical del viento describe el comportamiento de la velocidad del viento en el eje z y está descrito por A.1 [9]:

(A.1)

$$\frac{V(z_2)}{V(z_1)} = \left(\frac{z_2}{z_1}\right)^H$$

En donde $V(z_i)$ es la velocidad del viento a la altura z_i y H es un coeficiente que está en el rango $\{0,1 - 0,6\}$.

Anexo B

Este anexo muestra el coeficiente de correlación a_k entre la potencia y la potencia retardada. Este coeficiente se muestra en la Figura B.1.

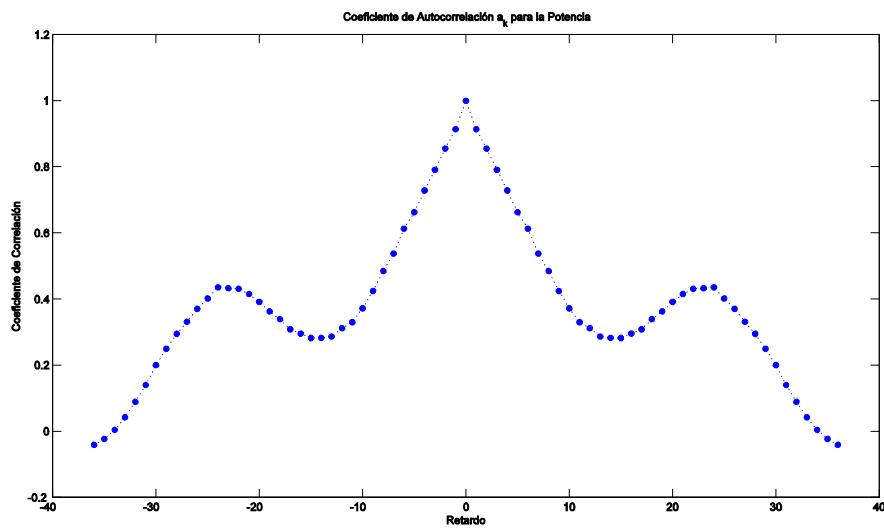


Figura B.1

Anexo C

Este anexo muestra el método de entrenamiento para redes neuronales de Levenberg-Marquardt [34].

El algoritmo de Levenberg-Marquardt está diseñado para realizar un entrenamiento de segundo orden aproximando la matriz Hessiana. Cuando la función de performance es el MSE (*Mean Square Error*), entonces se definen los siguientes valores:

- $H=J^T J$ (H matriz Hessiana, J es matriz Jacobiana)
- $g=J^T e$ (g gradiente, e error)

La actualización de pesos se hace según:

(C.1)

$$w_{k+1} = w_k - [J^T J + \mu I]^{-1} J^T e$$

El parámetro adaptivo en este tipo de entrenamiento es μ . Cuando este valor es cercano a cero, entonces el método es bastante rápido cuando se está cerca de un óptimo. Cuando μ es grande tiende a parecerse al algoritmo de gradiente descendente con un paso pequeño. El algoritmo se usa primero utilizando un μ grande y éste luego se disminuye. Lo anterior para buscar primero dónde están los óptimos y luego acercárseles de manera rápida.

Anexo D

Este anexo muestra la configuración y los pesos de la red neuronal MLP desarrollada en el Capítulo 5 e implementada en el Capítulo 6.

La información de la red neuronal se muestra a continuación:

D.1 Arquitectura de Red Neuronal

La arquitectura de la red neuronal desarrollada en el Capítulo 4 se muestra a continuación.

```
net_b =  
  
Neural Network object:  
  
architecture:  
  
    numInputs: 1  
    numLayers: 2  
    biasConnect: [1; 1]  
    inputConnect: [1; 0]  
    layerConnect: [0 0; 1 0]  
    outputConnect: [0 1]  
  
        numOutputs: 1 (read-only)  
        numInputDelays: 0 (read-only)  
        numLayerDelays: 0 (read-only)  
  
subobject structures:  
  
    inputs: {1x1 cell} of inputs  
    layers: {2x1 cell} of layers  
    outputs: {1x2 cell} containing 1 output  
    biases: {2x1 cell} containing 2 biases  
    inputWeights: {2x1 cell} containing 1 input weight  
    layerWeights: {2x2 cell} containing 1 layer weight  
  
functions:  
  
    adaptFcn: 'trains'  
    divideFcn: 'dividerand'  
    gradientFcn: 'calcjx'  
    initFcn: 'initlay'  
    performFcn: 'mse'  
    trainFcn: 'trainlm'  
  
parameters:  
  
    adaptParam: .passes  
    divideParam: .trainRatio, .valRatio, .testRatio  
    gradientParam: (none)  
    initParam: (none)  
    performParam: (none)
```

```

trainParam: .epochs, .goal, .max_fail, .mem_reduc,
            .min_grad, .mu, .mu_dec, .mu_inc,
            .mu_max, .show, .time

weight and bias values:

IW: {2x1 cell} containing 1 input weight matrix
LW: {2x2 cell} containing 1 layer weight matrix
b: {2x1 cell} containing 2 bias vectors

other:

userdata: (user information)

```

D.2 Pesos de Red Neuronal

Los pesos de la red neuronal desarrollada en el Capítulo 4 se muestran en las Tablas D.1, D.2, D.3 y D.4.

Tabla D.1

| IW |
|-------|
| 5,11 |
| -4,18 |
| 3,19 |
| -3,71 |
| 3,69 |

Tabla D.2

| | | | | | |
|----|------|-------|------|-------|-------|
| LW | 0,32 | -0,01 | 0,40 | -0,22 | -0,90 |
|----|------|-------|------|-------|-------|

Tabla D.3

| | |
|--------|-------|
| b{1,1} | -2,54 |
| | 2,65 |

| | |
|--|-------|
| | -0,45 |
| | -0,80 |
| | 4,66 |

Tabla D.4

| | |
|---------------|------|
| b{2,1} | 0,82 |
|---------------|------|

Anexo E

En este anexo se muestran otros ejemplos de histogramas de error de predicción en función de la predicción de velocidad de viento y el horizonte de predicción.

La Figura E.1 muestra el histograma del error para las predicciones de velocidad de viento que están entre 10 y 11 m/s en un horizonte de entre 13 y 18 horas.

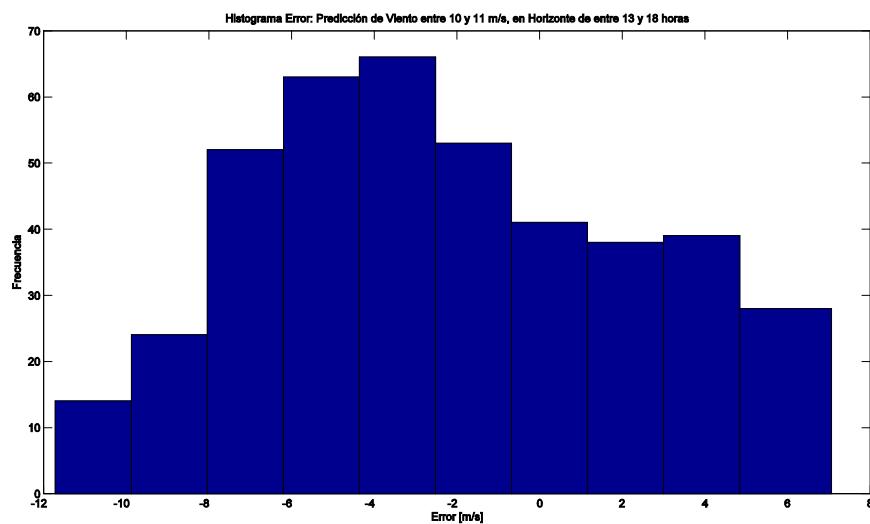


Figura E.1

La Figura E.2 muestra el histograma del error para las predicciones de velocidad de viento que están entre 10 y 11 m/s en un horizonte de entre 31 y 36 horas.

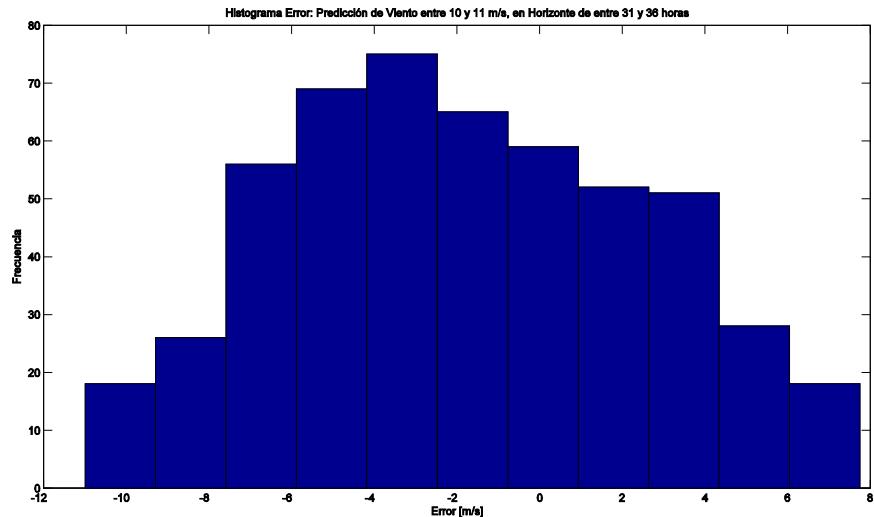


Figura E.2

La Figura E.3 muestra el histograma del error para las predicciones de velocidad de viento que están entre 8 y 9 m/s en un horizonte de entre 13 y 18 horas.

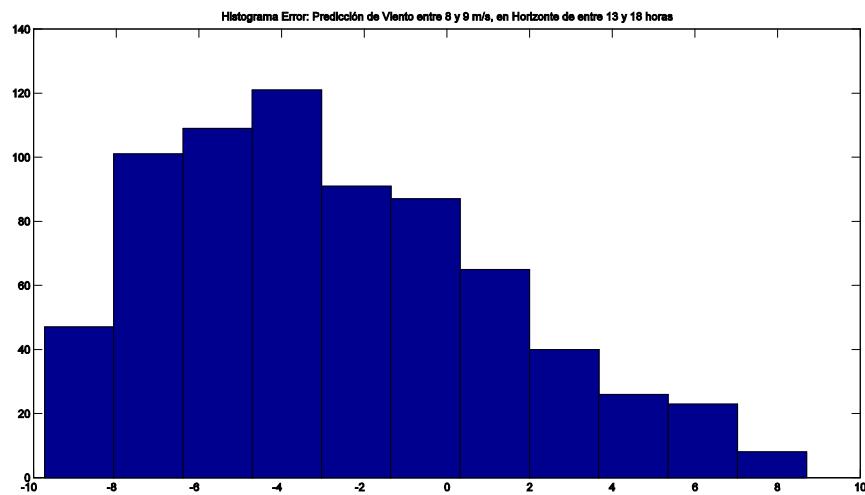


Figura E.3

La Figura E.3 muestra el histograma del error para las predicciones de velocidad de viento que están entre 8 y 9 m/s en un horizonte de entre 31 y 36 horas.

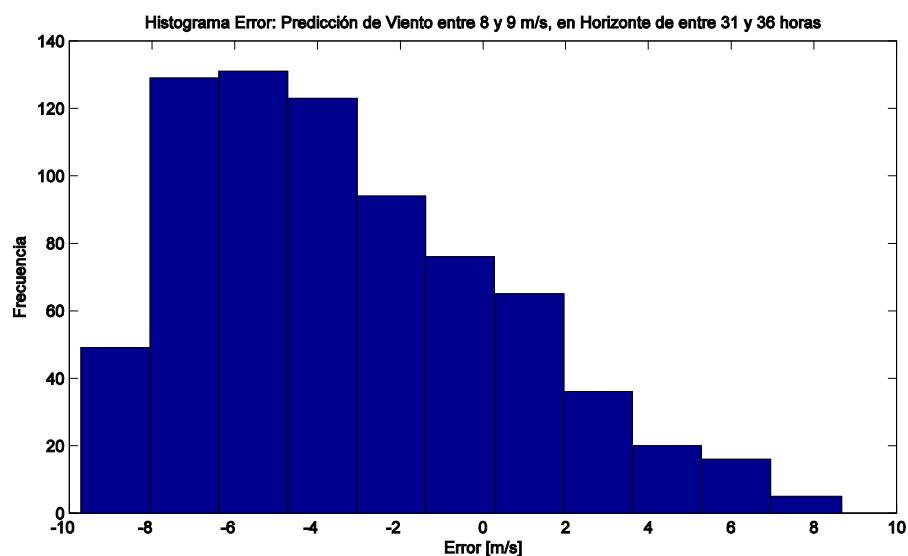


Figura E.4

Anexo F

En este anexo se muestran otros ejemplos de funciones de distribución acumulada empírica comparada con funciones de distribución acumulada regularizada.

La Figura F.1 muestra una comparación de FDA para una predicción de velocidad del viento de entre 7 y 8 m/s para un horizonte de predicción de entre 13 y 18 horas.

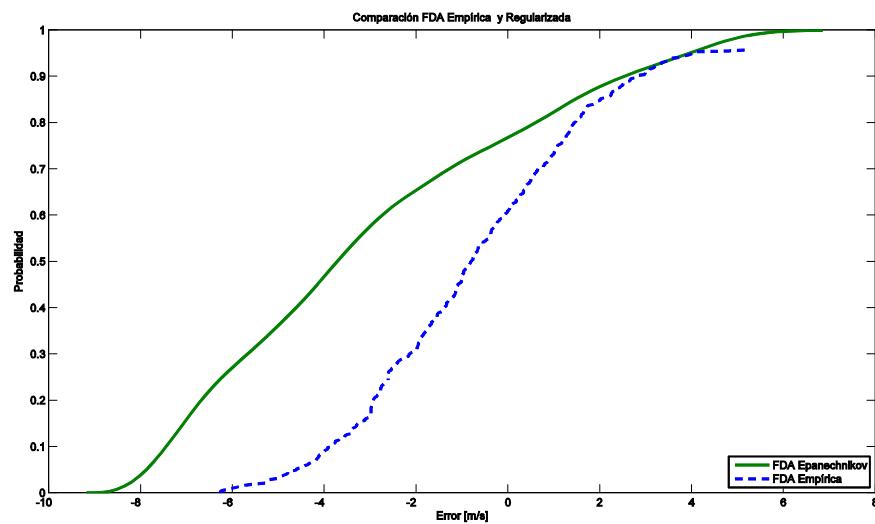


Figura F.1

La Figura F.2 muestra una comparación de FDA para una predicción de velocidad del viento de entre 14 y 15 m/s para un horizonte de predicción de entre 13 y 18 horas.

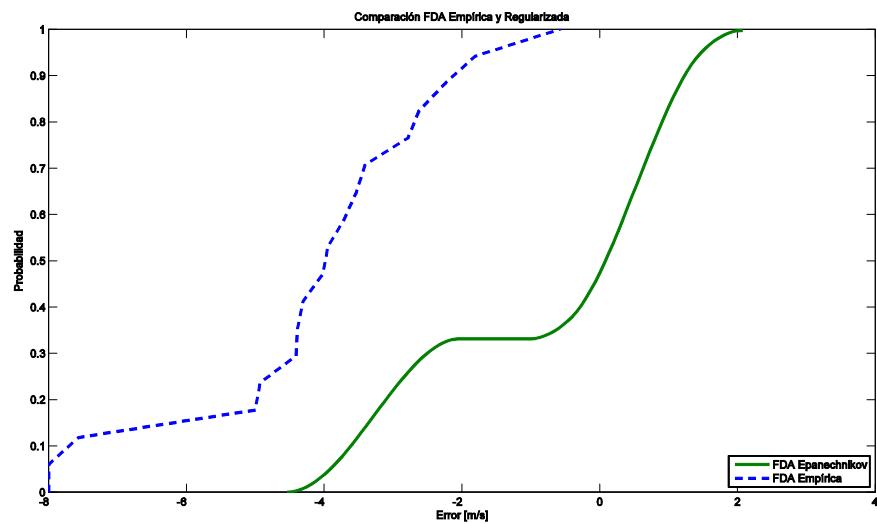


Figura F.2