

Machine Learning, Inteligencia Artificial y Big Data

Lo que todo directivo debe saber

www.asociaciondedirectivos.org

Con la colaboración de:

ÍNDICE

CAPÍTULO	PÁGINA
Presentación	4
01_ Estadística, Data Mining, Analytics y Machine Learning: un poco de historia	5
01.1_ ¿En qué consiste el Machine Learning?	6
01.2_ ¿Por qué funcionan los algoritmos de Machine Learning?	8
02_ Machine Learning & Big Data: más allá de la moda	10
03_ ¿Cómo asegurar que la inversión en Machine Learning y Big Data sea altamente rentable?	14
04_ Requisitos para obtener valor diferencial	17
05_ Los nuevos profesionales	20
06_ Conclusiones	21
07_ Glosario	23
08_ Bibliografía	25
09_ Sobre los autores	26



PRESENTACIÓN

La irrupción de nuevas tecnologías aplicadas al análisis de datos puede arrastrar a las empresas a una sensación de vértigo. No hay motivo real para que ello ocurra. Las empresas vienen usando información para optimizar sus resultados desde muchas décadas atrás, si bien es cierto que los procesos están ganando en complejidad: es posible recoger muchos más datos y más variados en un espacio de tiempo sensiblemente menor. Esta dinámica obligará a los directivos a tomar decisiones en tiempo real y predecir un nuevo escenario al que ningún profesional podrá permanecer ajeno.

Nuestro propósito es que este informe sea un instrumento útil para los directivos a la hora de enfrentarse a los retos que plantea la Inteligencia Artificial y que puedan obtener el máximo valor para el negocio a partir de las herramientas que esta nueva tecnología nos proporciona. También pretende indicar, a través de una serie de recomendaciones y consejos, cómo hacer un uso eficiente de las mismas, consiguiendo un rendimiento óptimo desde el punto de vista de la gestión del negocio.

El primer capítulo de este documento hace un repaso a cómo las empresas, históricamente y en los años recientes, han utilizado información y datos para mejorar sus objetivos comerciales. Asimismo, hace referencia a la evolución de la aplicación de estos datos: cómo pasaron de ser meros registros, a utilizarse para mejorar el negocio.

Seguidamente, los autores explican mediante experiencias reales las fórmulas más acertadas para que la organización haga un uso eficiente de la tecnología Big Data y el Machine Learning. También se advierte que la acumulación masiva de datos no proporciona, por sí misma, ningún beneficio para la empresa: el directivo debe decidir qué datos interesan realmente y descartar aquellos que no aportan valor. Con esta finalidad, el presente informe recopila también algunas recomendaciones para llevar a cabo una aplicación eficiente del sistema Big Data y del Machine Learning, así como los requisitos que se precisan para que la implantación de ambas tecnologías sea exitosa y aporte valor añadido al negocio.

Los perfiles -técnicos y directivos- que se necesitan para desarrollar una solución de Machine Learning constituyen, igualmente, un aspecto fundamental para garantizar el éxito del sistema. El documento recoge las *skills* más importantes que deben tener ambos perfiles para un buen uso de esta tecnología.

El cierre del informe "Machine Learning, Inteligencia Artificial y Big Data. Lo que todo directivo debe saber" lo protagonizan las conclusiones que pueden extraerse del documento, evidenciando que la aplicación de una solución de Big Data y Machine Learning es completamente necesaria para el negocio.

Xavier Gangonells
Director general de AED

Como expertos en minería de datos y aprendizaje automático, hemos tenido que explicar a profesionales de otras disciplinas, en numerosas situaciones, en qué consisten estos conceptos y cómo podrían incorporarlos en sus compañías. Con este artículo esperamos haberlo logrado: conectar con el negocio y hablar su mismo idioma es nuestra especialidad.

Nuestro objetivo es acercar la experiencia que atesoramos a los responsables de áreas de negocio con inquietudes similares; ayudarles ante la difícil tesitura de tener que decidir cómo llevar a cabo la transformación digital de sus compañías en la que se ha vuelto indispensable incorporar el aprendizaje automático en sus procesos y decisiones.

1. ESTADÍSTICA, DATA MINING, ANALYTICS Y MACHINE LEARNING: UN POCO DE HISTORIA

Al principio eran datos y, después, su análisis e interpretación. Un ordenador de mesa, herramientas estadísticas, reportes básicos y un grupo de expertos era suficiente para tomar decisiones operativas. Los directores de Marketing y planificadores de la demanda, para anticipar el volumen de ventas del siguiente trimestre o el impacto que tendría una nueva promoción, únicamente se valían de informes mensuales que confirmasen su intuición.

Así, el uso de los datos se circunscribía únicamente al ámbito en el que eran creados: las ventas históricas explicaban las futuras, el tiempo previsto determinaba si era conveniente abrigarse o salir con paraguas y las reclamaciones de garantías se utilizaban para reembolsar a los agentes responsables de la reparación de productos.

Con el tiempo, los datos capturados se multiplican y el fin deja de ser puramente

transaccional. Ya no se trata solo de los reportes de las ventas del último mes por tienda y SKU (código de artículo), sino que es indispensable conocer las ventas de ayer por SKU, tienda y cliente. Y no solo eso: quién es mi cliente, con qué frecuencia compra, qué anuncios le agradan, dónde vive y cuántos hijos tiene. Y aún más: qué tiempo hacía cuando realizó la compra y cómo circulaba el tráfico por las carreteras. Y también: a qué precio vendían los competidores un producto similar y qué promociones estaban disponibles.

En definitiva, los datos dejan de ser un puro registro y reflejo de las actividades de negocio para interrelacionarse e interconectarse; mientras, el tiempo adquiere una nueva dimensión: prima la inmediatez en la toma de decisiones. El director de Ventas ya no solicita un informe mensual. Quiere saber qué promoción lanzar y sobre qué producto, qué estrategia usar y durante cuánto tiempo.

Después, en el menor tiempo posible, querrá medir el impacto y la respuesta de los consumidores.

La conjunción tiempo, información y expectativas de los clientes exige un enfoque más allá de un grupo de expertos que toman decisiones en base a su experiencia e intuición. Ya no alcanza la potencia de un ordenador de mesa y ni siquiera la de un servidor para procesar los grandes volúmenes de información. Ya no solo gestionamos datos estructurados como nombres, volúmenes de venta y fechas; la información se capture en comentarios de texto por parte de clientes o perfiles técnicos, mediante mensajes grabados, imágenes y vídeos que es indispensable interpretar. En dos palabras: Big Data.

La definición de Big Data no puede limitarse a su simple traducción literal como "grandes datos". Tiene un alcance superior y podríamos sintetizarlo en las 3 V que los definen.

“Los datos dejan de ser un puro registro y reflejo de las actividades de negocio para interrelacionarse e interconectarse; mientras, el tiempo adquiere una nueva dimensión: prima la inmediatez en la toma de decisiones”



Las 3 V del Big Data

- Velocidad: rapidez en el almacenamiento, transmisión y procesamiento.
- Variedad: tipos (estructurados, sonido, imagen, texto) y fuentes (internas, externas).
- Volumen: cantidad masiva de datos.

Es acompañado de soluciones de Machine Learning cuando Big Data adquiere todo su valor.

1.1 ¿En qué consiste el Machine Learning?

El Machine Learning es una rama de la Inteligencia Artificial enfocada al desarrollo de técnicas que permitan el aprendizaje de las máquinas. Para saber cómo funciona y qué utilidad tiene esta disciplina, a continuación, ilustramos, a través de algunos ejemplos, la importancia del Machine Learning en la productividad de las empresas.

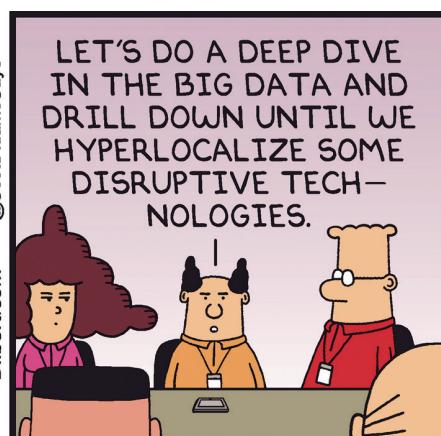
El comportamiento automático

Caso 1: Empresa retail japonesa

La temporada de verano en Japón se ha adelantado unos 10 días. El director de

Ventas de una empresa retail del país sabe que, durante las primeras semanas del periodo estival, el volumen de venta de las camisetas de manga corta supone el 40% del total. Conoce el impacto que tiene el clima, también el del precio y el de los productos de la competencia. Por eso, decide enviar más mercancía a las tiendas.

El año anterior ocurrió precisamente lo contrario: la temporada de verano se inició con temperaturas bajas, por lo que las ventas de un producto similar a las camisetas de manga corta se atrasaron. El director de Ventas decidió potenciar la venta de camisetas de manga larga con una promoción, de modo que consiguió





Los modelos matemáticos

De la misma manera que los expertos aprenden de manera intuitiva y toman la decisión que consideran más adecuada, los modelos matemáticos son capaces de proveer información útil. La simulación de toma de decisiones con datos históricos nos dará el nivel de confianza esperado; de modo que la intuición de los expertos se transforma en datos cuantificados.

En el caso de la empresa retail japonesa, los modelos matemáticos podrían ayudarnos a estimar el volumen de ventas al inicio de la temporada o a ajustar los pronósticos en función del grado de satisfacción reflejado por los clientes en las redes sociales.

En el caso del fabricante de maquinaria agrícola, podrían contribuir a despejar los factores vinculados con el fallo. Podrían estimar si los nuevos componentes superan la ratio de fallos históricos o la magnitud esperada en términos de coste y volumen, teniendo en cuenta los equipos expuestos al riesgo y sus horas de uso. Conociendo las causas, sería más factible encontrar las soluciones.

Ambos son ejemplos de aprendizaje automático sin necesidad de intervención humana: búsqueda de patrones de comportamiento basados en datos históricos para aplicarlos en nuevas situaciones desconocidas.

“El comportamiento automático consiste en utilizar la información histórica almacenada internamente o procedente de fuentes externas y aprender, con el fin de tomar decisiones inteligentes”

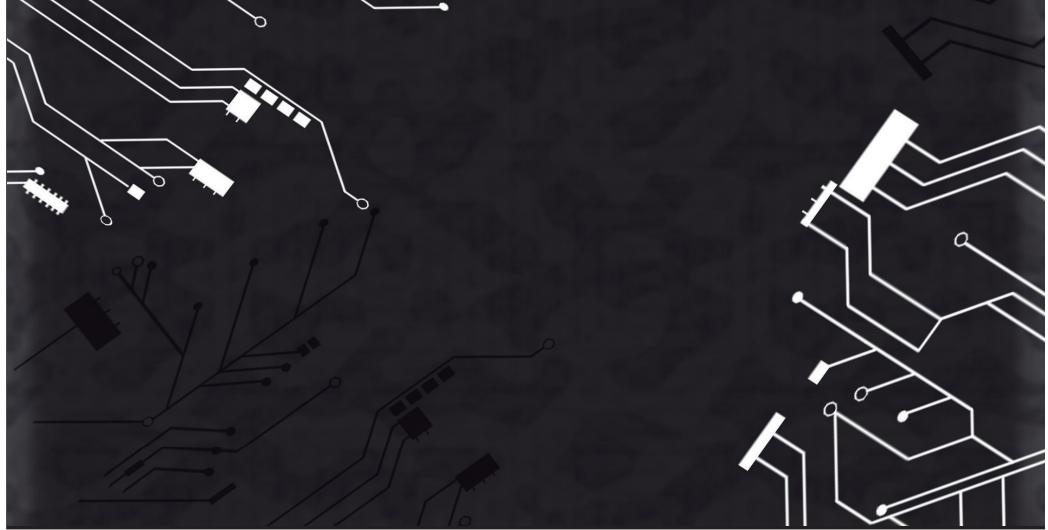
mejorar sus resultados un 20% a la vez que se incrementó la actividad de los clientes en redes sociales con relación a estas prendas.

Caso 2: Planta de fabricación de maquinaria agrícola

El ingeniero de una planta de fabricación de maquinaria agrícola reconoce que los nuevos componentes incorporados en el último modelo de uno de sus productos no se comportan de acuerdo con las expectativas de la compañía.

Cuenta con datos históricos que indican el nivel de fallo de nuevos componentes durante las primeras semanas por tiempo de uso (horas/kilómetros), por piezas de repuesto, clima y geografía. A su vez, conoce las tendencias en términos de costes por máquina y fallos por máquina durante el período de garantía. Desde su experiencia, el nivel de fallos supera el volumen esperado según el tiempo de uso, lo que le lleva a pensar en que está frente a un fallo epidémico emergente.

En ambos casos, tanto el director de Ventas como el ingeniero, nuestros expertos, contaban con conocimientos generados en base a su experiencia. Ambos han desarrollado lo que se conoce como “comportamiento automático”: utilizar la información histórica almacenada internamente o procedente de fuentes externas y aprender con el fin de tomar decisiones inteligentes.



1.2 ¿Por qué funcionan los algoritmos de Machine Learning?

En cualquier proceso analítico, el objetivo principal es extraer información *accionable* del conjunto de datos. Es decir, información objetiva y operacionalmente válida, ya sea para la toma de decisiones o para el control de procesos en tiempo real.

La característica fundamental de los algoritmos de Machine Learning es su extraordinaria capacidad para extraer patrones que se escapan a la mayoría de métodos aplicados históricamente. Además, destaca su versatilidad para trabajar con información gráfica, sonidos o lenguaje natural, entre otros, y de generar resultados de la misma naturaleza. Son altamente eficientes con series de datos complejas y con múltiples escalas o factores de variación.

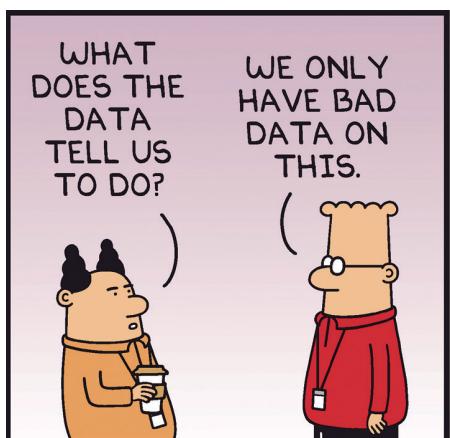
En definitiva, los algoritmos de Machine Learning resultan en gran medida eficaces para abordar problemas de segmentación, clasificación e incluso predicción. Un ejemplo de ello, en una de las áreas en las que, probablemente, vamos a ser testigos de grandes avances, es en la comunicación: tales como los sistemas de recomendación que muchos de nosotros utilizamos habitualmente en tiendas online, apps de agregación de noticias u otras aplicaciones.

Por otro lado, Machine Learning puede contrarrestar de manera eficiente uno de los principales problemas no resueltos en Big Data: el sesgo. Como bien saben los analistas encargados de realizar encuestas electorales, su acierto no solo depende del tamaño de la muestra -de hecho, este suele tener una importancia

bastante relativa-, sino de su correcta estratificación. Y, muy especialmente, de la correcta identificación de las fuentes de variación, así como de los respectivos factores de ponderación.

En este sentido, los algoritmos de Machine Learning son capaces de extraer patrones de variación de manera mucho más eficiente que los considerados "métodos clásicos", basados en la estadística paramétrica. Los algoritmos no asumen ningún tipo de prerequisito previo, ya sea normalidad o potencia de la muestra.

En sectores maduros en los que la operativa empresarial o industrial depende directamente o está estrechamente vinculada con el resultado de algún tipo de modelo predictivo, una mejora signifi-





cativa en dicho resultado en términos de alcance o precisión representa igualmente un impacto económico que hay que valorar. En muchos casos, la aplicación de modelos de Machine Learning constituye una ventaja competitiva relevante a considerar.

Sin embargo, a pesar del inmenso abanico de aplicaciones que ofrece esta tecnología y del avance que supone con respecto al pasado más reciente, estamos todavía lejos de poder confiar ciegamente en ella. Para crear y alimentar las variables que formarán parte de los algoritmos y poder ponderarlas adecuadamente durante el proceso de entrenamiento, aún resulta imprescindible contar con un conocimiento previo del contexto y de las dinámicas de los procesos de negocio. Y no solo eso, sino que, además, algunas de las principales áreas de investigación que se desarrollan en la actualidad son precisamente en el ámbito de los algoritmos semi-supervisados y del Aprendizaje por Refuerzo (Reinforcement Learning), basado en funciones de recompensa.

En resumen, sigue siendo necesario contar con el suficiente conocimiento del negocio, casi tanto como conocimiento y experiencia en el campo de la analítica, para poder identificar qué tipo de algoritmos son los más apropiados en cada caso, en términos de eficiencia, tiempo de cálculo y requerimientos.

Recomendaciones para directivos:

- *La adopción del Machine Learning en ningún caso implica romper con el pasado y empezar de cero, sino que combina toda la experiencia y el conocimiento previo del negocio con los nuevos datos recogidos para que, una vez tratados con los procedimientos adecuados, aporten nueva información más completa y útil.*

“La característica fundamental de los algoritmos de Machine Learning es su extraordinaria capacidad para extraer patrones que se escapan a la mayoría de métodos aplicados históricamente. Además, destaca su versatilidad para trabajar con información diversa”

“Para crear y alimentar las variables que formarán parte de los algoritmos y poder ponderarlas adecuadamente durante el proceso de entrenamiento, aún resulta imprescindible contar con un conocimiento previo del contexto y de las dinámicas de los procesos de negocio.”



2. MACHINE LEARNING & BIG DATA: MÁS ALLÁ DE LA MODA

¿Por dónde empezar? Estudiar casos de empresas que ya han recorrido un primer trecho del camino puede ayudar a orientar la aplicación de esta tecnología en una empresa. Por suerte, varios gigantes tecnológicos han compartido sus primeras experiencias y conclusiones con el resto de la comunidad.

Si bien es cierto que la evolución del conocimiento y el desarrollo tecnológico no suelen seguir procesos lineales, sino que alternan períodos de efervescencia y rápido desarrollo con otros de implementación y despliegue tecnológico, estos años bien podrían considerarse los del Aprendizaje Automático (Machine Learning). Años en los que esta disciplina se incorporó en los planes de desarrollo tecnológico de muchas compañías.

En los últimos tiempos, hemos conocido (y seguiremos conociendo) un gran número de noticias relacionadas con la Inteligencia Artificial y, en concreto con el Machine Learning. Distintas empresas líderes han aprovechado para liberar en la comunidad Open Source (OS) sus respectivos avances en este área.

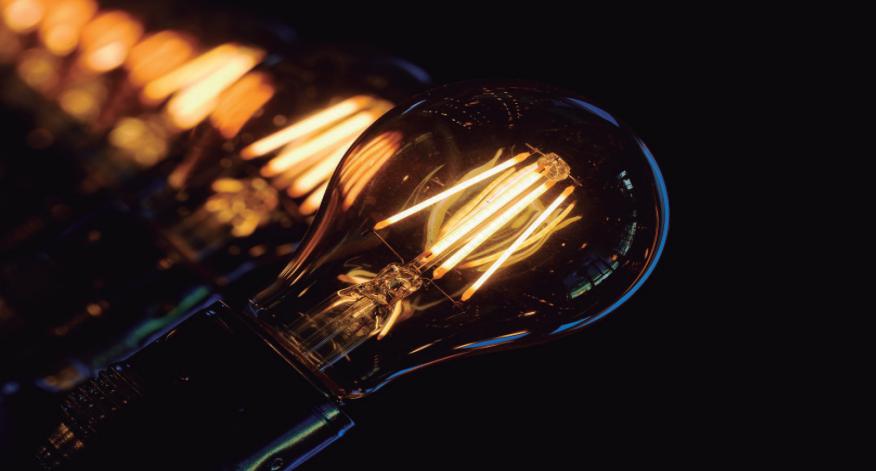
Sin ir más lejos, Google presentó TensorFlow; Microsoft, siempre amante de los cambios de nombre, realizó algo

semejante con MCT (Microsoft Cognitive Toolkit, conocido anteriormente como CNTK); Amazon difundió los últimos avances en MXNet¹ y Facebook presentó no uno sino dos proyectos: Torch y Caffe. Por otro lado, la propia comunidad OS, bajo el paraguas de la Apache Software Foundation, da cobertura a un gran número de iniciativas independientes, tanto a nivel de tecnologías Big Data como en Inteligencia Artificial.

El hecho de liberar el código, aunque sea bajo diferentes tipos de licencia, no hace más que favorecer y alimentar a escala global la investigación por parte de los diferentes grupos de desarrolladores alrededor del mundo, ya pertenezcan a grandes corporaciones o se trate de genios solitarios.

Tampoco resulta excepcional que algunos desarrolladores afiliados a grandes empresas tecnológicas den rienda suelta a su creatividad en su tiempo libre, liderando o, cuanto menos, aportando su granito de arena a algunos de estos proyectos. Sea el caso que sea, la mayoría de licencias OS obligan a los desarrolladores a difundir, asimismo, sus avances y modificaciones, por lo que la masa crítica aumenta exponencialmente acelerando todavía más el proceso.

1. Vogels, W. (2016). MXNet - Deep Learning Framework of Choice at AWS. 2018, de All Things Distributed Sitio web: <https://www.allthingsdistributed.com/2016/11/mxnet-default-framework-deep-learning-aws.html>



¿Por qué ahora?

Una de las preguntas que surgen ante este aluvión de noticias relacionadas con Machine Learning es: ¿por qué su desarrollo y aplicación despuntan precisamente ahora, a pesar de que los fundamentos teóricos de la mayoría de los algoritmos de Inteligencia Artificial y

Machine Learning tienen su origen varias décadas atrás (algunos, incluso, en los años sesenta del siglo pasado)?

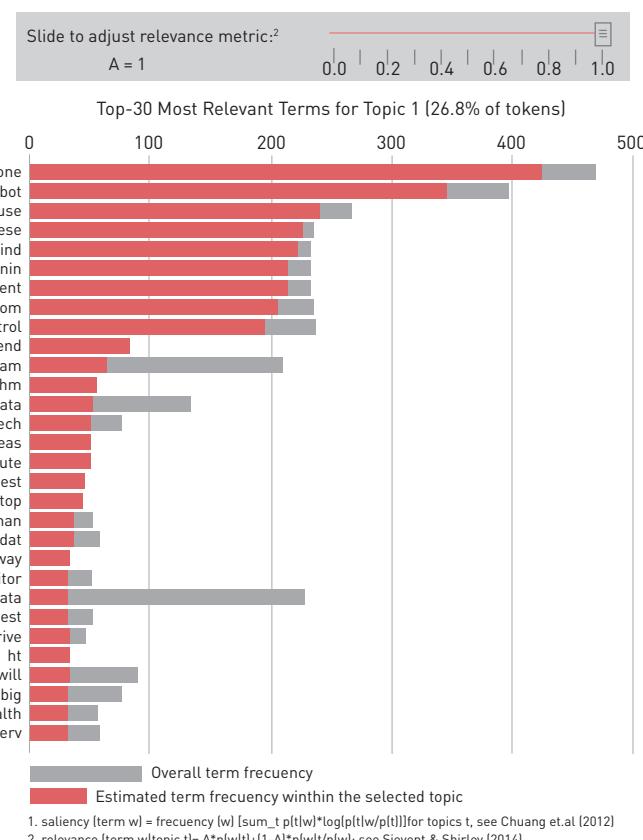
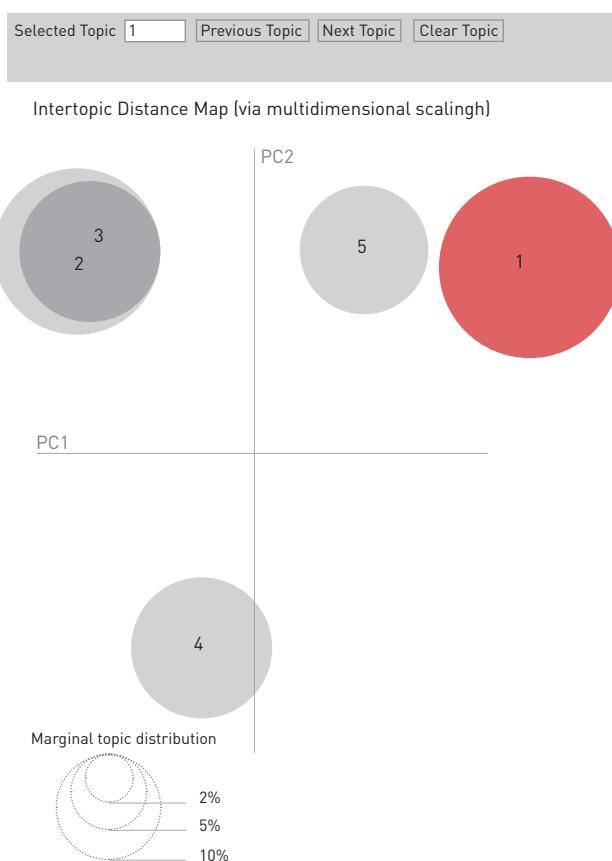
A diferencia de los métodos clásicos basados en la estadística multi-paramétrica, aquella en la que los datos reales responden a distribuciones conocidas, la mayoría de los algoritmos de Machine

Learning requieren grandes volúmenes de datos para entrenar y calibrar los algoritmos, volúmenes mayores en varios órdenes de magnitud que los requeridos para satisfacer los criterios estadísticos y niveles de confianza habituales.

Por otro lado, las herramientas y tecnologías necesarias para manejar actualmente los ingentes volúmenes de datos y la mayoría de los algoritmos de Machine Learning son computacionalmente tan exigentes, tanto, que requieren de uni-

Análisis de Temas de 1.000 tweets sobre Machine Learning

A través de los siguientes gráficos (bajo estas líneas y en la página siguiente) se muestra la relevancia del interés de estos temas objeto del informe, medidos a través de las búsquedas o menciones en diferentes redes sociales



Tema 1: drones / robótica / Deep Learning. Fuente: Elaboración propia



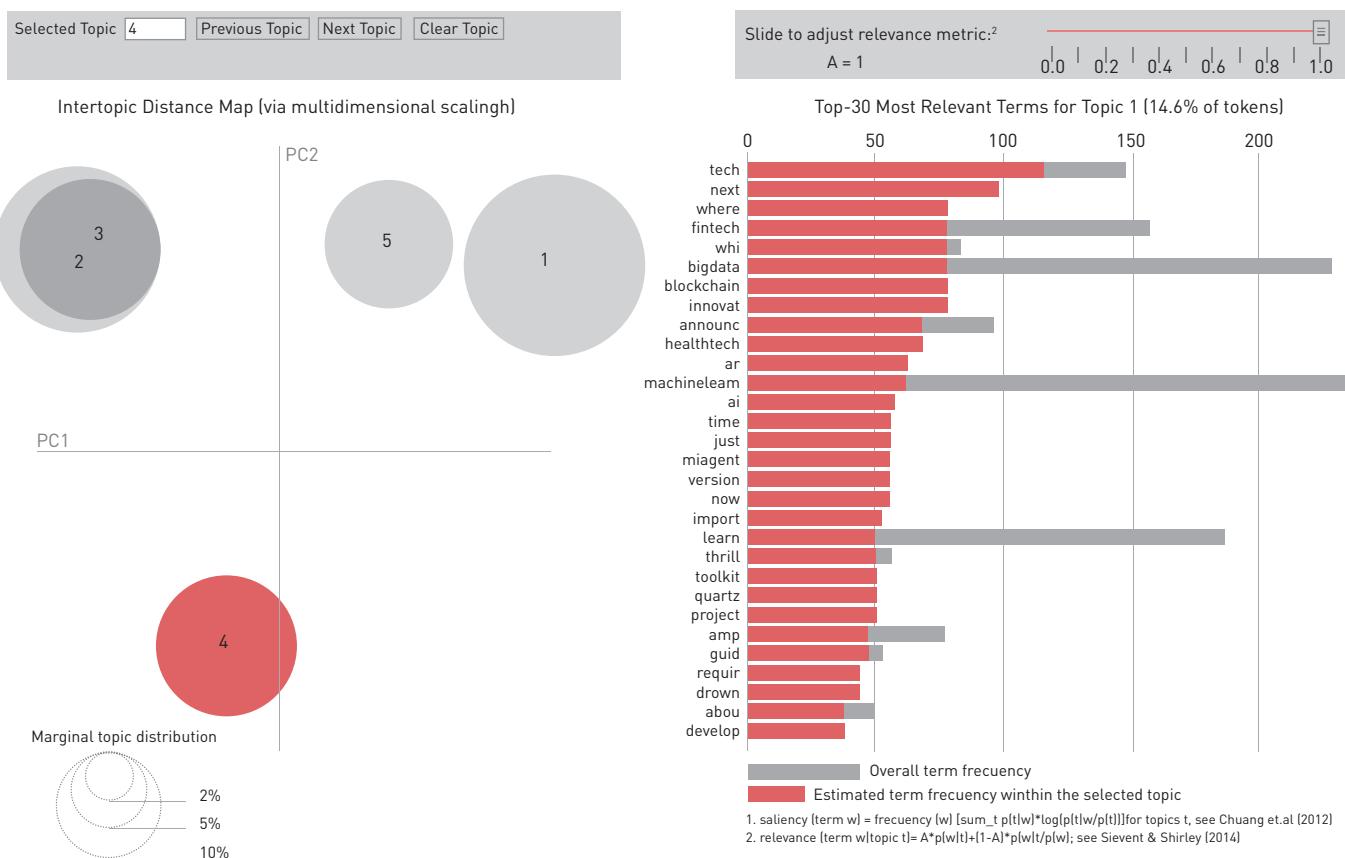
dades de procesamiento especializadas con altísimos niveles de paralelización (GPUs).

Así, las GPUs hace tiempo que dejaron de ser exclusivas de las consolas de videojuegos, de donde provienen, para formar parte no tan solo de las grandes infraestructuras de cálculo y servicios *cloud*, sino también de la mayoría de tarjetas gráficas de altas prestaciones.

Por tanto, los factores desencadenantes del rápido ascenso de las técnicas de Machine Learning son fundamentalmente dos. Por un lado, el desarrollo tecnológico y el acceso a grandes recursos computacionales a un coste asumible, no solo por parte de grandes empresas. En segundo lugar, la disponibilidad de grandes volúmenes de datos, necesarios para entrenar adecuadamente los algoritmos.

En los últimos años se han registrado grandes avances; pero, como cabía esperar, no todo han sido éxitos. Algunos de los fracasos más sonados tienen su origen en un exceso de confianza y, por ende, de falta de supervisión en la aplicación automática de algoritmos.

Sin duda, el desarrollo y aplicación de las técnicas de Inteligencia Artificial seguirán imparables durante los próximos años.



Tema 2: Big Data / blockchain / innovación. Fuente: Elaboración propia



“Los factores desencadenantes del rápido ascenso de las técnicas de Machine Learning son fundamentalmente dos: el desarrollo tecnológico y el acceso a grandes recursos computacionales a un coste asumible, así como la disponibilidad de grandes volúmenes de datos, necesarios para entrenar adecuadamente los algoritmos”

Principalmente, en áreas más especializadas y quizás alejadas de los grandes titulares, áreas en las que los algoritmos puedan resolver problemas de manera realmente efectiva y con un alto grado de precisión.

Solo por nombrar algunos ejemplos conocidos: ciberseguridad, seguridad personal, comercio financiero, cuidado de la salud, marketing personalizado, recomendaciones y búsquedas *on line*. Estos son algunos pocos ejemplos reales, pero hay muchos casos más donde su aplicación con resultados positivos ya es una realidad.

Recomendaciones para directivos:

- *El desarrollo y la aplicación de las técnicas de IA seguirá imparable durante los próximos años. No dejes que tu empresa se quede atrás.*



3. ¿CÓMO ASEGURAR QUE LA INVERSIÓN EN MACHINE LEARNING Y BIG DATA SEA ALTAMENTE RENTABLE?

Algunas empresas tienden a pensar que, a mayor cantidad de datos, o resultados que proporcionan algoritmos, mayor valor añadido. Sin embargo, no se trata de una cuestión de cantidad, sino de la relevancia de los datos disponibles para los objetivos de negocio.

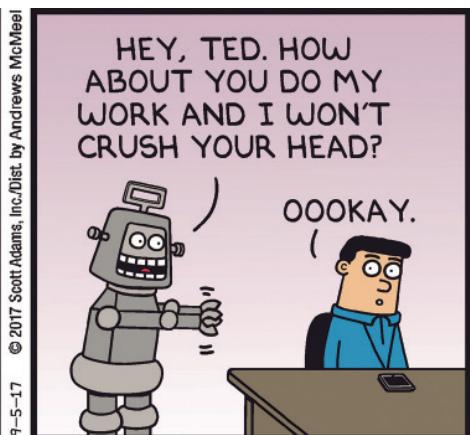
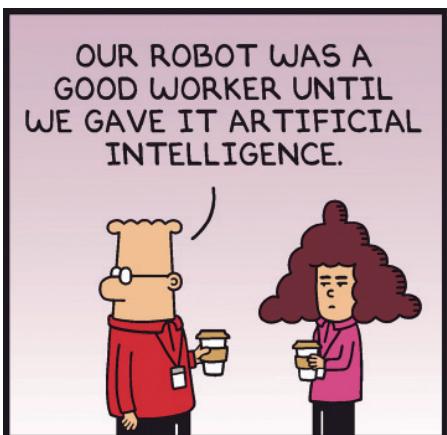
Preguntas, no solo datos (La importancia de un problema de negocio bien definido)

En su famoso libro “La Guía del Autoestopista Galáctico”, Douglas Adams imagina que una civilización muy avanzada crea

un superordenador, “Pensamiento Profundo”, capaz de responder a la eterna cuestión: “¿cuál es el sentido de la vida?”

Tras años procesando la información, la máquina da una respuesta: “42”. La sorpresa de sus creadores es grande, así que deciden preguntarle qué significado tiene ese número. “Pensamiento Profundo” asegura que “42” es la respuesta correcta, pero que el problema reside en la pregunta: ¿cuál es la pregunta correcta?

Esta divertida historia se vuelve anecdótica cuando se traslada al mundo de Machine Learning y Big Data y, más en general, de Analytics.



Es un error común pensar que contar con muchos datos y una o más herramientas que implementan algoritmos de Machine Learning aportan, por sí mismos, valor al negocio.

Pero no hay mayor equivocación: datos y algoritmos tienen valor para el negocio solo en la medida en que pueden dar respuestas diferenciales (es decir, de alto valor añadido) a problemas de negocio. Como en el caso de “Pensamiento Profundo”, las respuestas son útiles si las preguntas están bien formuladas.

Un ejemplo esclarecedor: imaginemos el caso de un fabricante de cerveza que quiere descubrir si la información relativa al tiempo atmosférico puede ayudarle a mejorar su negocio. Decide comprar una plataforma de Big Data para almacenar relevaciones de indicadores atmosféricos a nivel de hora y sección censal y, a la vez, información de consumo de unidades en punto de venta

(asumamos, por un momento, que el fabricante tiene acceso a datos detallados de tickets y al consumo de cerveza de presión a través de sensores). Además, se hace con las mejores aplicaciones de Machine Learning y, simplemente, las conectas a los datos.

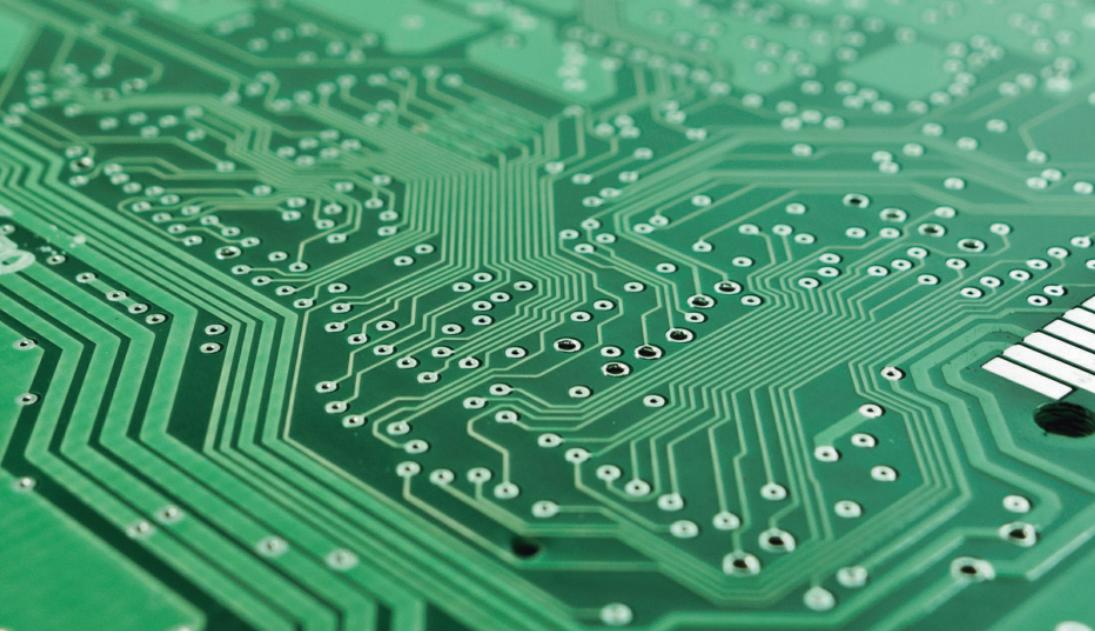
Pero ¿qué consideraciones hay que tener en cuenta para la implantación exitosa de un sistema de Machine Learning y Big Data?“.

1. Verificar la calidad de los datos:

como norma general, antes de usar cualquier tipo de información, hay que verificar la calidad de los datos, así como su consistencia y fiabilidad. Si las relevaciones atmosféricas son imprecisas, los resultados de los algoritmos serán falaces (“Garbage In – Garbage Out”).

2. El Machine Learning no sabe juntar fuentes de información: para la aplicación, todo serán datos sin ninguna connotación semántica. Aparecerán, por un

“Datos y algoritmos tienen valor para el negocio solo en la medida en la cual pueden dar respuestas diferenciales (es decir, de alto valor añadido) a problemas de negocio. Las respuestas son útiles si las preguntas están bien formuladas”



lado, los datos atmosféricos (coordenadas geográficas, fechas y horas, números decimales que representan mililitros de lluvia, etc.) y, por otro, los relativos al producto (códigos, ventas, consumo, etc.). El Machine Learning podría llegar a sugerir a través de qué campos relacionar las diferentes fuentes de información, pero, en general, le faltaría contexto para desempatar entre dos o más opciones que son plausibles.

3. Los algoritmos de Machine Learning **clasifican o predicen variables** que, por sí mismas, no existen en la información base, sino que tienen que ser creadas.

4. Estas **variables irán en función del problema de negocio** que se quiere resolver. En el caso de nuestro ejemplo, hay probablemente dos grupos de preguntas clave:

a. ¿Hay algún tipo de relación entre el tiempo atmosférico y el consumo de cerveza que planteábamos en el ejemplo del apartado anterior? ¿Cuáles son las variables que más influyen (intensidad de precipitaciones, temperatura, intensidad del viento...)? ¿Tienen siempre la misma relevancia o ésta puede variar en función de las características del local, de la geografía, del perfil de cliente...?

b. Una vez entendido cómo todos estos factores influencian el consumo de cerveza, ¿cómo se pueden utilizar para mejorar el negocio? ¿Anticipando el consumo esperado y sugiriendo el pedido de reposición al Local, basándose en las predicciones del tiempo? ¿Identificando patrones de consumo conjunto de productos en función del tiempo atmosférico, de la franja horaria, del precio (real o percibido) que permitan añadir al pedido de reposición productos en promoción que tienen alta probabilidad de ser comprados?

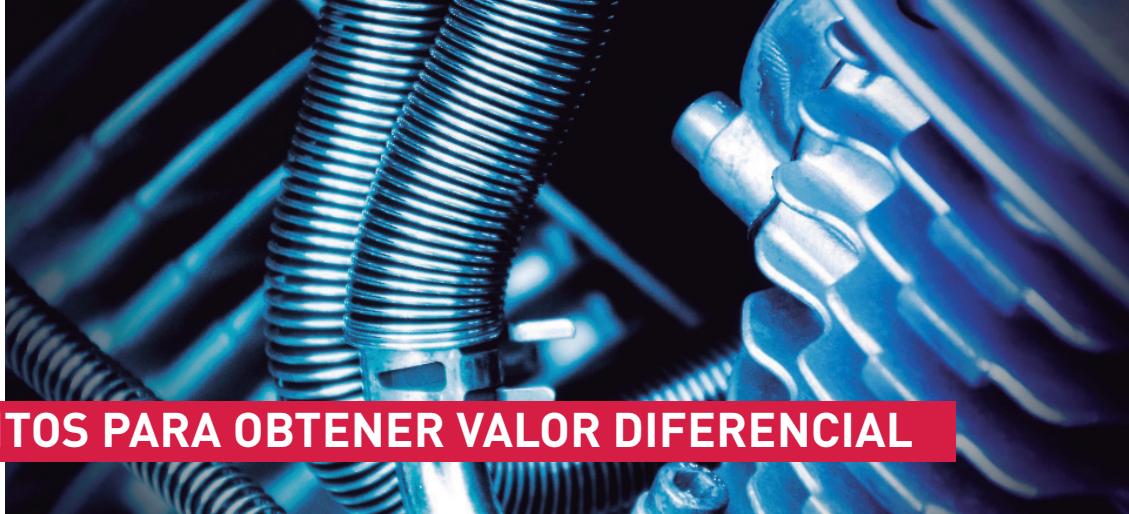
Como se puede observar, las preguntas planteadas son concretas y, aun así, no llegan a reflejar todo lo que se podría hacer con semejante información. Al mismo tiempo, también queda patente que, sin una buena pregunta (o más de una), la “Máquina” no puede contestar, porque le falta todo el contexto del negocio que nosotros damos por sentado.

5. Por último, cabe plantearse las siguientes preguntas para que el **éxito sea total**: sea cual sea el output generado por la “Máquina”, ¿será el fabricante capaz de diseñar e implementar acciones que lo aprovechen? ¿Cuánto costará el cambio de modelo de trabajo comparado con los beneficios incrementales?

Recomendaciones para directivos:

- *Por sí solos, los datos y algoritmos no representan un valor añadido al negocio. Únicamente lo tendrán si son capaces de dar respuestas diferenciales a problemas de negocio. Y, para que estas respuestas cumplan con su objetivo, resulta imprescindible que las preguntas estén bien formuladas.*

- *Para el éxito de una iniciativa de Machine Learning & Big Data, no solo es importante tener claros objetivos de negocio, sino también la capacidad de llevar a cabo de forma rentable las soluciones sugeridas.*



4. REQUISITOS PARA OBTENER VALOR DIFERENCIAL

Llegados a este punto, cabe preguntarse: ¿qué requisitos tienen que cumplirse para que el Machine Learning y el Big Data aporten un valor realmente diferencial?

Antes de arrancar una iniciativa de Machine Learning & Big Data, es imprescindible detenerse a evaluar una serie de requisitos que aseguren el éxito de la iniciativa:

Requisitos	Descripción	Siguiendo el ejemplo de la cervecería...
Disponibilidad de los Datos	Accesibilidad: Los datos tienen que ser accesibles para garantizar fluidez en su procesamiento y generación del input para los procesos de negocio afectados.	Si la generación de recomendaciones de pedido de reposición está pensada para ser diaria o incluso intra-diaria, el flujo de información de tiempo atmosférico tiene que tener una frecuencia al menos igual o superior.
	Calidad: los datos tienen que ser fiables, es decir, reproducir fielmente y de forma consistente en el tiempo lo que se pretende cuantificar.	Dado que los datos de tiempo atmosféricos son, normalmente, interpolados, hay un sesgo inherente al proceso analítico que los use. No obstante, la interpolación puede ser suficientemente buena como para garantizar valores coherentes y en línea con las variables de negocio que se quieren explicar.
	Información estructurada vs no estructurada: hay esencialmente dos tipos de información: <ul style="list-style-type: none">• Estructurada, es decir, almacenada en un formato estandarizado y fácilmente manipulable y accesible, como las Bases de Datos tradicionales. Puede ser utilizada de forma casi inmediata, donde el “casi” depende del formato de almacenamiento.• No estructurada: textos libres, información extraída de redes sociales, imágenes, vídeos, etc. Tiene un potencial enorme, pero requiere un esfuerzo inicial mucho mayor, comparado con el caso de la información estructurada, para poder ser utilizada eficazmente. <p>Es importante, por lo tanto, saber valorar y estimar el valor añadido representado por cada tipo de información en comparación con los costes que supone su utilización de forma eficaz.</p>	



Requisitos	Descripción	Siguiendo el ejemplo de la cervecera...
	<p>Precio: según el problema que se quiera resolver, es posible adquirir información externa, la cual, obviamente, suele tener un precio proporcional a su calidad o al nivel de granularidad exigido.</p> <p>Dado que los proveedores de datos ofrecen diferentes planes de precios en función de las opciones de adquisición de la información, será siempre necesario analizar qué tipo de información externa se precisa, con qué calidad y granularidad y qué precisión adicional se espera, antes de realizar la inversión.</p>	En el caso de la cervecera, por ejemplo, información meteorológica.
Los beneficios de una mayor previsión en la predicción superan el esfuerzo de implementación	<p>Las técnicas avanzadas de Machine Learning suelen proporcionar mejoras sustanciales con respecto a las técnicas analíticas más tradicionales cuando se puede realmente trabajar en un entorno de Big Data o cuando el problema de negocio es, por su propia naturaleza, imposible de ser tratado eficazmente sin Machine Learning (por ejemplo: reconocimiento de imágenes).</p> <p>Hay muchos casos, típicamente cuando la información es información transaccional estructurada – a menudo, incompleta o no suficiente para explicar el problema de negocio – donde la precisión incremental aportada por el Machine Learning es residual si la comparamos con la inversión necesaria para llevarla a cabo.</p> <p>Un Data Scientist experto sabrá valorar en cada momento cuándo vale la pena dar el salto al Machine Learning.</p>	



Requisitos	Descripción	Siguiendo el ejemplo de la cervecera...
<p>Resultados de los modelos integrados en los procesos de negocio</p> <p>Aunque parezca obvio, el resultado de un modelo analítico debe poderse utilizar dentro de un proceso de negocio. Menos obvio es cómo será posible:</p> <ul style="list-style-type: none"> • ¿Cómo viajarán, de forma automática y recurrente, los datos que alimentarán el modelo al sistema donde reside el Motor Analítico? • ¿Cómo serán devueltos los resultados a los sistemas origen o a los sistemas de soporte a la toma de decisiones? • ¿Qué reglas/acciones deberán ser implementadas en los sistemas para que el uso de los resultados del Machine Learning sea fluido y requiera de la mínima intervención humana? <p>Las condiciones para todo lo anterior son:</p> <ul style="list-style-type: none"> • Automatización de la transferencia de datos en tiempo real, de los locales a la cervecera. • Un Motor Analítico capaz de procesar rápidamente y con alta frecuencia la previsión del consumo y recalcular los pedidos de reaprovisionamiento. • Integración completa entre el Motor Analítico y los sistemas de CRM, para lanzar las notificaciones a los responsables de los locales. • Integración completa con los sistemas de logística, para adaptar el plan de entregas. • Un sistema ágil de interacción con el local (por ejemplo: una aplicación móvil) que permita enviar notificación y recibir respuestas en tiempos muy cortos. <p>De no ser posibles los puntos anteriores, un modelo de Machine Learning, por sofisticado que sea, no podría proporcionar el salto de calidad esperado, debido a las limitaciones del entorno y de los procesos existentes. Por lo tanto, hay que tener en cuenta que una solución de Machine Learning & Big Data puede implicar una transformación completa hacia la digitalización, para poder realmente aprovechar todo el potencial.</p>		<p>Los sensores instalados en los surtidores de los locales permitirían:</p> <ul style="list-style-type: none"> • Proyectar el consumo de las siguientes horas/días • Comparando con los niveles de stock, detectar alertas de ruptura • Calcular un pedido óptimo de reaprovisionamiento • Lanzar una notificación al responsable del local con la recomendación de pedido • Re-planificar la logística para poder entregar a tiempo el pedido extra de reaprovisionamiento



5. LOS NUEVOS PROFESIONALES

“La Inteligencia Artificial más avanzada aún no es capaz de reemplazar al hombre”

Uno de los errores más comunes a la hora de emprender la implementación de una plataforma de Machine Learning & Big Data es creer que es una cuestión de seleccionar la tecnología o el software adecuado; o el asumir que, una vez los datos empiecen a fluir a la plataforma, ésta sea capaz de aprender sola (“¿No era aprendizaje automático?”) y generar valor.

Desafortunadamente, no suele ser el caso porque, como ya hemos mencionado anteriormente:

- Los problemas de negocio tienen que ser traducidos en problemas analíticos.
- La información disponible tiene que ser analizada e interpretada, y su nivel de completitud es evaluado.
- Los algoritmos más avanzados tienen que ser entrenados y testados.
- La solución que se implemente necesitará mantenimiento, ya que la realidad del negocio es cambiante. Tanto los algoritmos como la definición misma del problema analítico tienen que ser actualizados constantemente.

Hoy en día, la Inteligencia Artificial más avanzada no es capaz de reemplazar al hombre en las tareas anteriores. Es solo con la conjunción de las capacidades de las máquinas y los conocimientos de las personas cuando las compañías pueden alcanzar todo su potencial.

Para introducir Data Science en una organización, es necesario incorporar perfiles que dominen el análisis de datos y los algoritmos de Machine Learning, que cuenten con conocimiento tecnológico y con la visión de negocio necesaria para diseñar e implementar una solución de Machine Learning & Big Data. Asimismo, un buen Data Scientist ha de contar con años de experiencia (más allá de la propia formación).

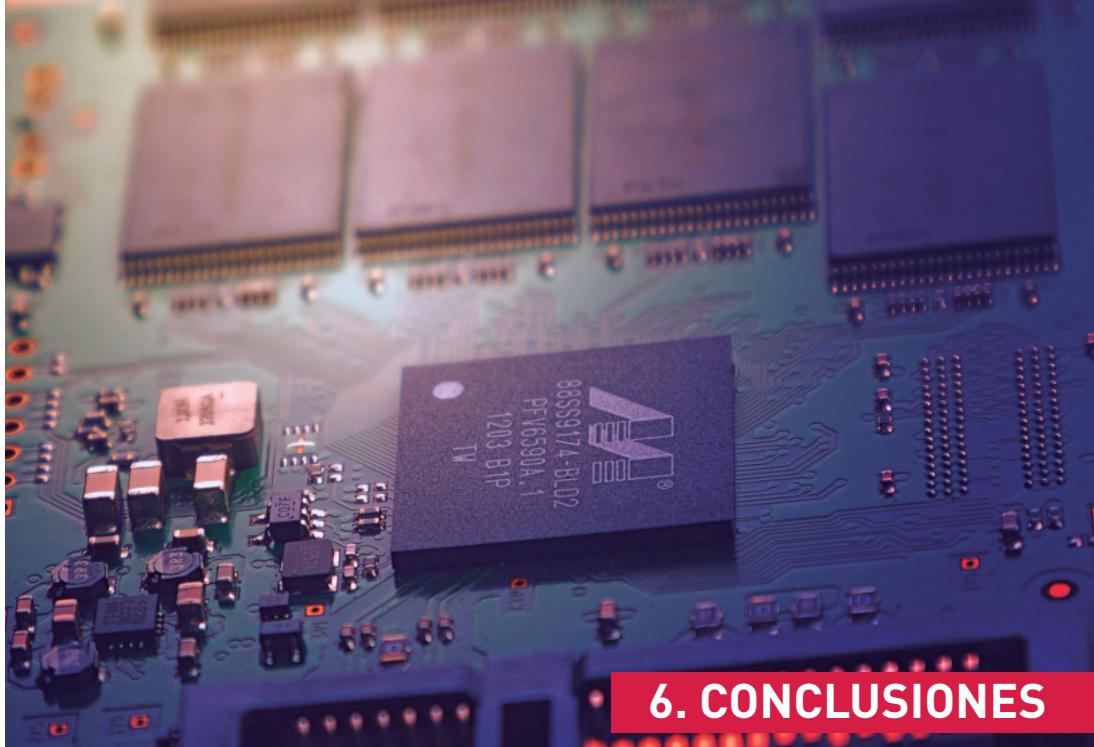
Sin duda, perfiles escasos por la creciente demanda de la que disfrutan en el mercado. Si bien es cierto que la oferta ha crecido acorde a la demanda y que seguirá haciéndolo, tanto en número de profesionales como en experiencia aportada.

Ante la complejidad de encontrar a profesionales que aglutinen todas estas capacidades, más común es poder contar con perfiles de Data Scientists que cubran las necesidades en cuanto a análisis de datos, algoritmos de Machine Learning y conocimiento tecnológico. También con perfiles de Negocio, pero con capacidades y conocimientos destacables en el ámbito analítico, que actúen de punto de unión entre Data Science y Negocio.

Por tanto, se puede afirmar que no puede existir Machine Learning & Big Data sin una seria apuesta por este tipo de profesionales, tanto en plantilla como a través de servicios profesionales.

Recomendaciones para directivos:

- Para obtener el máximo provecho, es necesario conjugar una buena solución de Inteligencia Artificial con un equipo de expertos en Data Science, que además domine el funcionamiento del negocio.



6. CONCLUSIONES

“Machine Learning & Big Data e Inteligencia Artificial ya no son un Nice-to-Have sino un Must-Have”

“La pregunta no es ya si es necesario implementar una solución de Machine Learning & Big Data, sino cuándo”

El ser humano procesa un número muy limitado de variables para tomar una decisión racional. Cuando nos enfrentamos a un problema complejo que excede nuestra capacidad de razonamiento, las mejores decisiones son, a menudo, inconscientes y se toman guiadas por la intuición.

Con el aprendizaje automático esta limitación desaparece: las decisiones óptimas vuelven a ser las decisiones racionales.

Los humanos tenemos toda la vida para aprender; las máquinas no tienen tanta paciencia. Una de las disciplinas de aprendizaje automático es el aprendizaje reforzado, en el que las máquinas adquieren conocimiento solas, simplemente captando información sobre las reglas del entorno.

Años de aprendizaje y conocimiento acumulado del ser humano se transforman en minutos para una máquina: pasa de saber únicamente cómo se mueven las piezas en un tablero de ajedrez a convertirse en un experto y vencer al campeón del mundo en tan solo unas horas de práctica.

Aun así, nos seguimos preguntando, ¿es el aprendizaje automático adecuado para mí?

Desde esta perspectiva, la respuesta es, claramente, sí. Porque la transformación ya ha empezado y no se parará: para poder sobrevivir en un mercado cada vez más competitivo, las claves serán conseguir mayor eficiencia (en forma de automatización inteligente de los procesos) y mayor eficacia (en forma de decisiones más acuñadas y de mayor impacto).

El aprendizaje automático ya está aquí. Las máquinas seguirán su carrera imparable de aprendizaje, la automatización reemplazará al ser humano en los trabajos repetitivos, los vehículos circularán con conducción autónoma, el diagnóstico médico se hará de forma remota, los equipos y los objetos estarán interconectados -internet de las cosas- y será en torno a 2040. Aunque nos quede tiempo para vivir esta realidad, es hoy cuando tenemos que rotar hacia lo nuevo y convertir en realidad nuestras decisiones inteligentes: operativas, tácticas y estratégicas.

Machine Learning & Big Data e Inteligencia Artificial ya no son un *Nice-to-Have* sino un *Must-Have*.



El no reunir los requisitos necesarios debería leerse como una campana de alerta: ya representa una desventaja competitiva que cuestiona la supervivencia en el medio y largo plazo.

La pregunta no es ya si es necesario implementar soluciones de Machine Learning & Big Data, sino cuándo. Y, cuanto antes, mejor.

Recomendaciones para directivos:

- *La transformación digital y la aplicación de nuevas tecnologías en lo ordinario ya está aquí. Tendrás que ponerte en marcha si no quieres verte superado por un mercado muy disruptivo donde la competitividad será cada vez más extrema. La digitalización no es una opción.*





7. GLOSARIO

• **Algoritmos:** conjunto de instrucciones o reglas bien definidas, ordenadas y que permiten llevar a cabo una actividad mediante una serie de pasos sucesivos. A partir de un dato inicial, se llevan a cabo esta serie de pasos para obtener un resultado final. En lo que se refiere a algoritmos de aprendizaje automáticos, estos reciben una entrada (los datos disponibles y tratados), de manera que puedan ser utilizados por el algoritmo. Se realiza la ejecución de los pasos necesarios, ya sea una clasificación, una previsión o una segmentación, y se produce una salida que corresponde al objetivo buscado.

• **Algoritmos no supervisados:** son aquellos algoritmos que intentan predecir un fenómeno que históricamente no ha podido ser observado. Por ejemplo, un modelo no supervisado de detección de fraude intenta agrupar casos que, debido a sus características diferenciadas del resto de casos, podrían considerarse sospechosos, pero no hay ninguna evidencia histórica de que lo hayan sido.

• **Algoritmos semi-supervisados:** combinación de algoritmos supervisados y no supervisados.

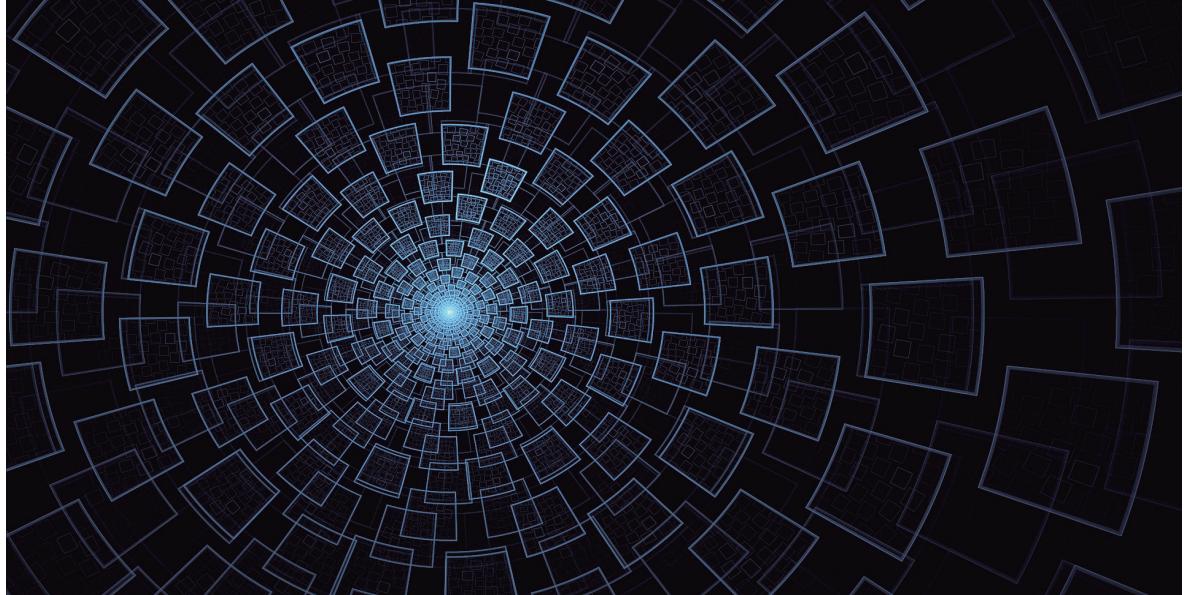
• **Algoritmos supervisados:** son aquellos algoritmos que intentan predecir un

fenómeno históricamente observado y registrado. Por ejemplo, un modelo supervisado de detección de fraude intenta clasificar automáticamente los casos que históricamente han sido considerados fraudulentos.

• **Aprendizaje reforzado (o aprendizaje por refuerzo):** estos algoritmos aprenden interactuando con el mundo que los rodea, es decir, se retroalimentan del mundo exterior. Su aprendizaje está basado en recompensas que obtienen cuando toman decisiones que permiten maximizar el objetivo deseado. Un algoritmo que juega al ajedrez tan solo conociendo las reglas del juego es un ejemplo de ello. El algoritmo aprenderá simulando partidas en las que, en cada situación, tomará una decisión posible, y recibirá una recompensa cuando su decisión lo conduzca a ganar la partida.

• **Comportamiento automático:** son aquellas decisiones que los modelos y algoritmos de aprendizaje automático pueden tomar sin necesidad de la intervención de los humanos.

• **Data Scientist:** es la denominación que reciben actualmente los profesionales dedicados al análisis y manipulación de datos. Utilizan metodologías estadís-



ticas avanzadas y tienen la capacidad de desarrollar algoritmos y modelos analíticos utilizando herramientas estadísticas de programación.

- **Datos estructurados y no estructurados:** los datos estructurados son aquellos que se encuentran organizados en un repositorio de datos con un formato específico; por ejemplo, códigos de identificación de clientes, importes o fechas. Cada uno se corresponde con una columna en una base de datos. En cambio, los datos no estructurados no tienen una estructura definida. Son, por ejemplo, los ficheros de texto, datos de redes sociales, fotos o videos, entre otros.
 - **Estadística paramétrica:** son análisis basados en distribuciones conocidas. Por ejemplo, en el análisis de supervivencia de ciertos productos, se asume que su ciclo de vida sigue una distribución de Weibull o distribución Exponencial que estima qué probabilidad tiene un producto de fallar en un momento determinado.
 - **Granularidad:** se refiere al nivel jerárquico o nivel de detalle de los datos. Por ejemplo, en el caso de una prenda de vestir, el análisis requerido podría ser a nivel de categoría de producto o producto / talla /color.
 - **Información accionable:** es el tipo de información que generan los modelos

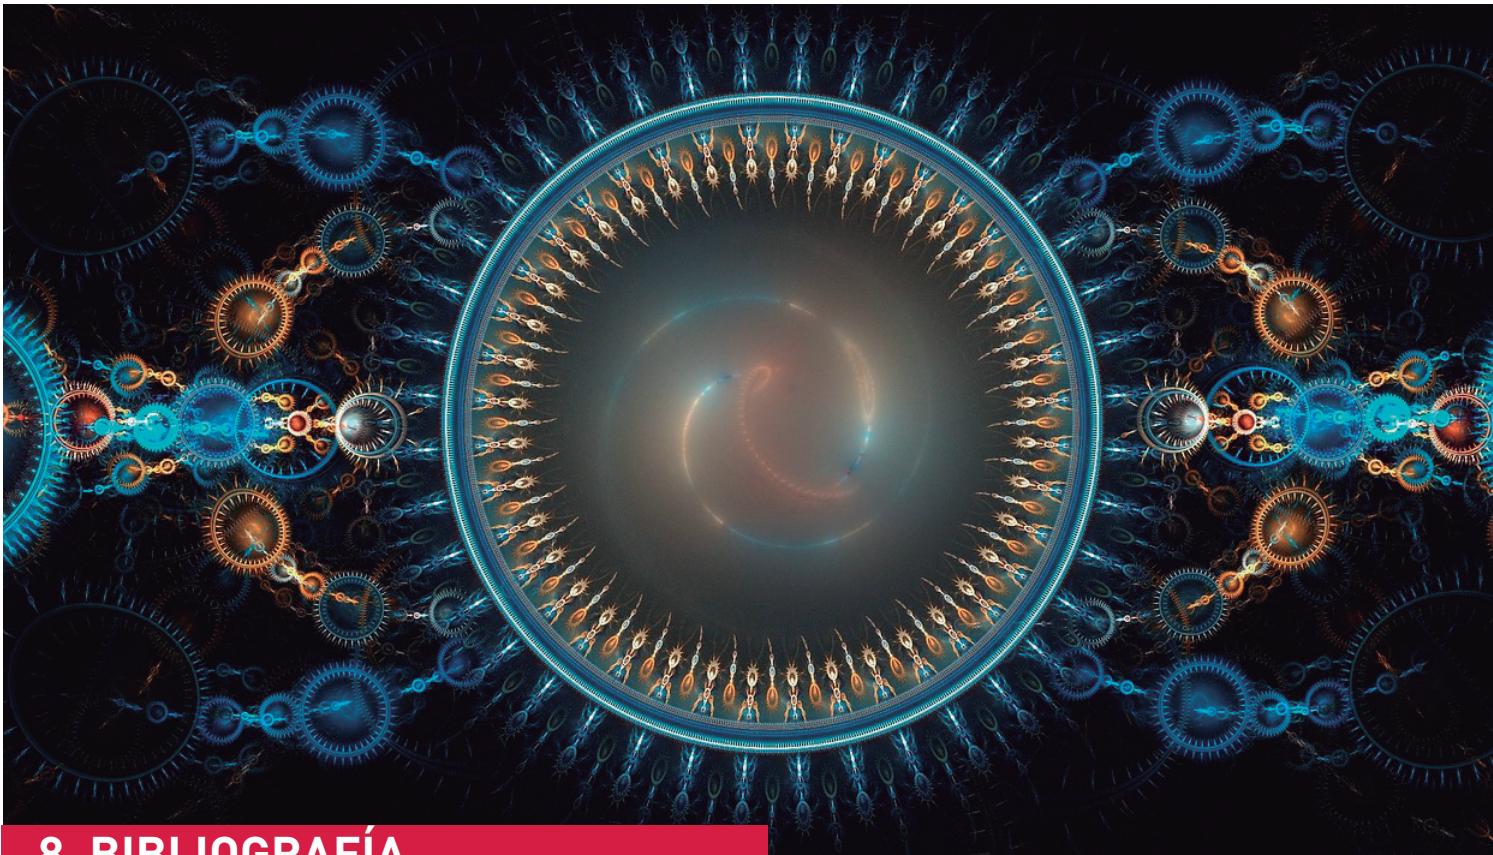
analíticos y que nos permite tomar decisiones que impactan en el negocio.

- **Paralelización:** en el contexto de este artículo, se refiere a la capacidad de ejecutar algoritmos de aprendizaje automático utilizando varios CPU/ordenadores simultáneamente logrando, así, mucha rapidez en la ejecución.

- **Patrones:** en el contexto de este artículo, se refiere a perfiles de comportamiento.



Nube de palabras: representación de las palabras más destacadas en el presente informe.



8. BIBLIOGRAFÍA

- Russell, Stuart and Norvig, Peter (2009, 3rd ed.). Artificial Intelligence: A Modern Approach. Prentice Hall.
- Barrat, James (2013). Our Final Invention: Artificial Intelligence and the End of the Human Era. Thomas Dunne Books.
- Sigman, Mariano (2015). La vida secreta de la mente. Debate.
- Sutton, Richard S. & Barto, Andrew G. (2015). Reinforcement Learning: An Introduction. The MIT Press.
- Tegmark, Max (2017). Life 3.0: Being Human in the Age of Artificial Intelligence. Knopf.
- Alphago (2017). IMDB: <https://www.imdb.com/title/tt6700846/>.



9. SOBRE LOS AUTORES

Javier Kuperman

Ingeniero en Sistemas por la Universidad Tecnológica Nacional de Buenos Aires, Argentina.

Senior Manager en el grupo de Inteligencia Aplicada de Accenture y miembro del Centro de Innovación de Analytics. Más de 20 años de experiencia en el desarrollo y liderazgo de soluciones basadas en analítica avanzada, inteligencia artificial y aprendizaje automático, principalmente en áreas vinculadas con la cadena de suministro y operaciones.

Franz Naselli

Licenciado en Matemáticas por la “Università degli Studi di Milano” y Post-Grado en “Matemàtiques pels Instruments Financers” por la “Universitat Autònoma de Barcelona”.

Ha trabajado en Consultoría TIC (Soluzione TI, ahora Indra), Consultoría de Estrategia de Marketing y Ventas (Daemon Quest, ahora Deloitte) y, actualmente, es Senior Manager en el grupo de Inteligencia Aplicada de Accenture y miembro del Centro de Innovación de Analytics, donde es responsable del área de “Forecasting”.

Lleva más de 13 años trabajando en la creación de soluciones analíticas avanzadas, inteligencia artificial y aprendizaje automático, tanto en las áreas de Marketing & Ventas (CRM, Optimización de Redes de Ventas...) como en Cadena de Suministro (Predicción y Planificación de la Demanda y Optimización de Inventario).

Jesús E. Gabaldón

Doctor en Ciencias Físicas por la Universitat Politècnica de Catalunya y licenciado (MSc) en Bioquímica por la Universidad de Barcelona.

Senior Manager en el grupo de Inteligencia Aplicada de Accenture, miembro del Centro de Innovación de Analytics y responsable del área de Mantenimiento Predictivo para el mercado europeo.

Después de 12 años en investigación fundamental en simulación numérica, sistemas dinámicos y dinámica de fluidos en España, Alemania y Francia, a su vuelta a España emprende su carrera profesional en el ámbito privado en ingeniería de software y analítica, acumulando un total de más de 20 años de experiencia en análisis operacional, modelos matemáticos y arquitectura de sistemas.



AED

ASOCIACIÓN
ESPAÑOLA DE
DIRECTIVOS

Con la colaboración de:

ACEC+
Associació Catalana
d'Empreses Consultores

www.asociaciondedirectivos.org

accenture