

**UNIVERSIDAD DE SANTIAGO DE CHILE  
FACULTAD DE INGENIERIA**

**Departamento de Ingeniería Informática**



*la generación  
o la producción  
no el consumo*

**PREDICCIÓN DE ENERGÍA EÓLICA CON  
MACHINE LEARNING**

**AUTOR: Manuel Jesús Moya Muñoz**

**Profesor Guía: Gonzalo XX Acuña XX**

*Leiva*

**Trabajo de titulación en conformidad a los  
requisitos para obtener el título de  
Ingeniero Civil en Informática**

**Santiago – Chile**

© Manuel Jesús Moya Muñoz, 2020



Creative Commons Atribución-NoComercial (CC:BY-NC): Se permite usar la obra y generar obras derivadas, siempre y cuando esos usos no tengan fines comerciales y siempre reconociendo al autor.

## RESUMEN

En esta memoria se desarrolla lorem ipsum lorem ipsum lorem ipsum lorem ipsum lorem ipsum lorem ipsum lorem ipsum lorem ipsum lorem ipsum lorem ipsum

**PALABRAS CLAVES:** lorem ipsum lorem ipsum lorem ipsum lorem ipsum lorem ipsum lorem ipsum lorem ipsum lorem ipsum lorem ipsum lorem ipsum

## AGRADECIMIENTOS

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu.

Muchas gracias a todos.

# TABLA DE CONTENIDO

RESUMEN .....	i
AGRADECIMIENTOS .....	ii
TABLA DE CONTENIDO .....	iii
ÍNDICE DE TABLAS .....	vi
ÍNDICE DE FIGURAS .....	vii
CAPÍTULO 1: INTRODUCCIÓN.....	1
1.1 ANTECEDENTES Y MOTIVACIÓN .....	1
1.2 DESCRIPCIÓN DEL PROBLEMA .....	2
1.3 SOLUCIÓN PROPUESTA.....	2
1.3.1 Características de la Solución .....	2
1.3.2 Propósito de la solución.....	3
1.4 OBJETIVOS Y ALCANCES DEL PROYECTO .....	3
1.4.1 Objetivo General .....	3
1.4.2 Objetivos Específicos .....	3
1.4.3 Alcances .....	3
1.5 METODOLOGÍAS Y HERRAMIENTAS UTILIZADAS .....	4
1.5.1 Metodología .....	4
1.5.2 Herramientas de Desarrollo .....	5
1.5.3 Ambiente de Desarrollo .....	7
1.6 ORGANIZACIÓN DEL DOCUMENTO .....	7
CAPÍTULO 2: MARCO TEÓRICO .....	8
2.1 VIENTOS Y ENERGÍA EÓLICA EN CHILE .....	8
2.2 PREDICCIÓN .....	8
2.3 MACHINE LEARNING.....	8
2.3.1 Una Inspiración Biológica. ....	9
2.3.2 Neuronas Artificiales. ....	10
2.3.3 Redes Neuronales. ....	10
2.3.4 Tipos de Aprendizajes. ....	11

2.4 MODELOS.....	12
2.5 PREDICCIÓN CON MACHINE LEARNING .....	12
2.6 MACHINE LEARNING: PREOCUPACIONES .....	14
2.6.1 Datos no representan el negocio.....	14
2.6.2 Cantidad de datos no son necesarios. ....	14
2.6.3 Ruido.....	14
2.6.4 Overfitting / Underfitting .....	15
2.6.5 Varias soluciones, un mismo resultado . ....	15
2.7 RESUMEN.....	15
CAPÍTULO 3:    ANÁLISIS Y DISEÑO .....	16
3.1 DISEÑANDO EL PROCESO DE PREDICCIÓN .....	16
3.1.1 Obtención de Datos .....	16
3.1.2 Entendimiento de los Datos y su Representación.....	16
3.1.2 Definición de las Métricas.....	16
3.2 ANÁLISIS ESTADÍSTICO E INFERENCIAL .....	17
3.3 ARQUITECTURA DE REDES NEURONALES.....	17
3.5 RESUMEN.....	17
CAPÍTULO 4:    IMPLEMENTACIÓN .....	18
4.1 PROGRAMACIÓN DEL MODELO.....	18
4.2 EJECUCIÓN DEL MODELO .....	18
4.2 ANÁLISIS DE LOS RESULTADOS.....	18
4.3 RESUMEN.....	18
CAPÍTULO 5:    CONCLUSIONES .....	19
5.1 ACERCA DE LOS OBJETIVOS .....	19
5.2 TRABAJOS FUTUROS .....	20
5.3 REFLEXIÓN PERSONAL.....	20
REFERENCIAS.....	21
APENDICE A: HISTORIAS DE USUARIO .....	22



## ÍNDICE DE TABLAS

Tabla 2.1: Horizontes de predicción energía eólica [3].....	13
Taba A.1: Historias de usuario con fuente. Fuente: Elaboración Propia, 2019.....	22



## ÍNDICE DE FIGURAS

Figura 1.1: Datos del modelo [6]. .....	2
Figura 1.2: Metodología CRISP [7] .....	4
Figura 1.3: Proceso de predicción ML [8]. .....	5
Figura 1.4: Python para Ciencia de Datos. ....	6
Figura 1.5: Librería Python para Análisis de Datos. ....	6
Figura 1.6: Machine Learning en Python .....	6
Figura 1.7: Librería Python para Aprendizaje Profundo .....	6
Figura 2.1: Alcance de <i>Machine Learning</i> [11]. ....	9
Figura 2.2: Neurona Biológica. ....	10
Figura 2.3: Neurona Artificial.....	10
Figura 2.4: Red Neuronal – Perceptrón Multicapa. ....	11
Figura 2.5: Aprendizaje Supervisado [13]. ....	12
Figura 2.6: Aprendizaje No Supervisado [13]. ....	12
Figura 2.7: Curva de potencia de aerogenerador de 2 MW [17]. ....	14

# CAPÍTULO 1: INTRODUCCIÓN.

[illegible]

## 1.1 ANTECEDENTES Y MOTIVACIÓN

Este trabajo conjuga la problemática de la predicción de la energía eólica y las potenciales soluciones que entrega la Inteligencia Artificial (IA), específicamente con el uso de técnicas de Machine Learning (ML), catalogada en el 2018 como componente tecnológico relevante [1]. La motivación se describe en los siguientes puntos:

- La energía que se genera actualmente en el sistema eléctrico de Chile (gran escala), es difícil de almacenar [2], por lo tanto, la planificación de producción de un parque eólico requiere información certera, la más cercana a la realidad.
- El sistema eléctrico debe poder asegurar la demanda, así mantener el balance con la oferta, de esta forma evitar el colapso del sistema. Por lo anterior es fundamental predecir valores de los parques eólicos e integrar esta energía de forma eficiente al sistema eléctrico nacional [2].
- Se necesita predicción de energía eólica para planificar producción, tomar decisiones de incrementarla y/o disminuirla, incluyendo decisiones económicas; adicionalmente tomar medidas de seguridad energética cuando sean requeridas [2].
- Modelos estadísticos tradicionales (basados en datos de modelos atmosféricos) tienen porcentaje de error mayor a modelos basados en series de tiempo [3] y algunos no reflejan de buena forma la realidad.
- Aumento de Energía Renovable No Convencional (ERNC) a través de Plan Energía 2050 de Chile [4], el cual tiene como meta el 70% de ERNC para el 2050.
- La predicción de energía eólica es compleja, ya que depende de condiciones meteorológicas, las cuales son muy variables.

## 1.2 DESCRIPCIÓN DEL PROBLEMA

Aunque la predicción del viento ha mejorado con el tiempo, aún tiene un alto porcentaje de error debido a su naturaleza caótica, lo cual genera intermitencias, estas intermitencias hacen que la generación de energía eólica tenga muchas fluctuaciones [5]. Esto provoca problemas en la integración de la energía eólica al sistema eléctrico chileno, ya que dificulta el trabajo de operadores eléctricos y su planificación, haciéndose complejo determinar la producción necesaria para cubrir la demanda y pudiendo generar problemas de seguridad del sistema eléctrico. Este problema se irá acrecentando a medida que se vaya cumpliendo el Plan Energía 2050, el cual contempla un crecimiento del 70% de las ERNC en Chile.

¿Pena  
"velocidad viento"?

## 1.3 SOLUCIÓN PROPUESTA

### 1.3.1 Características de la Solución

La solución será basada en redes neuronales artificiales ya que está comprobada su eficiencia con respecto a mediciones existentes, además es un componente tecnológico relevante que toma cada vez mayor preponderancia. Para la solución inicialmente se hará una investigación para entender los conceptos de predicción de energía eólica a corto plazo, también lo relacionado a redes neuronales artificiales, abordando puntos como recolección y entendimiento de datos, diseño neuronal (perceptrón multicapa y Long Short Term Memory -LSTM-) y entrenamiento de la red. Posteriormente se implementará el modelo con sus algoritmos de redes neuronales artificiales, se harán mediciones de error del modelo, se comparará con datos existentes en parque eólico y otras técnicas de ML disponibles desarrolladas con datos similares. Los datos principales del modelo son fecha, hora, velocidad del viento y energía generada como se visualizan en Figura 1.1. Adicionalmente se pueden considerar datos como dirección del viento y densidad del aire.

c/n  
a  
OTAS  
mito  
existen  
(p/muchas)



Figura 1.1: Datos del modelo [6].

Estos datos utilizados, serán de un parque eólico chileno, si esto no es posible se usará un conjunto de datos disponible en el sitio Kaggle.com (sitio de competencia de *Machine Learning* con datos gratis disponibles para su uso), de esta forma crear el modelo predictor. En ambos casos el conocimiento generado será aplicado a la realidad chilena.

### 1.3.2 Propósito de la solución

Permitir a los parques eólicos nacionales obtener predicciones más certeras con una menor tasa de error (¿y a un bajo costo?), así realizar de buena forma la planificación de la producción energética para cumplir la demanda, apoyar la toma de decisiones de producción, abastecimiento y económica de un parque eólico. Además, poder evitar problemas de seguridad de la matriz energética, reduciendo el impacto de potenciales pérdidas económicas en el sistema eléctrico chileno.

→ de qué!!!

## 1.4 OBJETIVOS Y ALCANCES DEL PROYECTO

### 1.4.1 Objetivo General

Desarrollar un modelo predictor de energía eólica de corto plazo basado en Machine Learning (ML), logrando mejores predicciones con los datos disponibles. El conocimiento extraído debe ser aplicable en los parques eólicos ubicados en Chile, de esta forma aportar a la industria nacional generando sistemas de predicción de energía eólica de más bajo costo.

### 1.4.2 Objetivos Específicos

- Generar un marco de trabajo que permita entender, describir y modelar los datos, para abordar el problema de predicción de energía eólica.
- Crear un modelo predictor, de corto plazo, de producción de energía eólica utilizando técnicas de ML.
- Establecer un cuadro comparativo del resultado del modelo predictor en base al análisis de información estadística disponible (línea base) y otras técnicas de ML descritas en la literatura académica con datos similares.
- Desarrollar un sistema de predicción en base al modelo creado y al conjunto de datos utilizado, que pueda ser empleado como herramienta complementaria en un parque eólico.

→ de qué!

Aha'.

### 1.4.3 Alcances

Los alcances y limitaciones de este proyecto son:

- El resultado del modelo ML, será comparado con predicciones estadísticas que posea el parque eólico y con resultados de otros modelos de ML disponibles en literatura académica con datos similares.
- Solo se creará un modelo predictor utilizando técnica de ML.

- Se utilizará un conjunto de datos de un parque eólico chileno, en caso de no obtener estos datos, se utilizarán los que estén disponibles en el sitio de internet Kaggle.com.
- La información estadística para comparar se modelará con una regresión lineal, de esta forma poder hacer la comparación.
- La solución estará basada en redes neuronales artificiales, utilizando perceptrón multicapa y en una red profunda con LSTM.

## 1.5 METODOLOGÍAS Y HERRAMIENTAS UTILIZADAS

### 1.5.1 Metodología

La metodología utilizada tiene como marco referencial el proceso CRISP (*Cross Industry Standard Process for Data Mining*) (Figura 1.2), el cual parte por la comprensión del negocio y datos, preparación de los datos, modelado, evaluación e implementación, todo bajo un proceso iterativo hasta encontrar la solución definitiva.

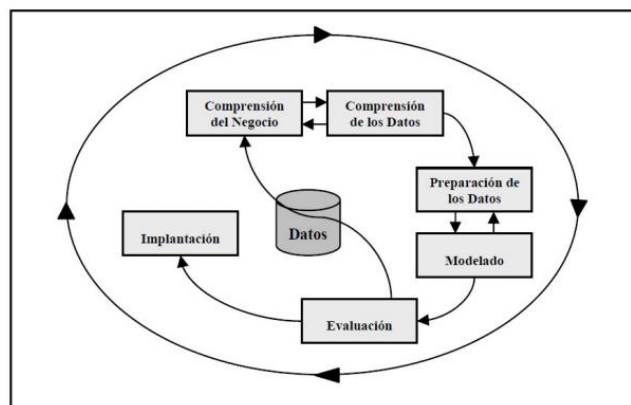


Figura 1.2: Metodología CRISP [7]

En cuanto al proceso de predicción basado en Machine Learning, tendrá como entrada los datos y existirá un proceso de entrenamiento del modelo creado hasta obtener la predicción esperada. Como se puede visualizar en la Figura 1.3, los pasos del proceso de predicción son obtener datos, entender datos y su representación, filtrar datos perdidos y fuera de rango (también llamado preprocesamiento), separar datos de prueba y validación, diseñar modelo neuronal, entrenar modelo, analizar resultado y comparar con datos estadísticos existentes [8]. Este proceso será iterativo y se repetirá hasta encontrar la solución esperada. => describir mejor



Figura 1.3: Proceso de predicción ML [8].

### 1.5.2 Herramientas de Desarrollo

Las herramientas de desarrollo serán basadas en el lenguaje Python. Éste es un lenguaje de programación de código abierto, su principal característica es su código conciso y legible lo que ayuda a su simplicidad, posee una sintaxis simple que lo hace ser mas ágil, lo que permite que sea mas fácil de escribir y leer, ayudando la colaboración. Adicionalmente posee una gran comunidad que lo soporta y una amplia fuente de librerías y *frameworks*. Todo lo anterior ha hecho que Python sea casi el lenguaje por defecto para *Machine Learning*.

Una de las configuraciones básicas de *Data Science* es: *Jupyter Notebook* + Python + Numpy, con esto se puede crear un modelo ML sin problemas (Figura 1.4). Un complemento de visualización estadística es la librería Pandas (Figura 1.5). Si se requiere utilizar con librerías específicas de ML se usará la librería *Scikit-learn* (Figura 1.6). Para Aprendizaje Profundo, se utilizará la librería Keras, ya que es una de las librerías mas usada (Figura 1.7). Lo importante es que estas librerías son *Open Source* y tiene respaldo de la comunidad, incluyendo empresas privadas y centros científicos.



Figura 1.4: Python para Ciencia de Datos.



Figura 1.5: Librería Python para Análisis de Datos.




Figura 1.6: Machine Learning en Python

### Keras: The Python Deep Learning library



Figura 1.7: Librería Python para Aprendizaje Profundo

En cuanto al hardware necesario para este proyecto es un computador *MacBook Pro-15'* (Intel *Core i7* de 6 núcleos y 2,2 GHz, 16 GB de memoria LPDDR3 y SSD de 256 GB), lo que otorgará el rendimiento que permita ejecutar el modelo respectivo.

Adicionalmente se usarán:

- Google *Drive*, como plataforma de almacenamiento online.
- MS *Office* 2016, *Word* y *Power Point* para la realización de la documentación oficial y preparación de presentaciones, respectivamente.
- draw.io para la realización de diagramas y modelamiento de la aplicación.
- Github para mantener un control de versiones.

### 1.5.3 Ambiente de Desarrollo

El ambiente de desarrollo será el hardware y software indicados en el punto 1.5.2. El lugar físico será el domicilio del alumno que cuenta con las condiciones necesarias para el trabajo, el cual cuenta con acceso a internet e impresora.

Adicionalmente, se usarán las dependencias del Departamento Informática USACH.

## 1.6 ORGANIZACIÓN DEL DOCUMENTO

El documento está dividido en X partes, iniciando por este capítulo (introducción), y continuando por el marco teórico que pretende introducir a los conceptos utilizados a lo largo del documento.

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu. =>

OJO redactar mejor



## CAPÍTULO 2: MARCO TEÓRICO

El objetivo de este capítulo es introducir los conceptos utilizados, de esta forma establecer el marco y contextualización en el cual se desarrollará esta memoria de título.

### 2.1 VIENTOS Y ENERGÍA EÓLICA EN CHILE

El uso industrial del viento en Chile inició con la molienda de cereales y para bombear agua en las salitreras, las primeras décadas del siglo XX. En cuanto a la generación de energía eólica, su uso comenzó en el año 2001. En las zonas costeras los vientos son ideales para la generación de energía, por lo que existe un gran potencial en el país para esta industria [9].

Actualmente, la ERNC (Energía Renovable No Convencional) en Chile es del 24%, donde la energía eólica ocupa el 6,02%, lo que equivale a la generación de 1540 MW. Adicionalmente para este tipo de energía se estiman proyectos por 500 MW/año (aproximadamente). Esto clasifica a Chile como el segundo país en capacidad instalada de energía eólica en América Latina y el Caribe [10]. En relación con la industria de ERNC, Chile ha establecido la Política Energía Nacional 2050, la cual pone como meta tener un 70% de ERNC en el 2050, lo que incrementará la generación de energías renovables incluyendo la eólica.

El proceso de generación de energía eólica consta en convertir la energía cinética del viento en energía eléctrica mediante turbinas que están diseñadas para generar energía eléctrica aprovechando el efecto Venturi. En cuanto a los parques eólicos actuales, usan turbinas modernas de 2 a 3 MW, permitiendo producir la energía de forma eficiente.

### 2.2 PREDICCIÓN

Para el ser humano siempre ha sido un desafío saber lo que sucederá, que puede ocurrir o cuando puede ocurrir, es importante porque este conocimiento genera una cierta ventaja para anteponerse a los hechos. Es importante indicar que la predicción es una parte fundamental del método científico. Al inicio esta predicción se hacía en base a supuesto, hoy los datos son un input fundamental para realizar este proceso. También es importante señalar que la predicción tiene dificultades, ya sea porque existen variables ocultas o dinámicas desconocidas o complejas. En resumen, aunque actualmente aun existen problemas difíciles de predecir, la predicción tiene una tasa mayor de certeza, esto es debido, a que la gran cantidad de datos disponibles pueden de alguna manera establecer un comportamiento definido.

### 2.3 MACHINE LEARNING

*Machine Learning* (ML) o aprendizaje de máquina, como definió Arthur Samuel, pionero en inteligencia artificial de IBM y *Stanford*: “es el campo de estudio que da a las computadoras la

habilidad de aprender sin ser explícitamente programadas” [11], su objetivo es detectar patrones de forma automática a partir de datos de entradas. Los algoritmos empleados se ejecutan en un proceso de aprendizaje supervisado o no supervisado. Como se puede ver en la Figura 2.1, ML es una subárea de inteligencia artificial, actualmente de forma errónea son usadas como sinónimos. A su vez ML tiene como subárea todo lo relacionado Deep Learning. ML es un nuevo campo de la ingeniería informática, la cual ha tenido un auge en los últimos años. Sus algoritmos están basados principalmente en redes neuronales artificiales y las soluciones son abordadas a través de clasificación o regresión [12]. Su utilización ha tomado fuerza, siendo en el 2018 declarado componente tecnológico relevante por la ACM (*Association for Computing Machinery*).




Figura 2.1: Alcance de *Machine Learning* [11].

### 2.3.1 Una Inspiración Biológica.

Machine Learning está inspirado en los seres cognitivos ya que tienen gran facilidad de reconocer patrones, procesar voz, imagen, etc., lo que se traduce en complejidad, paralelismo y alta conectividad. Todo lo anterior basado en la neurona biológica, que se puede visualizar en la Figura 2.2. Esta neurona tiene la capacidad de recoger información (externa), procesar la información y generar una respuesta activando otra neurona vía sinapsis, algunas pueden generar hasta 100 mil sinapsis [8].




Figura 2.2: Neurona Biológica.

### 2.3.2 Neuronas Artificiales.

La neurona artificial, modelo de McCulloch y Pitts (1943), es un autómata con el cual se intenta modelar una neurona biológica, es la unidad esencial de una red neuronal. El resultado del cálculo en una neurona consiste en realizar una suma ponderada de las entradas, seguida de la aplicación de una función no lineal, como se ilustra en la Figura 2.3.

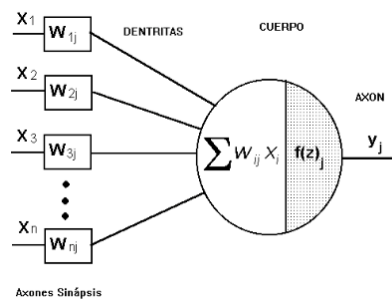


Figura 2.3: Neurona Artificial.

El aprendizaje de la neurona artificial es la capacidad de ajustar las conexiones para satisfacer algún criterio. Este mismo aprendizaje aplica para una red neuronal.

### 2.3.3 Redes Neuronales.

Una red neuronal, ver Figura 2.4, es un conjunto de neuronas conectadas entre sí que tienen como objetivo procesar (vía operaciones matemáticas) información de entrada, produciendo un

valor de salida. Las conexiones entre si pueden incrementar o disminuir el estado de activación de cada neurona, además la salida de cada neurona tiene una función de activación, la cual pone un limite o umbral modificando el resultado antes que se propague. Una red neuronal se puede usar para aprendizaje o para simulación. La red neuronal es el principal componente tecnológico del ML.




Figura 2.4: Red Neuronal – Perceptrón Multicapa.

Existen varios tipos de redes neuronales, pero es el Perceptrón Multicapa (creado por Frank Rosenblatt en 1958) la red base de aprendizaje maquina o ML, la cual se puede ver en la Figura 4.

Una red neuronal se enfoca en la problemática de aproximación de funciones, Esta problemática se puede resolver mediante clasificación o regresión. Clasificación “es un problema de asignación automática de una etiqueta a una etiqueta sin ejemplo. Detección de SPAM es un famoso ejemplo de clasificación” [6]. Regresión “es un problema de predecir una etiqueta de valor real (a menudo llamada objetivo) dado un ejemplo sin etiqueta. Estimación de la valoración del precio de la vivienda según las características de la casa, como el área, el número de habitaciones, la ubicación, etc. es un famoso ejemplo de regresión” [12].

### 2.3.4 Tipos de Aprendizajes.

Una red neuronal tiene principalmente dos tipos de aprendizaje, uno supervisado y otro no supervisado. El aprendizaje supervisado realiza predicciones basados en un conjunto de ejemplos, acá el entrenamiento es fundamental (ejemplo, Figura 5). El aprendizaje no supervisado tiene por objetivo organizar los datos de alguna manera o describir su estructura, agrupándolos en clústeres o de forma diferentes (ejemplo, Figura 6).




Figura 2.5: Aprendizaje Supervisado [13].




Figura 2.6: Aprendizaje No Supervisado [13].

## 2.4 MODELOS

Los seres humanos vivimos en una realidad caótica y compleja, nuestro ordenamiento es basado en patrones que se van identificando en la realidad a través de una mirada simplificada, es decir, construimos la realidad mediante modelos. Los modelos son “representaciones culturales que son construidas a partir de fenómenos reales y proposiciones teóricas, que median entre la teoría y el mundo y que ayudan a satisfacer alguna preocupación humana” [14] y sirven para entender de mejor forma la realidad. Los modelos deben ser simples para lograr el entendimiento de lo que se requiere, generalmente para lograr la representación necesaria se utiliza la probabilidad, así se puede interpretar la incertidumbre existente. Estos modelos son denominados modelos probabilísticos y son la base del ML. Estos modelos son construidos en base a los datos disponibles, los cuales son multidimensionales y representan la realidad. También se debe considerar que los modelos poseen parámetros, estos valores son los que se pueden modificar para adaptar el modelo de mejor forma a la realidad representada por los datos. Finalmente, un modelo puede no representar la realidad al cien por ciento, por esto poseen una función de error que indicará que tan cerca está el modelo de la realidad [15].

## 2.5 PREDICCIÓN CON MACHINE LEARNING

En ML la forma de predicción más usada es vía series de tiempo, es decir, con datos de entrada (muestras) tomados a intervalos de tiempo periódicas o regulares. Las series de tiempo tienen dos restricciones, dependen del tiempo y tienen algún tipo de estacionalidad, algunos ejemplos de series temporales son: ventas de una compañía, producción de alguna industria, valor de acciones, entre otras. Algunos autores también clasifican la regresión y regresión logística como técnicas de ML, aunque no necesariamente se resuelven vía redes neuronales.

Es importante señalar que la predicción de energía eólica se divide en tres grupos, según su horizonte de predicción y cada uno de ellos tiene un uso distinto considerando el respectivo error asociado, como muestra la Tabla 1.

Tabla 2.1: Horizontes de predicción energía eólica [3].

Horizonte Predicción	Tiempo	Error	Uso	Utilidad
Muy Corto Plazo	< 4 hrs.	Menor error de predicción	* Toma decisiones de seguridad de la producción * Operación de red en tiempo real	✓
Corto Plazo	< 48 / 72 hrs.	Error razonable de predicción	* Planificación de producción energética * Toma de decisiones de producción * Seguridad operacional del mercado energético * Planificación de despacho de carga	✓ ✓ ✓
Largo Plazo	< 7 días	Error muy grande de predicción	* Provisión de recursos de producción * Gestión de producción * Planes de mantención * Costo operacional optimo	✓

La predicción de energía eléctrica y más aún cuando es eólica, tiene una complejidad intrínseca debido a su incertidumbre de predicción, esto debido a que la naturaleza de la meteorología es explicada por la dinámica de fluido y el comportamiento caótico de la atmosfera [15], esto conlleva un grado de error en las estimaciones estadísticas y físicas (usando modelos de leyes de la física para predecir energía eléctrica). Esta incertidumbre también se puede visualizar en Figura 1, es decir, la potencia generada a 10 m/s es 8 veces mayor la generada a 5 m/s. Un error en la predicción puede significar un alto error en la generación de energía eléctrica.



#### 2.6.4 Overfitting / Underfitting.

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

#### 2.6.5 Varias soluciones, un mismo resultado .

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

### 2.7 RESUMEN

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

.



## CAPÍTULO 3: ANÁLISIS Y DISEÑO

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

### 3.1 DISEÑANDO EL PROCESO DE PREDICCIÓN

#### 3.1.1 Obtención de Datos

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

#### 3.1.2 Entendimiento de los Datos y su Representación

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

#### 3.1.2 Definición de las Métricas

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

### **3.2 ANÁLISIS ESTADÍSTICO E INFERENCIAL**

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

### **3.3 ARQUITECTURA DE REDES NEURONALES**

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

### **3.5 RESUMEN**

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu



## CAPÍTULO 5: CONCLUSIONES

[illegible]

## 5.1 ACERCA DE LOS OBJETIVOS

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

## 5.2 TRABAJOS FUTUROS

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

## 5.3 REFLEXIÓN PERSONAL

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu  
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

## REFERENCIAS

- [1] Association for Computing Machinery (2018). *Fathers of the Deep Learning Revolution Receive ACM A.M. Turing Award*. Disponible: <https://awards.acm.org/about/2018-turing>.
- [2] J. Clerc, J. Olmedo, J. Peralta, M. Saavedra, E. Sauma, I. Urzúa, A. Hernando. "Energías renovables en Chile. Hacia una inserción eficiente de la matriz eléctrica", Centro de Estudios Públicos (CEP), Chile, 2017.
- [3] L. Fernández, "Modelos avanzados para la predicción a corto plazo de la producción eléctrica de parques eólicos", Tesis Doctoral, Universidad de la Rioja, Logroño, España, 2007.
- [4] Ministerio de Energía de Chile (2016). Política Energética de Chile. Disponible: <http://www.energia2050.cl/>.
- [5] C. González, D. López (2013). Energía eólica y su intermitencia ¿mayor predicción del viento o almacenamiento de energía? Disponible: <http://latinoamericarenovable.com/2013/07/27/energia-eolica-y-su-intermitencia-mayor-prediccion-del-viento-o-almacenamiento-de-energia/>.
- [6] I. Erbetta, "Predicción de la potencia para la operación de parques eólicos", Tesis de Ingeniería Civil Electricista, Universidad de Chile, Santiago, Chile, 2010.
- [7] P. Chapman, J. Clinton, R. Kerber, T. Khabaza, T. Reinartz, C. Shearer, R. Wirth. "Step-by-step data mining guide", CRISP-DM Consortium (NCR, DaimlerChrysler, SPSS & Bank Groep B.V.), USA, 2000.
- [8] G. Acuña, "Curso Redes Neuronales", Apuntes no publicados, Universidad de Santiago de Chile. Segundo semestre 2018.
- [9] Ministerio de Energía de Chile (2016). El desarrollo de la energía. Disponible: <https://www.aprendeconenergia.cl/el-desarrollo-de-la-energia-eolica-en-chile/>.
- [10] Global Wind Energy Council (2017). Installed Wind Capacity Worldwide. Disponible: <https://gwec.net/publications/global-wind-report-2/>.
- [11] J. Patterson y A. Gibson. Deep Learning: A Practitioner's Approach. O'Reilly. 2017.
- [12] A. Burkov. The Hundred-Page Machine Learning. Andriy Burkov. 2019.
- [13] Ligdi González (2018). Aprendizaje Supervisado y No Supervisado. Disponible: <http://ligdigonzalez.com/clasificacion-de-machine-learning/>.
- [14] A. Adúriz-Bravo, "Algunas características clave de los modelos científicos relevantes para la educación química", Universidad Autónoma De México, Educación Química Vol.23, supl.2 México, mayo 2012.
- [15] C. Santana (2017). Modelos para entender una realidad caótica. Disponible: <https://www.youtube.com/watch?v=Sb8XVheowVQ>
- [16] E. Lorenz. The Essence of Chaos. University of Washington Press. 1995.
- [17] CORFO (2013). Guía de desarrollo de pequeños y medianos proyectos de Energía Eólica. Disponible: [http://dataset.cne.cl/Energia\\_Abierta/Estudios/CER/Gu%C3%ADa%20eolica%20desarrollo%20de%20proyectos%20peque%C3%B1os%20y%20medianos.pdf](http://dataset.cne.cl/Energia_Abierta/Estudios/CER/Gu%C3%ADa%20eolica%20desarrollo%20de%20proyectos%20peque%C3%B1os%20y%20medianos.pdf).

# **APENDICE A: HISTORIAS DE USUARIO**

Taba A.1: Ipsu Loren

Código	Nombre	Descripción	Fuente
01	ipsu loren ipsu	ipsu loren ipsu	ipsu loren ipsu
02	ipsu loren ipsu	ipsu loren ipsu	ipsu loren ipsu
15	ipsu loren ipsu	ipsu loren ipsu	ipsu loren ipsu