

**UNIVERSIDAD DE SANTIAGO DE CHILE
FACULTAD DE INGENIERIA**

Departamento de Ingeniería Informática



**PREDICCIÓN DE GENERACIÓN DE ENERGÍA EÓLICA
CON MACHINE LEARNING**

AUTOR: Manuel Jesús Moya Muñoz

Profesor Guía: Gonzalo Acuña Leiva.

**Trabajo de titulación en conformidad a los
requisitos para obtener el título de
Ingeniero Civil en Informática**

Santiago – Chile

© Manuel Jesús Moya Muñoz, 2020



Creative Commons Atribución-NoComercial (CC:BY-NC): Se permite usar la obra y generar obras derivadas, siempre y cuando esos usos no tengan fines comerciales y siempre reconociendo al autor.

RESUMEN

En esta memoria se desarrolla loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

PALABRAS CLAVES: loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

AGRADECIMIENTOS

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu.

Muchas gracias a todos.

TABLA DE CONTENIDO

RESUMEN	i
AGRADECIMIENTOS	ii
TABLA DE CONTENIDO	iii
ÍNDICE DE TABLAS	vi
ÍNDICE DE FIGURAS	vii
CAPÍTULO 1: INTRODUCCIÓN	1
1.1 ANTECEDENTES Y MOTIVACIÓN	1
1.2 DESCRIPCIÓN DEL PROBLEMA	2
1.3 SOLUCIÓN PROPUESTA	2
1.3.1 Características de la Solución	2
1.3.2 Propósito de la Solución	3
1.4 OBJETIVOS Y ALCANCES DEL PROYECTO	3
1.4.1 Objetivo General	3
1.4.2 Objetivos Específicos	3
1.4.3 Alcances	3
1.5 METODOLOGÍAS Y HERRAMIENTAS UTILIZADAS	4
1.5.1 Metodología	4
1.5.2 Herramientas de Desarrollo	5
1.5.3 Ambiente de Desarrollo	7
1.6 ORGANIZACIÓN DEL DOCUMENTO	7
CAPÍTULO 2: MARCO TEÓRICO	8
2.1 VIENTOS Y ENERGÍA EÓLICA EN CHILE	8
2.2 PREDICCIÓN	8
2.3 MACHINE LEARNING	9
2.3.1 Una Inspiración Biológica.	9
2.3.2 Neuronas Artificiales.	10
2.3.3 Redes Neuronales.	10
2.3.4 Tipos de Aprendizajes.	11

2.4 MODELOS	12
2.5 PREDICCIÓN CON MACHINE LEARNING	12
2.6 CONSIDERACIONES EN MACHINE LEARNING	14
2.6.1 Generalización de los Modelos.....	14
2.6.2 Varias Soluciones, Un Mismo Resultado.....	14
2.6.3 Datos No Representan el Negocio.	15
2.6.4 Cantidad de Datos No Son Suficientes.	15
2.6.5 Ruido.	15
2.6.6 <i>Overfitting</i> y <i>Underfitting</i>	15
2.7 RESUMEN	16
CAPÍTULO 3: ANÁLISIS Y DISEÑO	17
3.1 DISEÑANDO EL PROCESO DE PREDICCIÓN	17
3.1.1 Obtención de Datos	17
3.1.2 Entendimiento de los Datos y su Representación	17
3.1.2 Definición de las Métricas.....	20
3.2 ANÁLISIS ESTADÍSTICO DESCRIPTIVO E INFERENCIAL.....	21
3.2.1 Limpiar y Adecuar los Datos.....	21
3.2.2 Análisis Descriptivo.....	21
3.2.3 Análisis Inferencial.....	21
3.3 ARQUITECTURA DE REDES NEURONALES.....	21
3.5 RESUMEN	21
CAPÍTULO 4: IMPLEMENTACIÓN	22
4.1 PROGRAMACIÓN DEL MODELO.....	22
4.2 EJECUCIÓN DEL MODELO	22
4.2 ANÁLISIS DE LOS RESULTADOS.....	22
4.3 RESUMEN	22
CAPÍTULO 5: CONCLUSIONES	23
5.1 ACERCA DE LOS OBJETIVOS	23
5.2 TRABAJOS FUTUROS	24

5.3 REFLEXIÓN PERSONAL	24
REFERENCIAS	25
APENDICE A: HISTORIAS DE USUARIO	27

ÍNDICE DE TABLAS

Tabla 2.1: Horizontes de Predicción Energía Eólica [3].....	13
Tabla 3.1: Descripción de Archivos del Conjunto de Datos.....	17
Tabla 3.2: Descripción de Variables para Datos de Entrenamiento.	18
Tabla 3.3: Descripción de Variables para Datos de Test.....	18
Tabla 3.4: Descripción de Variables para Datos de Benchmark.	18
Tabla 3.5: Descripción de Variables de los Parques Eólicos 1 hasta 7.....	19
Taba A.1: Ipsi Loren	27
Taba A.2: Ipsi Loren	27

ÍNDICE DE FIGURAS

Figura 1.1: Datos del modelo [7].	2
Figura 1.2: Metodología CRISP [8].	4
Figura 1.3: Proceso de predicción ML [9].	5
Figura 1.4: Python para Ciencia de Datos.	6
Figura 1.5: Librería Python para Análisis de Datos.	6
Figura 1.6: Machine Learning en Python	6
Figura 1.7: Librería Python para Aprendizaje Profundo.	6
Figura 2.1: Alcance de <i>Machine Learning</i> [15].	9
Figura 2.2: Neurona Biológica.	10
Figura 2.3: Neurona Artificial.	10
Figura 2.4: Red Neuronal – Perceptrón Multicapa.	11
Figura 2.5: Aprendizaje Supervisado [17].	12
Figura 2.6: Aprendizaje No Supervisado [17].	12
Figura 2.7: Curva de potencia de aerogenerador de 2 MW [21].	14

CAPÍTULO 1: INTRODUCCIÓN.

[illegible]

1.1 ANTECEDENTES Y MOTIVACIÓN

Este trabajo conjuga la problemática de la predicción de la energía eólica y las potenciales soluciones que entrega la Inteligencia Artificial (IA), específicamente con el uso de técnicas de Machine Learning (ML), catalogada en el 2018 como componente tecnológico relevante [1]. La motivación se describe en los siguientes puntos:

- La energía que se genera actualmente en el sistema eléctrico de Chile (gran escala), es difícil de almacenar [2], por lo tanto, la planificación de producción de un parque eólico requiere información certera, la más cercana a la realidad.
- El sistema eléctrico debe poder asegurar la demanda, así mantener el balance con la oferta, de esta forma evitar el colapso del sistema. Por lo anterior es fundamental predecir valores de los parques eólicos e integrar esta energía de forma eficiente al sistema eléctrico nacional [2].
- Se necesita predicción de energía eólica para planificar producción, tomar decisiones de incrementarla y/o disminuirla, incluyendo decisiones económicas; adicionalmente tomar medidas de seguridad energética cuando sean requeridas [2].
- Modelos estadísticos tradicionales (basados en datos de modelos atmosféricos) tienen porcentaje de error mayor a modelos basados en series de tiempo [3] y algunos no reflejan de buena forma la realidad.
- Aumento de Energía Renovable No Convencional (ERNC) a través de Plan Energía 2050 de Chile [4], el cual tiene como meta el 70% de ERNC para el 2050.
- La predicción de energía eólica es compleja, ya que depende de condiciones meteorológicas, la cuales son muy variables.

1.2 DESCRIPCIÓN DEL PROBLEMA

Aunque la predicción del viento ha mejorado con el tiempo, aún tiene un alto porcentaje de error debido a su naturaleza caótica, lo cual genera intermitencias, estas intermitencias hacen que la generación de energía eólica tenga muchas fluctuaciones [5]. Esto provoca problemas en la integración de la energía eólica al sistema eléctrico chileno, ya que dificulta el trabajo de operadores eléctricos y su planificación, haciéndose complejo determinar la producción necesaria para cubrir la demanda y pudiendo generar problemas de seguridad del sistema eléctrico. Este problema se irá acrecentando a medida que se vaya cumpliendo el Plan Energía 2050, el cual contempla un crecimiento del 70% de las ERNC en Chile.

1.3 SOLUCIÓN PROPUESTA

1.3.1 Características de la Solución

La solución será basada en redes neurales artificiales ya que está comprobada su eficiencia de al menos de 13% respecto a mediciones existentes [6], además es un componente tecnológico relevante que toma cada vez mayor preponderancia. Para la solución inicialmente se hará una investigación para entender los conceptos de predicción de energía eólica a corto plazo, también lo relacionado a redes neuronales artificiales, abordando puntos como recolección y entendimiento de datos, diseño neuronal (perceptrón y multicapa LSTM -*Long Short Term Memory*-) y entrenamiento de la red. Posteriormente se implementará el modelo con sus algoritmos de redes neuronales artificiales, se harán mediciones de error del modelo, se comparará con datos existentes en parque eólico y otras técnicas de ML disponibles desarrolladas con datos similares. Los datos principales del modelo son fecha, hora, velocidad del viento y energía generada como se visualizan en Figura 1.1. Adicionalmente se pueden considerar datos como dirección del viento y densidad del aire.



Figura 1-1: Datos del modelo [7].

Estos datos utilizados, serán de un parque eólico chileno, si esto no es posible se usará un conjunto de datos disponible en el sitio Kaggle.com (sitio de competencia de *Machine Learning* con datos gratis disponibles para su uso), de esta forma crear el modelo predictor. En ambos casos el conocimiento generado será aplicado a la realidad chilena.

1.3.2 Propósito de la Solución

Permitir a los parques eólicos nacionales obtener predicciones más certeras con una menor tasa de error (¿y a un bajo costo?), así realizar de buena forma la planificación de la producción energética para cumplir la demanda, apoyar la toma de decisiones de producción, abastecimiento y económica de un parque eólico. Además, poder evitar problemas de seguridad de la matriz energética, reduciendo el impacto de potenciales pérdidas económicas en el sistema eléctrico chileno.

1.4 OBJETIVOS Y ALCANCES DEL PROYECTO

1.4.1 Objetivo General

Desarrollar un modelo predictor de energía eólica de corto plazo basado en Machine Learning (ML), logrando mejores predicciones con los datos disponibles. El conocimiento extraído debe ser aplicable en los parques eólicos ubicados en Chile, de esta forma aportar a la industria nacional generando sistemas de predicción de energía eólica de más bajo costo.

1.4.2 Objetivos Específicos

- Generar un marco de trabajo que permita entender, describir y modelar los datos, para abordar el problema de predicción de energía eólica.
- Crear un modelo predictor, de corto plazo, de producción de energía eólica utilizando técnicas de ML.
- Establecer un cuadro comparativo del resultado del modelo predictor en base al análisis de información estadística disponible (línea base) y otras técnicas de ML descritas en la literatura académica con datos similares.
- Desarrollar un sistema de predicción en base al modelo creado y al conjunto de datos utilizado, que pueda ser empleado como herramienta complementaria en un parque eólico.

1.4.3 Alcances

Los alcances y limitaciones de este proyecto son:

- El resultado del modelo ML, será comparado con predicciones estadísticas que posea el parque eólico y con resultados de otros modelos de ML disponibles en literatura académica con datos similares.
- Solo se creará un modelo predictor utilizando técnica de ML.

- Se utilizará un conjunto de datos de un parque eólico chileno, en caso de no obtener estos datos, se utilizarán los que estén disponibles en el sitio de internet Kaggle.com.
- La información estadística para comparar se modelará con una regresión lineal, de esta forma poder hacer la comparación.
- La solución estará basada en redes neuronales artificiales, utilizando perceptrón multicapa y en una red profunda con LSTM.

1.5 METODOLOGÍAS Y HERRAMIENTAS UTILIZADAS

1.5.1 Metodología

La metodología utilizada tiene como marco referencial el proceso CRISP (*Cross Industry Standard Process for Data Mining*) (Figura 1.2), el cual parte por la comprensión del negocio y datos, preparación de los datos, modelado, evaluación e implementación, todo bajo un proceso iterativo hasta encontrar la solución definitiva.

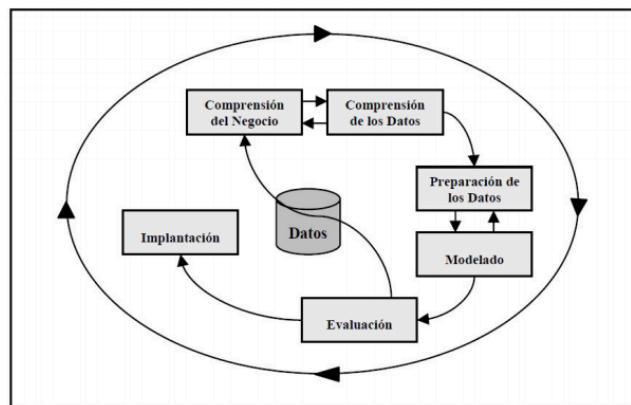


Figura 1-2: Metodología CRISP [8]

En cuanto al proceso de predicción basado en Machine Learning, tendrá como entrada los datos y existirá un proceso de entrenamiento del modelo creado hasta obtener la predicción esperada. Como se puede visualizar en la Figura 1.3, los pasos del proceso de predicción son obtener datos, entender datos y su representación, filtrar datos perdidos y fuera de rango (también llamado preprocesamiento), separar datos de prueba y validación, diseñar modelo neuronal, entrenar modelo, analizar resultado y comparar con datos estadísticos existentes [9]. Este proceso será iterativo y se repetirá hasta encontrar la solución esperada. => describir mejor



Figura 1-3: Proceso de predicción ML [9].

1.5.2 Herramientas de Desarrollo

Las herramientas de desarrollo serán basadas en el lenguaje Python. Éste es un lenguaje de programación de código abierto, su principal característica es su código conciso y legible lo que ayuda a su simplicidad, posee una sintaxis simple que lo hace ser mas ágil, lo que permite que sea mas fácil de escribir y leer, ayudando la colaboración. Adicionalmente posee una gran comunidad que lo soporta y una amplia fuente de librerías y *frameworks*. Todo lo anterior ha hecho que Python sea casi el lenguaje por defecto para *Machine Learning*.

Una de las configuraciones básicas de *Data Science* es: *Jupyter Notebook* + Python + Numpy, con esto se puede crear un modelo ML sin problemas (Figura 1.4). Un complemento de visualización estadística es la librería Pandas (Figura 1.5). Si se requiere utilizar con librerías específicas de ML se usará la librería *Scikit-learn* (Figura 1.6). Para Aprendizaje Profundo, se utilizará la librería Keras, ya que es una de las librerías mas usada (Figura 1.7). Lo importante es que estas librerías son *Open Source* y tiene respaldo de la comunidad, incluyendo empresas privadas y centros científicos.



Figura 1-4: Python para Ciencia de Datos.




Figura 1-5: Librería Python para Análisis de Datos.




Figura 1-6: Machine Learning en Python

Keras: The Python Deep Learning library



Figura 1-7: Librería Python para Aprendizaje Profundo

En cuanto al hardware necesario para este proyecto es un computador *MacBook Pro-15'* (Intel *Core i7* de 6 núcleos y 2,2 GHz, 16 GB de memoria LPDDR3 y SSD de 256 GB), lo que otorgará el rendimiento que permita ejecutar el modelo respectivo.

Adicionalmente se usarán:

- Google Drive, como plataforma de almacenamiento online.
- MS Office 2016, Word y Power Point para la realización de la documentación oficial y preparación de presentaciones, respectivamente.
- draw.io para la realización de diagramas y modelamiento de la aplicación.
- Github para mantener un control de versiones.

1.5.3 Ambiente de Desarrollo

El ambiente de desarrollo será el hardware y software indicados en el punto 1.5.2. El lugar físico será el domicilio del alumno que cuenta con las condiciones necesarias para el trabajo, el cual cuenta con acceso a internet e impresora.

Adicionalmente, se usarán las dependencias del Departamento Informática USACH.

1.6 ORGANIZACIÓN DEL DOCUMENTO

El documento está dividido en X partes, iniciando por este capítulo (introducción), y continuando por el marco teórico que pretende introducir a los conceptos utilizados a lo largo del documento.

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

CAPÍTULO 2: MARCO TEÓRICO

El objetivo de este capítulo es introducir los conceptos utilizados, de esta forma establecer el marco y contextualización en el cual se desarrollará esta memoria de título.

2.1 VIENTOS Y ENERGÍA EÓLICA EN CHILE

El uso industrial del viento en Chile inició con la molienda de cereales y para bombear agua en las salitreras, las primeras décadas del siglo XX. En cuanto a la generación de energía eólica, su uso comenzó en el año 2001. En las zonas costeras los vientos son ideales para la generación de energía, por lo que existe un gran potencial en el país para esta industria [10].

Actualmente, la ERNC (Energía Renovable No Convencional) en Chile es del 24%, donde la energía eólica ocupa el 6,02%, lo que equivale a la generación de 1540 MW. Adicionalmente para este tipo de energía se estiman proyectos por 500 MW/año (aproximadamente). Esto clasifica a Chile como el segundo país en capacidad instalada de energía eólica en América Latina y el Caribe [11]. En relación con la industria de ERNC, Chile ha establecido la Política Energía Nacional 2050, la cual pone como meta tener un 70% de ERNC en el 2050, lo que incrementará la generación de energías renovables incluyendo la eólica.

El proceso de generación de energía eólica consta en convertir la energía cinética del viento en energía eléctrica mediante turbinas que están diseñadas para generar energía eléctrica aprovechando el efecto Venturi. En cuanto a los parques eólicos actuales, usan turbinas modernas de 2 a 3 MW, permitiendo producir la energía de forma eficiente.

2.2 PREDICCIÓN

Para el ser humano siempre ha sido un desafío saber lo que sucederá, que puede ocurrir o cuando puede ocurrir, es importante porque este conocimiento genera una cierta ventaja para anteponerse a los hechos ya que es un paso de lo desconocido a lo conocido [12]. Es importante indicar que la predicción es una parte fundamental del método científico. Al inicio esta predicción se hacía en base a supuesto, hoy los datos son un input fundamental para realizar este proceso. También es importante señalar que la predicción tiene dificultades, ya sea porque existen variables ocultas o dinámicas desconocidas o complejas [13]. Las predicciones no son exactas y no es fácil predecir variables del comportamiento humano o del clima, pero es importante destacar que, aunque no sea exacta la predicción tiene un gran valor, lo que se traduce en “el efecto de predicción: una pequeña predicción tiene un gran valor” [14]. En resumen, aunque actualmente aun existen problemas difíciles de predecir, la predicción tiene una tasa mayor de certeza lo que entrega gran valor, esto es debido, a que la gran cantidad de datos disponibles pueden de alguna manera establecer un comportamiento definido.

2.3 MACHINE LEARNING

Machine Learning (ML) o aprendizaje de máquina, como definió Arthur Samuel, pionero en inteligencia artificial de IBM y *Stanford*: “es el campo de estudio que da a las computadoras la habilidad de aprender sin ser explícitamente programadas” [15], su objetivo es detectar patrones de forma automática a partir de datos de entradas. Los algoritmos empleados se ejecutan en un proceso de aprendizaje supervisado o no supervisado. Como se puede ver en la Figura 2.1, ML es una subárea de inteligencia artificial, actualmente de forma errónea son usadas como sinónimos. A su vez ML tiene como subárea todo lo relacionado Deep Learning. ML es un nuevo campo de la ingeniería informática, la cual ha tenido un auge en los últimos años. Sus algoritmos están basados principalmente en redes neuronales artificiales y las soluciones son abordadas a través de clasificación o regresión [15]. Su utilización ha tomado fuerza, siendo en el 2018 declarado componente tecnológico relevante por la ACM (*Association for Computing Machinery*).




Figura 2-1: Alcance de *Machine Learning* [15].

2.3.1 Una Inspiración Biológica.

Machine Learning está inspirado en los seres cognitivos ya que tienen gran facilidad de reconocer patrones, procesar voz, imagen, etc., lo que se traduce en complejidad, paralelismo y alta conectividad. Todo lo anterior basado en la neurona biológica, que se puede visualizar en la Figura 2.2. Esta neurona tiene la capacidad de recoger información (externa), procesar la información y generar una respuesta activando otra neurona vía sinapsis, algunas pueden generar hasta 100 mil sinapsis [9].




Figura 2-2: Neurona Biológica.

2.3.2 Neuronas Artificiales.

La neurona artificial, modelo de McCulloch y Pitts (1943), es un autómata con el cual se intenta modelar una neurona biológica, es la unidad esencial de una red neuronal. El resultado del cálculo en una neurona consiste en realizar una suma ponderada de las entradas, seguida de la aplicación de una función no lineal, como se ilustra en la Figura 2.3.

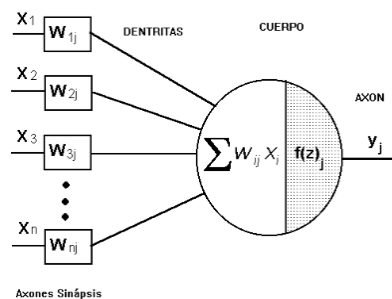


Figura 2-3: Neurona Artificial.

El aprendizaje de la neurona artificial es la capacidad de ajustar las conexiones para satisfacer algún criterio. Este mismo aprendizaje aplica para una red neuronal.

2.3.3 Redes Neuronales.

Una red neuronal, ver Figura 2.4, es un conjunto de neuronas conectadas entre sí que tienen como objetivo procesar (vía operaciones matemáticas) información de entrada, produciendo un

valor de salida. Las conexiones entre si pueden incrementar o disminuir el estado de activación de cada neurona, además la salida de cada neurona tiene una función de activación, la cual pone un limite o umbral modificando el resultado antes que se propague. Una red neuronal se puede usar para aprendizaje o para simulación. La red neuronal es el principal componente tecnológico del ML.




Figura 2-4: Red Neuronal – Perceptrón Multicapa.

Existen varios tipos de redes neuronales, pero es el Perceptrón Multicapa (creado por Frank Rosenblatt en 1958) la red base de aprendizaje maquina o ML, la cual se puede ver en la Figura 4.

Una red neuronal se enfoca en la problemática de aproximación de funciones, Esta problemática se puede resolver mediante clasificación o regresión. Clasificación “es un problema de asignación automática de una etiqueta a una etiqueta sin ejemplo. Detección de SPAM es un famoso ejemplo de clasificación” [6]. Regresión “es un problema de predecir una etiqueta de valor real (a menudo llamada objetivo) dado un ejemplo sin etiqueta. Estimación de la valoración del precio de la vivienda según las características de la casa, como el área, el número de habitaciones, la ubicación, etc. es un famoso ejemplo de regresión” [16].

2.3.4 Tipos de Aprendizajes.

Una red neuronal tiene principalmente dos tipos de aprendizaje, uno supervisado y otro no supervisado. El aprendizaje supervisado realiza predicciones basados en un conjunto de ejemplos, acá el entrenamiento es fundamental (ejemplo, Figura 5). El aprendizaje no supervisado tiene por objetivo organizar los datos de alguna manera o describir su estructura, agrupándolos en clústeres o de forma diferentes (ejemplo, Figura 6).




Figura 2-5: Aprendizaje Supervisado [17].




Figura 2-6: Aprendizaje No Supervisado [17].

2.4 MODELOS

Los seres humanos vivimos en una realidad caótica y compleja, nuestro ordenamiento es basado en patrones que se van identificando en la realidad a través de una mirada simplificada, es decir, construimos la realidad mediante modelos. Los modelos son “representaciones culturales que son construidas a partir de fenómenos reales y proposiciones teóricas, que median entre la teoría y el mundo y que ayudan a satisfacer alguna preocupación humana” [18] y sirven para entender de mejor forma la realidad. Los modelos deben ser simples para lograr el entendimiento de lo que se requiere, generalmente para lograr la representación necesaria se utiliza la probabilidad, así se puede interpretar la incertidumbre existente. Estos modelos son denominados modelos probabilísticos y son la base del ML. Estos modelos son construidos en base a los datos disponibles, los cuales son multidimensionales y representan la realidad. También se debe considerar que los modelos poseen parámetros, estos valores son los que se pueden modificar para adaptar el modelo de mejor forma a la realidad representada por los datos. Finalmente, un modelo puede no representar la realidad al cien por ciento, por esto poseen una función de error que indicará que tan cerca está el modelo de la realidad [19].

2.5 PREDICCIÓN CON MACHINE LEARNING

En ML la forma de predicción más usada es vía series de tiempo, es decir, con datos de entrada (muestras) tomados a intervalos de tiempo periódicas o regulares. Las series de tiempo tienen dos restricciones, dependen del tiempo y tienen algún tipo de estacionalidad, algunos ejemplos de series temporales son: ventas de una compañía, producción de alguna industria, valor de acciones, entre otras. Algunos autores también clasifican la regresión y regresión logística como técnicas de ML, aunque no necesariamente se resuelven vía redes neuronales.

Es importante señalar que la predicción de energía eólica se divide en tres grupos, según su horizonte de predicción y cada uno de ellos tiene un uso distinto considerando el respectivo error asociado, como muestra la Tabla 2.1.

Tabla 2.1: Horizontes de Predicción Energía Eólica [3].

Horizonte Predicción	Tiempo	Error	Uso	Utilidad
Muy Corto Plazo	< 4 hrs.	Menor error de predicción	* Toma decisiones de seguridad de la producción * Operación de red en tiempo real	✓
Corto Plazo	< 48 / 72 hrs.	Error razonable de predicción	* Planificación de producción energética * Toma de decisiones de producción * Seguridad operacional del mercado energético * Planificación de despacho de carga	✓✓
Largo Plazo	< 7 días	Error muy grande de predicción	* Provisión de recursos de producción * Gestión de producción * Planes de mantención * Costo operacional optimo	✓

La predicción de energía eléctrica y más aún cuando es eólica, tiene una complejidad intrínseca debido a su incertidumbre de predicción, esto debido a que la naturaleza de la meteorología es explicada por la dinámica de fluido y el comportamiento caótico de la atmosfera [20], esto conlleva un grado de error en las estimaciones estadísticas y físicas (usando modelos de leyes de la física para predecir energía eléctrica). Esta incertidumbre también se puede visualizar en Figura 1, es decir, la potencia generada a 10 m/s es 8 veces mayor la generada a 5 m/s. Un error en la predicción puede significar un alto error en la generación de energía eléctrica.




Figura 2-7: Curva de potencia de aerogenerador de 2 MW [21].

2.6 CONSIDERACIONES EN MACHINE LEARNING

Para poder llegar a un buen puerto con los modelos y procesos de *Machine Learning*, siempre se deben tener en consideración los siguientes puntos:

2.6.1 Generalización de los Modelos.

“El desafío central del ML es desempeñarse bien con entradas nuevas e inéditas, no solo en aquellas en las que se capacitó nuestro modelo. La capacidad de funcionar bien en entradas no observadas anteriormente se llama generalización” [22]. Generalizar bien se refiere a que la información obtenida, a través de los ejemplos del entrenamiento, sirva para resolver nuevos casos relacionados a los datos del dominio del problema, esto permite predecir a partir de datos que nunca se vieron [23]

2.6.2 Varias Soluciones, Un Mismo Resultado.

Cuando se trabaja en problemas estadísticos, al existir diferentes posibles soluciones siempre se debe mantener el principio de parsimonia. Este principio metodológico también es conocido como Navaja de Ockham, desarrollado por el filósofo y lógico inglés William de Ockham (1287-1347), el cual indica “dadas las mismas condiciones, la explicación que suele ser correcta es la mas sencilla”. Este concepto también es utilizado cuando se trabaja en problemas de ML y se ve reflejada cuando se indica que “soluciones simples generalizan mejor”, esto quiere decir que, si el modelo tiene 1.000 características y se puede explicar la predicción con 10 de estas, se deben usar solo estas 10 [24]. Es importante mantener este concepto cuando se crea el modelo predictor.

2.6.3 Datos No Representan el Negocio.

Una de las principales limitantes es cuando los datos no representan el negocio o la problemática que se debe modelar, por esto es importante entender claramente el caso de negocio o el problema a resolver y con esto validar que los datos sean representativos. Para lograr lo anterior se usarán los pasos propuestos por el modelo CRISP [8] que son: recolectar la data, describir data, explorar data y verificar la calidad de esta. En esta tesis se abordará como Análisis Descriptivo en el **capítulo NNN**.

2.6.4 Cantidad de Datos No Son Suficientes.

Ni la literatura ni las discusiones relacionadas han definido alguna formula para determinar cual es la cantidad de datos que se necesita para que un modelo funcione de forma correcta, lo que si se sabe es que entre mas datos se usan para el entrenamiento, los modelos generalizan mejor [22]. Por esto se debe asegurar una cantidad y calidad de datos suficientes que sean relevantes para el problema que se va a abordar, de esta forma el modelo entregará el valor esperado [25]. Como indica Brooks en su clásico ensayo, en relación con la tecnología “no sólo no hay balas de plata a la vista, sino que la misma naturaleza del software impide que las haya” [26] y para las soluciones ML aplica el mismo concepto, no es solución a todos los problemas, estas soluciones son valiosas si entregan una respuesta con valor al problema abordado, para esto los datos son fundamentales ya que son la base del ML.

2.6.5 Ruido.

Cuando se habla de ruido en ML, se hace en directa relación a los datos utilizados por los modelos, y son todos aquellos datos que no aportan valor, distorsionan los datos de interés, limitan el estudio de la clase predictora definida y/o no tienen relación con ésta [27]. Algunos ejemplos de ruido son errores en etiquetas o datos fuera de rango (*outliers* en inglés) [16]. El concepto principal es que en la etapa de preprocesamiento se deben limpiar los datos “ruidos” y solo dejar los datos valiosos para el modelo, este proceso se realiza mediante herramientas estadísticas [28]. La limitación del ruido en los datos del mundo real es normal. Muchos factores y errores extraños distorsionan los valores de los datos. Un buen algoritmo ML debe distinguir las señales que pueden ser mapeada a la función objetivo y poder dejar de lado el ruido de los datos o variable a predecir [29].

2.6.6 Overfitting y Underfitting.

Como ya se revisó anteriormente la capacidad de generalización del modelo es el desafío central del ML. Adicionalmente los factores que determinan un buen funcionamiento de un algoritmo de ML son su capacidad en:

- Hacer que el error de entrenamiento sea pequeño.
- Hacer que el error entre el entrenamiento y prueba sea pequeño.

Para poder resolver lo anterior hay que enfrentar los dos desafíos *underfitting* (bajo ajuste) y *overfitting* (sobre ajuste) [22]. “*Underfitting* ocurre cuando el modelo no puede obtener un valor de error suficientemente bajo en el conjunto de entrenamiento. *Overfitting* ocurre cuando la brecha entre el error de entrenamiento y el error de prueba es demasiado grande” [22]. En otras palabras, *Overfitting* se refiere cuando un modelo es muy ajustado (exceso de flexibilidad) que incluso representa el ruido de los datos [30], es decir el modelo se especializa demasiado en los casos para los cuales ha sido entrenado, casi como memorizaran la solución mas que aprender [31]. Por otro lado, *Underfitting* es cuando un modelo está mal ajustado (falta de flexibilidad) ya que la función objetivo utilizada no se adapta a los valores de los datos, por lo tanto, no tiene la capacidad de aprender. Para esta consideración la clave es de tener un modelo en el punto intermedio capaz de aprender el entrenamiento y generalizar el conocimiento.

2.7 RESUMEN

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

.

CAPÍTULO 3: ANÁLISIS Y DISEÑO

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

3.1 DISEÑANDO EL PROCESO DE PREDICCIÓN

3.1.1 Obtención de Datos

Como se ha mencionado anterior mente los datos son fundamentales para realizar el modelo de ML, para este caso existían dos potenciales fuentes de los datos. El primero era un importante parque eólico nacional y el segundo información que proveía el sito de competencia de ML Kaggle.com . Aunque se hicieron muchas gestiones con el parque eólico nacional, no fue posible obtener los datos necesarios, por esta razón utilizaron los datos de Kaggle de la competición “*Global Energy Forecasting Competition 2012 – Wind Forecasting*” [32], un problema de predicción de la generación de energía eólica por hora hasta 48 horas de anticipación en 7 parques eólicos. El modelo realizado se podrá probar con datos nacionales cuando exista disponibilidad de estos.

3.1.2 Entendimiento de los Datos y su Representación

La problemática es la predicción de generación de energía eólica usando ML para un horizonte de predicción de corto plazo. Para esto se utilizará el conjunto de datos (*dataset* en inglés) que se encuentra contenido en el archivo *GEF2012-wind-forecasting.zip* y tiene el detalle que se describe en la Tabla 3.1.

Tabla 3.1: Descripción de Archivos del Conjunto de Datos.

Nombre Archivo	Descripción
train.csv	Contiene datos de entrenamiento
test.csv	Contiene datos para realizar pruebas (test en inglés)
benchmark.csv	Proporciona ejemplos de resultados de pronóstico del método de pronóstico de persistencia ("lo que ve es lo que obtiene"). Este archivo también proporciona una plantilla para el envío de resultados que deben seguirse estrictamente.
windforecasts_wf1.csv	Pronósticos de viento con variables explicativas para el parque eólico 1.
windforecasts_wf2.csv	Pronósticos de viento con variables explicativas para el parque eólico 2.

windforecasts_wf3.csv	Pronósticos de viento con variables explicativas para el parque eólico 3.
windforecasts_wf4.csv	Pronósticos de viento con variables explicativas para el parque eólico 4.
windforecasts_wf5.csv	Pronósticos de viento con variables explicativas para el parque eólico 5.
windforecasts_wf6.csv	Pronósticos de viento con variables explicativas para el parque eólico 6.
windforecasts_wf7.csv	Pronósticos de viento con variables explicativas para el parque eólico 7.

A continuación, se describirá cada una de las variables que contiene cada archivo. Las variables del archivo de entrenamiento se pueden ver en la Tabla 3.2, para el archivo de pruebas ver la Tabla 3.3. Para las variables del archivo *benchmark* se visualizan en la Tabla 3.4 y las variables de cada parque eólico (1 hasta 7) están en Tabla 3.5:

Tabla 3.2: Descripción de Variables para Datos de Entrenamiento.

Nombre	Descripción	Ejemplo	Valores	Tipo
date	Es una indicación de fecha y hora de las mediciones por hora de energía eólica.	"2009070812" es para el 8 de julio de 2009 a las 12:00;	Fecha y hora	Continua
wp1 hasta wp7	Medidas de energía eólica para los 7 parques eólicos. Normalizados para tomar valores entre 0 y 1.	"0.233"	Numérica	Continua

Tabla 3.3: Descripción de Variables para Datos de Prueba.

Nombre	Descripción	Ejemplo	Valores	Tipo
id	Identificador único para cada registro	"1"	Numérica	Discreta
date	Es una indicación de fecha y hora de las mediciones por hora de energía eólica.	"2009070812" es para el 8 de julio de 2009 a las 12:00;	Fecha y hora	Continua

Tabla 3.4: Descripción de Variables para Datos de Benchmark.

Nombre	Descripción	Ejemplo	Valores	Tipo
id	Identificador único para cada registro	"1"	Numérica	Discreta
date	Es una indicación de fecha y hora de las	"2009070812" es para el 8 de julio de 2009 a las 12:00;	Fecha y hora	Continua

	mediciones por hora de energía eólica.			
wp1 hasta wp7	Medidas de energía eólica para los 7 parques eólicos. Normalizados para tomar valores entre 0 y 1.	"0.233"	Decimal	Continua

Tabla 3.5: Descripción de Variables de los Parques Eólicos 1 hasta 7.

Nombre	Descripción	Ejemplo	Valores	Tipo
date	Fecha y hora en la que se emiten los pronósticos	"2009070812" es para el 8 de julio de 2009 a las 12:00;	Fecha y hora	Continua
hors	Tiempo de entrega del pronóstico	"28" es para el horizonte de predicción de 28 hrs.	Numérica	Discreta
u	Componente de viento zonal (Vector velocidad eje x)	"2.34"	Decimal	Continua
v	Componente de viento meridional (Vector velocidad eje y)	"-0.79"	Decimal	Continua
ws	Velocidad del viento	"2.47"	Decimal	Continua
wd	Dirección del viento	"108.68"	Numérica	Continua

De este primer análisis de los datos se pueden obtener las siguientes conclusiones sobre ellos:

- La información del viento es representada de dos formas equivalentes, es decir de forma cartesiano (variables u y v) y vectorial (variables ws y wd).
- Los archivos de cada parque o central eólica representan las variables del viento sobre la predicción de generación de energía eólica.
- El archivo *benchmark* contiene toda la información de energía generada que fue medida por el horizonte de tiempo, el cual es medido cada una hora
- El archivo de entrenamiento posee información de energía eólica producida por fecha y para cada central eólica.

- El archivo de prueba también posee información de energía eólica producida por fecha y para cada central eólica. Como no viene en el mismo formato del archivo de entrenamiento, se debe reconstruir para que quede homologado al formato de entrenamiento.

3.1.2 Definición de las Métricas

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

3.2 ANÁLISIS ESTADÍSTICO DESCRIPTIVO E INFERENCIAL

3.2.1 Limpiar y Adecuar los Datos

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

3.2.2 Análisis Descriptivo

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

3.2.3 Análisis Inferencial

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

3.3 ARQUITECTURA DE REDES NEURONALES

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

3.5 RESUMEN

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

5.2 TRABAJOS FUTUROS

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

5.3 REFLEXIÓN PERSONAL

loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu
loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu loren ipsu

REFERENCIAS

- [1] Association for Computing Machinery (2018). *Fathers of the Deep Learning Revolution Receive ACM A.M. Turing Award*. Disponible: <https://awards.acm.org/about/2018-turing>.
- [2] J. Clerc, J. Olmedo, J. Peralta, M. Saavedra, E. Sauma, I. Urzúa, A. Hernando. "Energías renovables en Chile. Hacia una inserción eficiente de la matriz eléctrica", Centro de Estudios Públicos (CEP), Chile, 2017.
- [3] L. Fernández, "Modelos avanzados para la predicción a corto plazo de la producción eléctrica de parques eólicos", Tesis Doctoral, Universidad de la Rioja, Logroño, España, 2007.
- [4] Ministerio de Energía de Chile (2016). Política Energética de Chile. Disponible: <http://www.energia2050.cl/>.
- [5] C. González, D. López (2013). Energía eólica y su intermitencia ¿mayor predicción del viento o almacenamiento de energía? Disponible: <http://latinoamericarenovable.com/2013/07/27/energia-eolica-y-su-intermitencia-mayor-prediccion-del-viento-o-almacenamiento-de-energia/>.
- [6] G. Kariniotakis, G. Stavrakakis, E. Nogaret, "Wind power forecasting using advanced neural networks models", *IEEE Transaction on Energy Conversion*, Vol.11, no.4, 762-767, 1996.
- [7] I. Erbetta, "Predicción de la potencia para la operación de parques eólicos", Tesis de Ingeniería Civil Electricista, Universidad de Chile, Santiago, Chile, 2010.
- [8] P. Chapman, J. Clinton, R. Kerber, T. Khabaza, T. Reinartz, C. Shearer, R. Wirth. "Step-by-step data mining guide", *CRISP-DM Consortium (NCR, DaimlerChrysler, SPSS & Bank Groep B.V.)*, USA, 2000.
- [9] G. Acuña, "Curso Redes Neuronales", Apuntes no publicados, Universidad de Santiago de Chile. Segundo semestre 2018.
- [10] Ministerio de Energía de Chile (2016). El desarrollo de la energía. Disponible: <https://www.aprendeconenergia.cl/el-desarrollo-de-la-energia-eolica-en-chile/>.
- [11] Global Wind Energy Council (2017). Installed Wind Capacity Worldwide. Disponible: <https://gwec.net/publications/global-wind-report-2/>.
- [12] J. Aramburu, "El problema de la predicción en las Ciencias Sociales", Tesis en Sociología, Universidad Nacional de la Plata, Buenos Aires, Argentina, 2005.
- [13] N. Silver. *The Signal and the Noise*. The Penguin Press. 2012.
- [14] E. Siegel. *Predictivity Analytics*. Wiley. 2013.
- [15] J. Patterson, A. Gibson. *Deep Learning: A Practitioner's Approach*. O'Reilly. 2017.
- [16] A. Burkov. *The Hundred-Page Machine Learning*. Andriy Burkov. 2019.
- [17] Ligdi González (2018). Aprendizaje Supervisado y No Supervisado. Disponible: <http://ligdigonzalez.com/clasificacion-de-machine-learning/>.
- [18] A. Adúriz-Bravo, "Algunas características clave de los modelos científicos relevantes para la educación química", Universidad Autónoma de México, Educación Química Vol.23, supl.2 México, mayo 2012.
- [19] C. Santana (2017). Modelos para entender una realidad caótica. Disponible: <https://www.youtube.com/watch?v=Sb8XVheowVQ>

- [20] E. Lorenz. *The Essence of Chaos*. University of Washington Press. 1995.
- [21] CORFO (2013). Guía de desarrollo de pequeños y medianos proyectos de Energía Eólica. Disponible: http://dataset.cne.cl/Energia_Abierta/Estudios/CER/Gu%C3%ADa%20eolica%20desarrollo%20de%20proyectos%20peque%C3%B1os%20y%20medianos.pdf.
- [22] I. Goodfellow, Y. Bengio y A. Courville. *Deep Learning*. The Mit Press. 2016.
- [23] J. Brownlee (2019). Machine Learning Mastery. Disponible: <https://machinelearningmastery.com/>
- [24] H. Daumé (2017). *A Course of Machine Learning*. Self-Published. 2017.
- [25] J. Kuperman, F. Naselli, J. Gabaldón. “*Machine Learning*, Inteligencia Artificial y Big Data: Lo que todo directivo debe saber”, Asociación Española de Directivos, *Digital Basics* N° 4 España, 2019.
- [26] F. Brooks. *No Silver Bullet - Essence and Accident in Software Engineering*. *Proceedings of the IFIP Tenth World Computing Conference*: 1069-1076. 1986.
- [27] J. Márquez, “Tutorial: Ruido”, Tutorial no publicado, Universidad Nacional Autónoma de México. CCADET-UNAM 2014.
- [28] J. Toro, D. Pascual y F. Vasquez, “Limpieza de ruido para clasificación basado en vecindad y cambios de conceptos en el tiempo”, Universidad de Las Ciencias Informáticas, Revista Cubana de Ciencias Informáticas Vol.10, no.2 La Habana, abril-junio 2016.
- [29] J. Mueller y L. Massaron. *Machine Learning for Dummies*. Wiley. 2016.
- [30] C. Santana (2019). Las Rede Neuronales ¿Aprenden o Memorizan? – *Overfitting y Underfitting*. Disponible: <https://www.youtube.com/watch?v=7-6X3DTt3R8>
- [31] A. Brock, J. Donahue, K. Simonyan, “Large Scale Gan Training for High Fidelity Natural Image Synthesis”, International Conference on Learning Representations (ICLR), 2019.
- [32] Kaggle.com (2012). Global Energy Forecasting Competition 2012 - Wind Forecasting. Disponible: <https://www.kaggle.com/c/GEF2012-wind-forecasting>

APENDICE A: HISTORIAS DE USUARIO

Taba A.1: Ipsu Loren

Taba A.2: Ipsu Loren

Código	Nombre	Descripción	Fuente
01	ipsu loren ipsu	ipsu loren ipsu	ipsu loren ipsu
02	ipsu loren ipsu	ipsu loren ipsu	ipsu loren ipsu
15	ipsu loren ipsu	ipsu loren ipsu	ipsu loren ipsu